



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΗΛΕΚΤΡΟΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ ΚΑΙ
ΠΛΗΡΟΦΟΡΙΚΗΣ

Αναγνώριση Συναισθήματος σε Διαλόγους
Κειμένου με χρήση Μεγάλων Γλωσσικών
Μοντέλων

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

ΤΟΥ

ΜΕΝΕΙ ΕΜΑΝΟΥΕΛΟ

Επιβλέπων Καθηγητής: Σωτήριος Νικολετσέας

Πάτρα, Σεπτέμβριος 2024



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΗΛΕΚΤΡΟΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ ΚΑΙ
ΠΛΗΡΟΦΟΡΙΚΗΣ

Αναγνώριση Συναισθήματος σε Διαλόγους
Κειμένου με χρήση Μεγάλων Γλωσσικών
Μοντέλων

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

ΤΟΥ

ΜΕΝΕΙ ΕΜΑΝΟΥΕΛΟ

Επιβλέπων Καθηγητής: Σωτήριος Νικολετσέας

Εγκρίθηκε από την τριμελή εξεταστική επιτροπή την 30 Σεπτεμβρίου 2024.

(Υπογραφή)

(Υπογραφή)

(Υπογραφή)

.....

Σωτήριος Νικολετσέας
Καθηγητής

.....

Σταύρος Κοσμάδakis
Καθηγητής

.....

Χρήστος Μακρής
Αν.Καθηγητής

Πάτρα, Σεπτέμβριος 2024



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΗΛΕΚΤΡΟΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ ΚΑΙ
ΠΛΗΡΟΦΟΡΙΚΗΣ

Copyright ©–All rights reserved Εμανουέλο Μένξι, 2024.

Με την επιφύλαξη παντός δικαιώματος.

Απαγορεύεται η αντιγραφή, αποθήκευση και διανομή της παρούσας εργασίας, εξ ολοκλήρου ή τμήματος αυτής, για εμπορικό σκοπό. Επιτρέπεται η ανατύπωση, αποθήκευση και διανομή για σκοπό μη κερδοσκοπικό, εκπαιδευτικής ή ερευνητικής φύσης, υπό την προϋπόθεση να αναφέρεται η πηγή προέλευσης και να διατηρείται το παρόν μήνυμα.

Το περιεχόμενο αυτής της εργασίας δεν απηχεί απαραίτητα τις απόψεις του Τμήματος, του Επιβλέποντα, ή της επιτροπής που την ενέκρινε.

Υπεύθυνη Δήλωση

Βεβαιώνω ότι είμαι συγγραφέας αυτής της πτυχιακής εργασίας, και ότι κάθε βοήθεια την οποία είχα για την προετοιμασία της είναι πλήρως αναγνωρισμένη και αναφέρεται στην πτυχιακή εργασία. Επίσης έχω αναφέρει τις όποιες πηγές από τις οποίες έκανα χρήση δεδομένων, ιδεών ή λέξεων, είτε αυτές αναφέρονται ακριβώς είτε παραφρασμένες. Επίσης, βεβαιώνω ότι αυτή η πτυχιακή εργασία προετοιμάστηκε από εμένα προσωπικά ειδικά για τις απαιτήσεις του προγράμματος σπουδών του τμήματος Μηχανικών Ηλεκτρονικών Υπολογιστών και Πληροφορικής του Πανεπιστημίου Πατρών.

(Υπογραφή)

.....

Εμανουέλο Μένξι

Περίληψη

Σε μία εποχή όπου ο άνθρωπος επικοινωνεί τα συναισθήματά του όλο και συχνότερα χρησιμοποιώντας ψηφιακά μέσα, η ικανότητα των μηχανών να αναγνωρίζουν και να ερμηνεύουν αυτά τα συναισθήματα γίνεται ολοένα και πιο σημαντική. Η παρούσα διπλωματική εργασία εξερευνά την πολύπλοκη πρόκληση της αναγνώρισης συναισθημάτων σε διαλόγους κειμένου, αξιοποιώντας τις τελευταίες εξελίξεις στα μεγάλα γλωσσικά μοντέλα (LLMs). Η έρευνα χρησιμοποιεί τρία από τα πιο σύγχρονα και ισχυρά μοντέλα —GPT-4o-2024-08-06, Claude-3-5-Sonnet-20240620, και LLaMA3— για να εξετάσει πώς αυτά μπορούν να προσαρμοστούν και να βελτιωθούν ώστε να κατανοούν την λεπτή συναισθηματική πληροφορία που είναι κρυμμένη στις ανθρώπινες αλληλεπιδράσεις.

Στόχος της έρευνας είναι να γεφυρώσει το χάσμα μεταξύ της θεωρίας των συναισθημάτων της υπολογιστικής γλωσσολογίας και της πληροφορικής με άξονες ανάλυσης τις ταξινομίες των συναισθημάτων, τις διανυσματικές αναπαραστάσεις λέξεων και τα LLMs. Με την αξιολόγηση και προσαρμογή αυτών των μοντέλων μέσω τεχνικών fine-tuning και prompt-engineering, η μελέτη στοχεύει στη βελτίωση της ικανότητάς τους να ανιχνεύουν και να ταξινομούν συναισθήματα σε διαλόγους με μεγαλύτερη ακρίβεια.

Μέσα από μια σειρά συγκριτικών πειραμάτων, το έργο αυτό αξιολογεί την απόδοση κάθε LLM στην αναγνώριση συναισθηματικών καταστάσεων σε μια ποικιλία συλλεγμένων δεδομένων κειμενικών διαλόγων. Ο τελικός στόχος της διπλωματικής αυτής είναι να διευρύνει τα όρια της ανίχνευσης συναισθημάτων μέσω της μηχανικής μάθησης, προάγοντας τόσο την τεχνολογία όσο και την κατανόηση του πώς τα γλωσσικά μοντέλα μπορούν να συνδεθούν βαθύτερα με τα ανθρώπινα συναισθήματα στην ψηφιακή εποχή.

Λέξεις Κλειδιά

Μεγάλα Γλωσσικά Μοντέλα, Αναγνώριση Συναισθήματος σε Διαλόγους, Prompt Engineering

Abstract

In a world where human emotions are often communicated through digital means, the ability for machines to recognize and interpret these emotions is becoming increasingly crucial. This thesis delves into the complex challenge of emotion recognition in text-based dialogues using the latest advancements in large language models (LLMs). The study harnesses the power of three cutting-edge models —GPT-4o-2024-08-06, Claude-3-5-Sonnet-20240620, and LLaMA3— to explore how they can be fine-tuned and adapted to understand the subtle emotional cues embedded in human interactions.

The research aims to bridge the gap between emotion theory, computational linguistics and informatics, leveraging powerful LLMs to capture the nuances of human emotions. By evaluating and adapting these models through fine-tuning and prompt-engineering techniques, the study seeks to enhance their ability to detect and classify emotions in dialogues with greater precision.

Through a series of comparative experiments, this work assesses the performance of each LLM in recognizing emotional states across a range of conversational contexts from a specially curated dataset. The ultimate goal of this thesis is to push the boundaries of what is possible in emotion detection through machine learning, advancing both the technology and our understanding of how language models can connect more deeply with human emotions in the digital age.

Keywords

Large Language Models, Emotion Recognition in Conversations, Prompt Engineering

στον παππού μου

Ευχαριστίες

Θα ήθελα καταρχήν να ευχαριστήσω τον καθηγητή κ.Σωτήριο Νικολετσέα για την επίβλεψη αυτής της διπλωματικής εργασίας και για την ευκαιρία που μου έδωσε να διατριβώ σε αυτό το τόσο ενδιαφέρον διεπιστημονικό αντικείμενο. Με βοήθησε να εντοπίσω έναν κλάδο στον οποίο μπορεί να απλωθεί όλη μου η ερευνητική περιέργεια. Επίσης ευχαριστώ ιδιαίτερα τον υποψήφιο Διδακτορικό Γκαντάλλα Μηνά, η ανελλιπής καθοδήγηση, ώθηση και συμβολή του οποίου, από την διαμόρφωση της εργασίας μέχρι και την εκπόνηση των πειραμάτων, ήταν καθοριστική και έκανε την δημιουργία αυτού του έργου εφικτή.

Περιεχόμενα

Περίληψη	i
Abstract	ii
Ευχαριστίες	iv
Περιεχόμενα	vi
Κατάλογος Σχημάτων	viii
Κατάλογος Πινάκων	ix
1 Εισαγωγή	1
1.1 Σημασία του προβλήματος	1
1.2 Στόχοι της Διπλωματικής Εργασίας	2
1.3 Συνεισφορά της Διπλωματικής Εργασίας	2
1.4 Διάρθρωση της Διπλωματικής Εργασίας	3
2 Θεωρητικό Υπόβαθρο	4
2.1 Θεωρία Συναισθημάτων και διασταύωση με Πληροφορική	4
2.1.1 Μελέτη των Συναισθημάτων	5
2.1.2 Μοντέλα και Ταξινομίες	5
2.2 Ορισμός ως Πληροφοριακό Πρόβλημα	7
2.2.1 Σημαντικές παράμετροι στην αναγνώριση συναισθήματος	7
2.2.2 Σύνολα Δεδομένων	8
2.3 Σχετική Βιβλιογραφία	10
3 Μέθοδοι Αναπαράστασης Λέξεων και Γλωσσικά Μοντέλα	14
3.1 Εισαγωγή	14
3.2 Αναπαράσταση λέξεων	15
3.2.1 Παραδοσιακές μέθοδοι	15
3.2.2 Μέθοδοι κατανεμημένης αναπαράστασης	21
3.2.3 Contextual αναπαραστάσεις λέξεων	25
3.3 Γλωσσικά Μοντέλα	26

3.3.1	Παραδοσιακά Μοντέλα	26
3.3.2	Νευρωνικά Μοντέλα	27
3.3.3	Transformer-Based Μοντέλα	27
4	Προσαρμογή προ-εκπαιδευμένων Γλωσσικών Μοντέλων	38
4.1	Fine-Tuning	39
4.2	Μάθηση βασισμένη σε προτροπές	39
4.2.1	Prompt engineering	40
4.2.2	Τύποι προτροπών	40
4.2.3	Εξελίξεις	41
5	Πειραματική αξιολόγηση και αποτελέσματα	43
5.1	Διαμόρφωση Πειράματος	43
5.2	Μεθοδολογία	44
5.2.1	Ενημέρωση Ταξινόμιας	44
5.2.2	Δημιουργία Συνόλου Δεδομένων	45
5.3	Πειραματική Αξιολόγηση	54
5.4	Αποτελέσματα πειραμάτων	59
5.4.1	Prompt-based Προσαρμογή	59
5.4.2	Σύγκριση prompt engineering - fine tuning	60
6	Συμπεράσματα και Μελλοντικές επεκτάσεις	62
6.1	Συμπεράσματα	62
6.2	Μελλοντικές Επεκτάσεις	63
A'	Παράρτημα	65
A'.1	Πρώτη ενότητα	65

Κατάλογος Σχημάτων

2.1	Τρισδιάστατη αναπαράσταση του μοντέλου Valence-Arousal για τα 6 βασικά συναισθήματα [12]	6
2.2	Παράδειγμα αναγνώρισης συναισθήματος σε διάλογο για $M = 3$ [56]	8
2.3	Διάγραμμα δικτύου keyword co-occurrence[53]	11
2.4	Συγκριτική ανάλυση προ-εκπαιδευμένων μοντέλων [52]	12
3.1	Αρχιτεκτονική των δύο μοντέλων[65]	23
3.2	Οπτικές αναλογίες που προκύπτουν από το W2V,Google Labs	24
3.3	Επίδειξη αναπαραστάσεων του ELMo σε σύγκριση με του glove, από[80]	25
3.4	Αρχιτεκτονική ενός (left-to-right) Transformer που επιδυνώνει την κωδικοποίηση κάθε token εισόδου[46]	28
3.5	Ροή πληροφορίας στην αυτό-προσοχή[46]	30
3.6	Encoder-Decoder Αρχιτεκτονική: [105]	31
3.7	BERT input representations: Η είσοδος είναι το άθροισμα των token embeddings, segment embeddings and position embeddings[105]	33
3.8	Επισκόπηση των μοντέλων LLaMA 3[29], των δυνατοτήτων και ημερομηνιών έκδοσης τους	37
3.9	Συγκριτική επίδοση fine tuned LLaMA 3 με άλλα ισχυρά γλωσσικά μοντέλα σε evaluation benchmarks όπως μαθηματική ικανότητα, reasoning, παραγωγή κώδικα κ.ο.κ.[29]	37
5.1	Κατανομή συναισθημάτων που χρησιμοποιούνται στις ταξινομίες της βιβλιογραφίας. Εμφανής είναι η τάση για υιοθέτηση της ταξινόμιας Έκμαν συγκριτικά με ταξινομίες που περιλαμβάνουν άλλα συναισθήματα[25]	44
5.2	Κατανομή Συναισθημάτων στο νέο σύνολο δεδομένων	52
5.3	Κατανομή Sentiment στο dataset, χωρισμένα σε αμφίσημα, θετικά και αρνητικά.	54
5.4	Heatmap συναισθημάτων ταξινομημένων βάσει Sentiment και την συχνότητα εμφάνισής τους. Όσο πιο κόκκινο το δείγμα, τόσο συχνότερα εμφανίζεται το αντίστοιχο συναίσθημα.	55
5.5	Loss plots στην εκπαίδευση, με πράσινο συμβολίζεται το Training Loss ενώ με μωβ το Validation Loss	60

5.6 Σύγκριση απόδοσης fine tuned GPT με Prompt tuning, ο κάθετος άξονας αντιπροσωπεύει το ποσοστό επιτυχίας και ο οριζόντιος τα ύπο-αξιολόγηση μοντέλα	61
--	----

Κατάλογος Πινάκων

2.1	Σύνοψη διαφόρων συνόλων δεδομένων για Αναγνώριση Συναισθήματος[25] με πληροφορίες για την ταξινόμια που υιοθετεί, την γλώσσα, πηγή και μέγεθος τους	9
2.2	Παραδείγματα χρήσης παραλλαγών του BERT κατά την βιβλιογραφία	12
3.1	Συχνότητα όρων κάθε εγγράφου	17
3.2	Συχνότητα όρων κάθε Εγγράφου	20
3.3	Πλήθος εγγράφων που περιέχουν κάθε λέξη	20
3.4	Inverse Document Frequencies	21
3.5	Βάρη TF-IDF για κάθε έγγραφο	21
5.1	Λίστα Συναισθημάτων που προέκυψαν από την συνάντηση των ταξινομιών της βιβλιογραφίας	45
5.2	Σύνοψη συνόλων δεδομένων για Αναγνώριση Συναισθήματος και λόγοι μη συμβατότητας με το πλαίσιο/σκοπό της εργασίας	46
5.3	Στοιχεία των Συμμετεχόντων της διαδικασίας ανάθεσης συναισθημάτων	47
5.4	Παράδειγμα ενός διαλόγου από το σύνολο δεδομένων. Περιλαμβάνει τα κομμάτια του διαλόγου καθώς και τους ομιλητές που τα εκφέρουν.	50
5.5	Παράδειγμα ανάθεσης συναισθημάτων από την ταξινόμια στα επιμέρους κομμάτια του διαλόγου από τυχαίο χρήστη y.	50
5.6	Παράδειγμα ανάθεσης συναισθημάτων από την ταξινόμια στα επιμέρους κομμάτια του διαλόγου από 2ο τυχαίο χρήστη x.	51
5.7	Παράδειγμα ανάθεσης συναισθημάτων από την ταξινόμια στα επιμέρους κομμάτια του διαλόγου από 3ο τυχαίο χρήστη z.	51
5.8	Αποτελέσματα εκλογής τελικού συναισθήματος ύστερα από την διαδικασία κανονικοποίησης.	51
5.9	Κατανομή πλήθους συναισθημάτων στο σύνολο δεδομένων	53
5.10	Δείγματα ανά σύνολο	58
5.11	Ποσοστά ακρίβειας κάθε μοντέλου	59
5.12	Ποσοστό βελτίωσης ανά prompt (improvement margin)	59

Με τις τελευταίες επιστημονικές συνεισφορές ερευνητικών κέντρων όπως η OpenAI στην ανάπτυξη Artificial General Intelligence (AGI - Γενική Τεχνητή Νοημοσύνη), η ικανότητα τέτοιων μοντέλων να ‘κατανοούν’ τον ανθρώπινο λόγο είναι εντυπωσιακή. Ωστόσο, παρά την πρόοδο αυτή, η τεχνητή νοημοσύνη εξακολουθεί να υστερεί σε έναν κρίσιμο τομέα: την ικανότητα κατανόησης και ερμηνείας των συναισθημάτων.

Η *R.W. Picard*, πρωτοπόρος στον τομέα του Affective Computing, τόνισε χαρακτηριστικά:

«Αν οι άνθρωποι θέλουν οι υπολογιστές να γίνουν πραγματικά ευφυής και να αλληλεπιδρούν φυσικά με τους ανθρώπους, πρέπει να τους κάνουμε ικανούς να αναγνωρίζουν, να ερμηνεύουν και να εκφράζουν συναισθήματα»[82].

1.1 Σημασία του προβλήματος

Παρά την αλματώδη πρόοδο που έχει σημειωθεί στη μηχανική μάθηση και την τεχνητή νοημοσύνη, η αντίληψη και κατανόηση των συναισθημάτων από τους υπολογιστές παραμένει ένα ανεπίλυτο πρόβλημα, δημιουργώντας ένα τεράστιο κενό στην έρευνα της τεχνητής νοημοσύνης. Η δυνατότητα των μηχανών να κατανοούν τα συναισθήματα είναι καθοριστική για τη προσομοίωση της συναισθηματικής νοημοσύνης, απαραίτητη σε πολλές εφαρμογές όπου οι υπολογιστές χρειάζεται να επικοινωνούν με ανθρώπους με φυσικό και ουσιαστικό τρόπο. Μέχρι να επιτύχουμε αυτή τη θεμελιώδη κατανόηση των συναισθημάτων, οι μηχανές θα παραμένουν ανίκανες να αλληλεπιδρούν με ανθρώπους με φυσικό τρόπο που να αντανακλά την ανθρώπινη συναισθηματική πολυπλοκότητα. Η αποτυχία της τεχνητής νοημοσύνης να προσομοιώσει την

κατανόηση και έκφραση συναισθημάτων αποτελεί έναν από τους μεγαλύτερους περιορισμούς στην ανάπτυξη πλήρους ανθρώπινης ικανότητας σε υπολογιστικά συστήματα, θέτοντας ένα αυστηρό άνω φράγμα στις δυνατότητες τους.

Στο πεδίο της αναγνώρισης συναισθημάτων από κείμενο, αυτή η πρόκληση ενισχύεται από την σημασιολογική πολυπλοκότητα της φυσικής γλώσσας, την δυσκολία απόδοσης των συμφραζομένων και τις λεπτές αποχρώσεις που φέρει κάθε ανθρώπινη συνομιλία. Η δυνατότητα εντοπισμού και ακριβούς ερμηνείας συναισθημάτων σε διαλόγους είναι απαραίτητη για τη βελτίωση πολλών εφαρμογών, από την εξυπηρέτηση πελατών έως την ψυχική υγεία και τις αλληλεπιδράσεις με προσωπικούς ψηφιακούς βοηθούς. Η αναγνώριση συναισθημάτων δεν αποτελεί απλώς μία ενδιαφέρουσα διεπιστημονική πρόκληση, αλλά μια αναγκαιότητα για την επόμενη γενιά συστημάτων τεχνητής νοημοσύνης.

1.2 Στόχοι της Διπλωματικής Εργασίας

Ο κύριος στόχος της παρούσας διπλωματικής εργασίας είναι η βελτίωση της ακρίβειας της αναγνώρισης συναισθημάτων σε διαλόγους κειμένου μέσω της χρήσης και προσαρμογής μεγάλων γλωσσικών μοντέλων (LLMs). Οι στόχοι συνοψίζονται ως εξής:

1. Να εξεταστεί και να **ενημερωθεί η θεωρητική βάση** της αναγνώρισης συναισθημάτων και η σύγκλιση της με την πληροφορική.
2. Να χαρτογραφηθούν οι μέθοδοι διανυσματικής αναπαράστασης-ενσωμάτωσης λέξεων (word embeddings) και η εξέλιξη των μηχανισμών των LLMs που σχετίζονται με την αναγνώριση συναισθημάτων.
3. Να προταθεί ένα **νέο σύνολο δεδομένων** που περιλαμβάνει κειμενικά δεδομένα διαλόγων και αμερόληπτες αναθέσεις από ανθρώπους (annotations) σε διευρημένες συναισθηματικές ταξονομίες.
4. Να προσαρμοστούν τα γλωσσικά μοντέλα μέσω **fine-tuning** και **prompt-based learning** για βελτιωμένη απόδοση στην αναγνώριση συναισθημάτων σε κειμενικούς διαλόγους.
5. Να αξιολογηθούν και να συγκριθούν τα μοντέλα **GPT-4o-2024-08-06**, **Claude-3-5-Sonnet-20240620**, και **LLAMA3** μέσα από μια σειρά πειραμάτων.

1.3 Συνεισφορά της Διπλωματικής Εργασίας

Η παρούσα διπλωματική εργασία συμβάλλει στους εξής τομείς:

1. **Εμπλουτισμός διαθέσιμων δεδομένων:** Η δημιουργία ενός προσαρμοσμένου συνόλου δεδομένων που επεκτείνει το DailyDialog dataset¹ με εθελοντικές συνεισφορές από χρήστες (στην μορφή αναθέσεων συναισθημάτων σε κειμενικούς διαλόγους),

¹https://huggingface.co/datasets/li2017dailydialog/daily_dialog

επιτρέποντας μια πιο ρεαλιστική αξιολόγηση των μοντέλων σε πραγματικά δεδομένα που αναγνωρίζουν την πολυμορφία των ανθρώπινων συναισθημάτων.

2. **Σύγκριση LLMs:** Η συστηματική σύγκριση τριών σύγχρονων μεγάλων γλωσσικών μοντέλων (ένα ανοιχτού κώδικα και δύο μη), επισημαίνοντας τα πλεονεκτήματα και τις αδυναμίες τους στην αναγνώριση συναισθημάτων σε κειμενικούς διαλόγους.
3. **Προσαρμογή LLMs:** Η ανάπτυξη και δοκιμή τεχνικών fine-tuning και prompt-tuning για τη βελτίωση της απόδοσης των LLMs στην αναγνώριση συναισθημάτων, με έμφαση στη βελτιστοποίηση της ανίχνευσης συναισθημάτων μέσα από συνεχείς προσαρμογές.
4. **Ενσωμάτωση συγκειμένου:** Η επινόηση ενός τρόπου ενσωμάτωσης της συγκειμενικής πληροφορίας (context) κατά την αλληλεπίδραση με τα γλωσσικά μοντέλα προς αποφυγή απομόνωσης των εκφωνήσεων.
5. **Συμπεράσματα και προοπτικές:** Η εξαγωγή χρήσιμων συμπερασμάτων για το πώς οι προσαρμογές μέσω prompt-tuning και fine-tuning μπορούν να βελτιώσουν τις επιδόσεις των μοντέλων στην ανίχνευση συναισθημάτων, με σημαντικά ποσοτικά αποτελέσματα που παρέχουν κατευθυντήριους άξονες για την μελλοντική έρευνα.

1.4 Διάρθρωση της Διπλωματικής Εργασίας

Η εργασία αυτή είναι οργανωμένη σε έξι κεφάλαια: Αφού προηγηθεί η εισαγωγή στο θέμα με το παρόν Κεφάλαιο 1, στο Κεφάλαιο 2 γίνεται ανασκόπηση της θεωρίας των συναισθημάτων και αναλύεται η σύνδεση με την πληροφορική, προσφέροντας τα θεμέλια για την απαραίτητη μοντελοποίηση που πρέπει να λάβει χώρα ώστε να γίνει εφικτή η προσπέλαση των συναισθημάτων σε κειμενικό επίπεδο από τους υπολογιστές, εφιστώντας στην πορεία την προσοχή στις νεότερες εξελίξεις στον τομέα της έρευνας συναισθημάτων. Στο Κεφάλαιο 3 παρουσιάζεται η εξέλιξη των μεθόδων διανυσματικής αναπαράστασης-ενσωμάτωσης λέξεων (word embeddings), καθώς και η τεχνολογική υποδομή των LLMs που επιτρέπει την κατανόηση σύνθετης σημασιολογικής πληροφορίας και συνεπώς την ανίχνευση συναισθημάτων. Στο Κεφάλαιο 4 εξηγείται η διαδικασία προσαρμογής των γλωσσικών μοντέλων μέσω των τεχνικών του fine tuning και prompt-based learning ενώ στο Κεφάλαιο 5 παρουσιάζονται τα αποτελέσματα της συγκριτικής αξιολόγησης αυτών των μεθόδων, βασισμένα σε πειράματα που έγιναν στα μοντέλα πειράματα που διεξήχθησαν με τα μοντέλα GPT-4o, Claude Sonnet 3.5 και LLAMA3. Τέλος, στο Κεφάλαιο 6 γίνονται συμπερασματικές αναλύσεις των αποτελεσμάτων, θέτηση μελλοντικών στόχων και φρόνηση περί της έρευνας.

Θεωρητικό Υπόβαθρο

Στο πλαίσιο της μελέτης ενός διεπιστημονικού προβλήματος που βρίσκεται στην διασταύρωση διαφόρων ερευνητικών πεδίων, αξιοποιώντας εργαλεία που παρέχει η Πληροφορική για την προσπέλαση εννοιών και ζητημάτων που αφορούν, πρωτίστως, τις επιστήμες της Ψυχολογίας, Βιολογίας και Κοινωνιολογίας -μεταξύ άλλων- κρίνεται πως η θεμελίωση κάποιων θεωρητικών πλαισίων είναι ιδιαίτερα χρησιμή. Ξεκινώντας λοιπόν με την παρουσίαση κάποιων βασικών στοιχείων της Θεωρίας των Συναισθημάτων, σε αυτό το κεφάλαιο θα χαρτογραφηθεί η πορεία της σχετικής έρευνας και θα τοποθετηθεί στο ευρύτερο επιστημονικό της πλαίσιο.

2.1 Θεωρία Συναισθημάτων και διασταύωση με Πληροφορική

Η αναγνώριση συναισθημάτων, ενώ εγγενώς ριζωμένη σε τομείς εκτός της Πληροφορικής, έχει προσελκύσει, λόγω της βαθιάς και αδιαπραγμάτευτης εισχώρησης της τεχνολογίας στην ανθρώπινη αλληλεπίδραση [38], το ερευνητικό ενδιαφέρον του κλάδου μας. Αυτό αποδυνκνείται στο έπακρο και από την σταθερή ανάπτυξη του ερευνητικού χώρου του Affective Computing[77] τα τελευταία χρόνια, καθώς και από τις ποικίλες εφαρμογές όπως η υγεία[45][93], η ανάπτυξη ευφυών, επικοινωνιακών πρακτόρων[97], η εξόρυξη γνώμης από μεγάλα πλήθη δεδομένων με όλες τις οικονομικές προεκτάσεις της, η έρευνα στις κοινωνικές επιστήμες, η συναισθηματικά-ενήμερη μετατροπή text-to-speech[4], η ανάπτυξη Ambient Intelligence²[32]

²Ambient intelligence is the concept of capturing and processing data through sensors, processors, and actuators unobtrusively embedded throughout the environment. Leveraging artificial intelligence (AI), ambient systems provide connected, seamless, uninterrupted everyday experiences that require no human intervention - <https://www.arm.com/glossary/ambient-intelligence>

και πολλά άλλα. Για να αξιολογήσουμε όμως με διεπιστημονική ακεραιότητα αυτό το ζήτημα, χρειάζεται να μελετήσουμε τα βασικά μοντέλα που θα το γεφυρώσουν με την επιστήμη μας.


2.1.1 Μελέτη των Συναισθημάτων

2.1.2 Μοντέλα και Ταξινομίες

Για πολλά χρόνια τα συναισθήματα απασχολούσαν τον άνθρωπο μονάχα σε επίπεδο φιλοσοφικής φρόνησης[96], με τις σύγχρονες συζητήσεις στον χώρο να είναι βαθιά υπόχρεες σε αυτήν τη αφετηρία. Ο Αριστοτέλης στα *Ἠθικά Νικομάχεια* αναφέρεται στα συναισθήματα ως *ῥάθυ* και στοχάζεται περί της άλλοτε ακούσιας φύσης τους και τον ρόλο τους στην επίτευξη της αρετής [6]. Προχωρώντας στον χρόνο και προσπερνώντας μία συστάδα από αξιόλογες συνεισφορές, εντοπίζουμε στο έργο του Ρενέ Ντεκάρτ μελέτες των συναισθημάτων και της σύνδεσής τους με τις οργανικές διεργασίες του ανθρώπινου σώματος [106]. Εκεί που όμως η πορεία αυτής της, έως τότε, ασυνεχούς έρευνας αρχίζει να λαμβάνει επιστημονικές διαστάσεις, είναι όταν, εν έτει 1872, εκδίδεται η *Ἐκφραση των Συγκινήσεων στον Ἄνθρωπο και στα Ζώα* του Κάρολου Δαρβίνου. Σε αυτό το έργο καταγράφονται οι οξυδερκείς παρατηρήσεις του συγγραφέα για τον τρόπο που τα οικόσιτα και τα άγρια ζώα, οι άνθρωποι και τα παιδιά τους εκφράζουν τη χαρά, τη λύπη, τον φόβο, τον θυμό τους[23]. Δίνοντας έκταση και βάθος σε αυτή τη βιολογική σκοπιά των συναισθημάτων, θα γίνουν και αξιολογήσεις από τον νευροεπιστημονικό φακό, συνεισφορά επιστημόνων όπως ο Jaak Panksepp [74] ο οποίος, συμβαδίζοντας με τα ερευνητικά εργαλεία που κάνει διαθέσιμα η εξέλιξη της τεχνολογίας, θα φέρει πιο αυστηρή επιστημονική μεθοδολογία σε έναν κλάδο που την αντιστεκόταν για πολύ καιρό. Φτάνοντας λοιπόν στην σημερινή εποχή, η προσπάθεια κατανόησης και ορισμού των συναισθημάτων συνεχίζει να εκλεπτύνεται και να κεντρίζει το επιστημονικό ενδιαφέρον.

Μέχρι αυτό το σημείο όμως δεν έχει συμφωνηθεί από την επιστημονική κοινότητα η ενοποιημένη ταξινόμια των συναισθημάτων, με τις διάφορες αφητηρίες προσέγγισης να αποφέρουν διαφορετικά μοντέλα κατηγοριοποίησης. Αρχικά, έχουμε τον διαχωρισμό σε δυο βασικά μοντέλα: τα **διακριτά** και τα **διαστατικά**. Σε αυτά που ανήκουν στην πρώτη κατηγορία, τα συναισθήματα κατατάσσονται σε διακριτές κατηγορίες, με κάθε συναίσθημα να θεωρείται ως ξεχωριστή οντότητα από το άλλο. Η ταξινόμια που, ως επί το πλείστον, αποτελεί το πρότυπο για την κατηγοριοποίηση των βασικών συναισθημάτων ανήκει σε αυτό το μοντέλο και αποδίδεται στον ψυχολόγο και ερευνητή Paul Ekman. Αυτή η κατηγοριοποίηση αναγνωρίζει 6 βασικά συναισθήματα **θυμό, φόβο, λύπη, χαρά, αηδία και έκπληξη** και ήταν αποτέλεσμα των διαπιστώσεων του κατά την διεξαγωγή ανθρωπολογικών ερευνών για την χαρτογράφηση των *οικουμενικών* συναισθημάτων που εκφράζονται από τους ανθρώπους ανεξαρτήτως πολιτιστικής προέλευσης[30]. Επέκταση σε αυτή την ταξινόμια προσφέρει το βασικό μοντέλο του Plutchik το οποίο προσθέτει την *άνυπομνησία* και την *έμπιστοσύνη* ως ξεχωριστές συναισθηματικές καταστάσεις[83]. Το διαστατικό μοντέλο απεναντίας βλέπει τα συναισθήματα ως συνδεδεμένες και όχι απομονωμένες οντότητες. Προτάθηκε από τον Wilhelm Wundt[91] αλλά επεκτάθηκε από τους Russell, Mehrabian[92] σύμφωνα με τους οποίους τα συναισθήματα μετρούνται σύμφωνα με τις παρακάτω παραμέτρους:

- Valence=Ποσό ευχαρίστησης που προκαλεί η αίσθηση από -1 έως 1
- Dominance=Ποσό έλεγχου απέναντι στο συναίσθημα από -1 έως 1
- Arousal=Ποσό διέγερσης που προκαλεί το συναίσθημα από -1 έως 1



Σχήμα 2.1: Τρισδιάστατη αναπαράσταση του μοντέλου Valence-Arousal για τα 6 βασικά συναισθήματα [12]

Στην βιβλιογραφία που σχετίζεται με την Πληροφορική επικρατεί το διακριτό μοντέλο καθώς η φύση του το καθιστά ιδανικό για υπολογιστική μοντελοποίηση ως ένα πρόβλημα ταξινόμησης μηχανικής μάθησης.

Μία μεγάλη αναταραχή ωστόσο στην σχετική έρευνα έφερε ο Alan S. Cowen³, ένας αναγνωρισμένος ερευνητής στην τομή Ψυχολογίας και Πληροφορικής (Computational Psychology), το έργο του οποίου ανανέωσε τις παραδοχές που είχαν θεσμοθετηθεί όσο αναφορά την ταξινόμηση των συναισθημάτων. Η βασική κριτική που προκύπτει από την εργασία του είναι ότι η απλοποίηση (ή αφαίρεση) των συναισθημάτων σε έξι βασικές κατηγορίες, όπως πρότεινε ο Ekman, δεν επαρκεί για να αποδώσει την πολυπλοκότητα και το εύρος των ανθρώπινων συναισθημάτων. Η θεωρία του τελευταίου είχε βασιστεί κυρίως στη μελέτη των εκφράσεων του προσώπου και υποστήριζε ότι οι βασικές κατηγορίες συναισθημάτων είναι "οικουμενικές" και βιολογικά καθορισμένες. Ωστόσο, η προσέγγιση αυτή δεν λάμβανε υπόψη τη δυναμική φύση των συναισθημάτων, την επιρροή του πολιτισμού, και τις πιο λεπτές αποχρώσεις του συναισθήματος[21]. Στη συνέχεια, ο Cowen επεκτείνει την ιδέα ότι τα συναισθήματα δεν είναι τόσο διακριτά και απλά όσο θεωρούσε ο Ekman μέσα από εκτεταμένη, μαζική στατιστική ανάλυση (χρησιμοποιώντας 324,066 crowd-sourced δείγματα συναισθηματικών αυτο-αναφορών σε επιλεγμένα βίντεο) η οποία βοήθησε να διαπιστωθεί ότι υπάρχουν τουλάχιστον 27 διακριτές κατηγορίες συναισθημάτων που ανήκουν σε έναν ενιαίο σημασιολογικό χώρο[19], η κάθε μία

³Συνεισφορές και πληροφορίες για τον ερευνητή: <https://scholar.google.com/citations?user=-i9gbsAAAAAJ&hl=el&oi=ao>. Επίσης συνεργάζεται στενά με τον Καθηγητή Ψυχολογίας Dacher Keltner

εκ των οποίων αναγνωρίζεται από σύγχρονες επιστημονικές μεθόδους ως διακριτή συναισθηματική κατάσταση. Για παράδειγμα, συναισθήματα όπως η νοσταλγία[110], η σύγχυση, και η τρυφερότητα είναι δύσκολο να καταταχθούν αποκλειστικά στις περιοριστικές αυτές κατηγορίες. Επίσης, κατά το έργο αυτό γίνεται και λόγος για το πως διαφορετικά modalities⁴ ενδεχομένως να εγείρουν διαφορετικές ταξινομίες[16][17].

Με αυτή την τεχνολογική ενημέρωση του υπο-ανάλυση χώρου, αναθεωρείται η ποιότητα των ευρημάτων προηγούμενων εργασιών, οι οποίες, μεν συνιστούν ένα μέτρο απόδοσης στην κατανόηση σημασιολογικών συσχετίσεων των μοντέλων μηχανικής μάθησης, αλλά δεν καλύπτουν τις αυξημένες απαιτήσεις που έχουν οι σύγχρονες εφαρμογές της τεχνητής νοημοσύνης από τα συστήματα ανίχνευσης συναισθημάτων.

2.2 Ορισμός ως Πληροφοριακό Πρόβλημα

Η ανίχνευση και αναγνώριση συναισθημάτων σε κείμενο αποτελεί ένα πολυδιάστατο πληροφοριακό πρόβλημα που απαιτεί την κατανόηση τόσο της γλωσσικής όσο και της παραγλωσσικής πληροφορίας. Στην Πληροφορική, κατατάσσεται στον τομέα της Επεξεργασίας Φυσικής Γλώσσας (Natural Language Processing - NLP) και αποσκοπεί στην εξαγωγή πληροφορίας που είναι ικανή να προσδιορίσει την συναισθηματική κατάσταση του εκάστοτε ομιλητή. Αυτά τα χαρακτηριστικά μπορεί να περιλαμβάνουν τόσο γραμματικά στοιχεία, όπως τη χρήση συναισθηματικά φορτισμένων λέξεων, όσο και πιο σύνθετες εννοιολογικές πληροφορίες, όπως η ειρωνεία και ο σαρκαστικός τόνος.


Στο πλαίσιο της παρούσας εργασίας ορίζουμε:

Ορισμός 2.1. Δεδομένης μιας ακολουθίας εκφωνήσεων $u_1, u_2, \dots, u_N$, και τους συνομιλητές p_M πλήθους $M = 2$ (p_1, p_2) για κάθε εκφώνηση u_i , $i = 1, 2, \dots, N$, η **αναγνώριση συναισθημάτων σε συνομιλία** είναι η διαδικασία πρόβλεψης της κατηγορίας συναισθήματος κάθε εκφώνησης από ένα σύνολο προκαθορισμένης συναισθηματικής ταξινόμιας (όπως χαρούμενος, ενθουσιασμένος, θυμωμένος, απογοητευμένος κτλ.), δοθέντος της συγκεκριμένης πληροφορίας (context)[62].

2.2.1 Σημαντικές παράμετροι στην αναγνώριση συναισθήματος

- **Συγκεκριμένο: (Context)** Εφόσον πρόκειται για ένα έργο που απαιτεί λεπτή κατανόηση της συγκεκριμένης πληροφορίας, είναι προφανές πως τα μοντέλα θα επωφεληθούν από τον ορισμό του συγκεκριμένου σαν μεταβλητή εισόδου, αφού η ακολουθιακή φύση των διαλόγων απαγορεύει την απομόνωση των εκφωνήσεων [84].
- **Αλληλοεξαρτήσεις ομιλητών:** Όπως αναφέρεται από τους Taewoon Kim et al. [50], η επίγνωση των ομιλητών και των σημασιολογικών αλληλοεξαρτήσεων των λεγόμενων τους είναι σημαντική παράμετρος για την επίδοση προ-εκπαιδευμένων γλωσσικών

⁴τροπικότητα, είδος δεδομένου. Π.χ ήχος, βίντεο, κείμενο κ.ο.κ.



Σχήμα 2.2: Παράδειγμα αναγνώρισης συναισθήματος σε διάλογο για $M = 3$ [56]

μοντέλων στην αναγνώριση συναισθήματος όπως δείχνει η σύγκριση του με περίπτωση που υπάρχει άγνοια αυτών των πληροφοριών.

Λαμβάνοντας υπόψιν όλα τα παραπάνω, γίνεται κατανοητό πως η αναγνώριση συναισθήματος από κείμενα δεν πρόκειται για ένα απλό NLP categorization task αλλά περιλαμβάνει σύνθετες διεργασίες όπως subjectivity detection, sarcasm detection, aspect extraction, entity extraction, το οποίο μας προϋδεάζει για την ανάγκη υιοθέτησης σημασιολογικών και όχι συντακτικών μοντέλων.

2.2.2 Σύνολα Δεδομένων

Ο παρακάτω πίνακας συνοψίζει τα πιο δημοφιλή σύνολα δεδομένων που χρησιμοποιούνται για την αναγνώριση συναισθήματος και τα βασικά χαρακτηριστικά τους (Με **P** σημειώνεται η κατηγοριοποίηση Plutchik ενώ με **E** η Έκμαν):

Dataset	Annotation	Lang.	Source	Size
IdeDialog (Ide and Kawahara, 2022)	P	JA	Twitter dialogues	13,806
M3ED (Zhao et al., 2022)	E + neutral	CN	TV dialogues	24,449
MuSE (Jaiswal et al., 2020)	sad, anger, contentment, amusement, neutral	EN	Recordings 28 speakers	28 speakers
MELD (Zahiri and Choi, 2017; Poria et al., 2019)	E + neutral	EN	Movie dialogues	13,000
DailyDialog (Li et al., 2017)	E + other	EN	Movie dialogues	13,118
EmoryNLP (Zahiri and Choi, 2017)	E + neutral	EN	TV show dialogues	12,606
IEMOCAP (Busso et al., 2008)	happiness, anger, sadness, frustration, neutral	EN	Dyadic interactions	10,039
StudEmo (Ngo et al., 2022)	28 emotion categories	EN	Customer reviews	5,182
RED v2 (Ciobotaru et al., 2022)	P - disgust, anticipation	RO	Tweets	5,449
APPReddit (Stranisci et al., 2022)	appraisals (Roseman, 1991)	EN	Reddit	1,091
Universal Joy (Lamprinidis et al., 2021)	anger, anticipation, fear, joy, sadness	18	Facebook posts	530k
WRIME (Kajiwara et al., 2021)	P, emotion intensity	JA	SNS posts	17,000
EmoEvent (Plaza-del-Arco et al., 2020)	E + neutral	EN-ES	Tweets	8,409
GoodNewsEveryone (Bostan et al., 2020)	15 emotion categories	EN	News Headlines	5,000
PO-EMO (Haider et al., 2020)	joy, sadness, uneasiness, vitality, suspense, sublime, humor, annoyance, nostalgia	EN-DE	Poems	64 (EN), 18 (DE)
enISEAR (Hofmann et al., 2020)	appraisals (Smith and Ellsworth, 1985)	EN	Self-reports	1,001

Πίνακας 2.1: Σύνοψη διαφόρων συνόλων δεδομένων για Αναγνώριση Συναισθήματος[25] με πληροφορίες για την ταξινόμια που υιοθετεί, την γλώσσα, πηγή και μέγεθος τους

Είναι αξιόλογο πως σε έρευνες που αποβλέπουν στην περίληψη της προόδου της κειμενικής αναγνώρισης συναισθήματος [53][25] σημειώνουν πως η βιβλιογραφία υποφέρει από ασταθή σύνολα δεδομένων. Όπως αναφέρουν οι Kusal et al.[53] τα πρόβλημα στα υπάρχοντα, μαζικά διαθέσιμα datasets είναι ο περιορισμός στα **σχολιασμένα** δεδομένα που στην πλειοψηφία τους ακολουθούν τις πιο συνοπτικές κατηγορηματικές ταξινομίες.

2.3 Σχετική Βιβλιογραφία

Ξεκινώντας θα επιστήσουμε την προσοχή στην παρατήρηση των Flor Miriam Plaza-del-Arco et al., ότι στο σύνολο της σχετικής έρευνας υπάρχει μία ασυνέχεια στην σημειογραφία[25]. Συγκεκριμένα, κατά την επισκόπηση που διεξάγανε στην βιβλιογραφία της ανάλυσης συναισθημάτων στο NLP, διαπιστώσανε ανομοιομορφία στην ονοματολογία στους πολύ βασικούς όρους της έρευνας, με 42.48% να χρησιμοποιεί τον όρο emotion recognition, 28.10% emotion analysis, 13.07% emotion classification και τέλος το emotion detection με 12.41%. Η βλέψη της συγκεκριμένης έρευνας ξεπερνά την απλή ανίχνευση παρουσίας συναισθήματος ή όχι και στοχεύει στην πιο λεπτομερειακή ανάλυση της συναισθηματικής κατανόησης των μεγάλων γλωσσικών μοντέλων. Ακολουθώντας λοιπόν αυτόν τον συλλογισμό, κρίνεται πως ο όρος ‘‘αναγνώριση συναισθήματος’’ (emotion recognition) είναι πιο ταιριαστός για το παρόν πλαίσιο.


Έχοντας σημειώσει στην σημειογραφία που θα υιοθετήσει η παρούσα εργασία, ξεκινάμε την αναδρομή από τις πρώτες μεθόδους που βασίζονταν σε λεξικά συναισθημάτων, έως τις πιο πρόσφατες εξελίξεις με τη χρήση μεγάλων γλωσσικών μοντέλων (LLMs). Στα αρχικά στάδια, οι λεξικογραφικές μέθοδοι (lexicon-based methods), όπως τα WordNet-Affect [99], βασίζονταν σε αναγνώριση συναισθημάτων μέσω αντιστοίχισης με λεξικά συναισθηματικά φορτισμένων λέξεων, προσφέροντας μια βασική κατανόηση των συναισθημάτων μέσω της συχνότητας εμφάνισης αυτών των λέξεων στο κείμενο. Παρά την απλότητά τους, αυτές οι μέθοδοι δεν ήταν ικανές να κατανοήσουν τη συναισθηματική πληροφωρία των περισσότερων συζητήσεων[64].

Στη συνέχεια, κατανομητές μηχανικής μάθησης εφαρμόστηκαν εκτενώς στο πρόβλημα. Δημοφιλοί παραδείγματα είναι τα Support Vector Machine (SVM), Naive Bayes και Decision Trees[90]. Οι Canales et al.[13] απέδειξαν ότι τεχνικές επιβλεπόμενης μάθησης επιφέρουν κατά μέσο όρο καλύτερα αποτελέσματα επιτυχίας αναγνώρισης συναισθήματος από τεχνικές μη επιβλεπόμενης μάθησης. Αυτές οι μέθοδοι επέτρεψαν την εκπαίδευση μοντέλων σε μεγαλύτερα σύνολα δεδομένων, αλλά η περιορισμένη κατανόηση των συσχετίσεων μεταξύ λέξεων παρέμεινε σημαντικό εμπόδιο.

Με την ανάπτυξη της βαθιάς μάθησης (deep learning), δίκτυα όπως τα RNNs και τα CNNs άρχισαν να προσφέρουν σημαντικές βελτιώσεις, καθώς μπορούσαν να μοντελοποιήσουν καλύτερα τη δομή της γλώσσας και τις διασυνδέσεις μεταξύ λέξεων. Αυτές οι μέθοδοι επέτρεψαν την αναγνώριση πιο σύνθετων συναισθημάτων [98], βελτιώνοντας τη συνολική ακρίβεια σε πολλές εφαρμογές. Έχουν χρησιμοποιηθεί, μεταξύ άλλων, RNNs[68], LSTMs[7][69] και GCNs[34] καθώς υβριδικά μοντέλα που συνιστούν τον συνδυασμό διαφόρων ταξινομητών[8][10][90][35]. Η μεγάλη πρόοδος ωστόσο έφτασε με την άνοδο των αρχιτεκτονικών Transformers και την

χρήση μεγάλων γλωσσικών μοντέλων, κάτι που γίνεται εμφανές και από την αύξηση της δημοσίευσης σχετικών ερευνών την χρονιά που οι Vaswani et al. εκδίδουν την επαναστατική έρευνα τους[105].

Η επανάσταση ήρθε με τα μοντέλα που βασίζονται στους transformers, όπως το BERT [27].



Σχήμα 2.3: Διάγραμμα δικτύου keyword co-occurrence[53]

Εφαρμόζοντας αυτή τη τεχνολογία, οι Huang et al[41] διερεύνησαν την απόδοση του BERT στην αναγνώριση συναισθημάτων. Χρησιμοποίησαν το σύνολο δεδομένων EmotionLines που αποτελείται από διαλόγους από τη σειρά "Friends" και το EmotionPush που αποτελείται από συνομιλίες του Facebook Messenger. Τα συναισθήματα ταξινομήθηκαν στη συνέχεια σε χαρά, λύπη, θυμό και ουδέτερο. Ο προ-εκπαιδευμένος κωδικοποιητής μετασχηματιστή BERT χρησιμοποιήθηκε για την εκτέλεση της εργασίας προ-εκπαίδευσης. Μετά το tokenization, το 15% των token της ακολουθίας εισόδου καλύφθηκε τυχαία και το μοντέλο έπρεπε να μάθει να προβλέπει τα καλυμμένα τοκεν από τις ακολουθίες που μαθαίνει από τα μη καλυμμένα. Το μοντέλο πέτυχε micro score F1 0,815 και 0,885 από τα σύνολα δεδομένων Friends.EmotionPush, αντίστοιχα. Οι συγγραφείς δήλωσαν ότι υψηλότερη απόδοση θα μπορούσε να επιτευχθεί σε μεγαλύτερο όγκο δεδομένων.

Φτάνοντας στην επικαιρότητα, τα Large Language Models (LLMs), όπως τα GPT, Claude, και LLAMA, προσφέρουν ακόμη μεγαλύτερη δυνατότητα αναγνώρισης συναισθημάτων, λόγω της ικανότητάς τους να επεξεργάζονται τεράστιους όγκους δεδομένων και να γενικεύουν σε διάφορα συναισθηματικά συμφραζόμενα [11]. Η προσαρμογή αυτών των μοντέλων μέσω τεχνικών fine-tuning και prompt-tuning προσφέρει νέες δυνατότητες στην ακριβή αναγνώριση και ταξινόμηση των συναισθημάτων σε συνομιλίες.

Πηγή	Γλώσσα	Σύνολο Δεδομένων	Μοντέλο	Αποτέλεσμα	Μετρική
[107]	Ινδικά, Αγγλικά	Twitter	BERT, RoBERTa, AL-BERT	71.43%	Accuracy
[5]	Αγγλικά	GoEmotions	BERT	11.8% baseline improvement	Accuracy
[112]	Αγγλικά	conversation bench-mark	BERT	Improve 5-10%	Accuracy
[78]	Αγγλικά	SemEval-2019 Task 3 and SMP2020-EWECT	BERT, BLS	IBERT,CFEBL 88.87%, 73.32%	Accuracy, F-score
[76]	Αγγλικά	SemEval-2016, EmoBank, GoEmotions, ISEAR	RoBERTa	Not Mentioned	F-score
[2]	Αγγλικά	ISEAR	BERT, RoBERTa, Distil-BERT, and XLNet	RoBERTa 74.31%	Accuracy

Πίνακας 2.2: Παραδείγματα χρήσης παραλλαγών του BERT κατά την βιβλιογραφία

Ref.	Model	Architecture	Description	Tuning	Advantages	Challenges	Trained on Datasets
Devlin et al. 2019	BERT	Transformer, Bidirectional	Bidirectional LSTM, Uses and the Next Sentence Prediction (NSP), Masked Language Modelling (MLM) mechanisms.	Pre-Training Fine Tuning	1) ability to handle contextual information 2) Faster Training	1) limited to monolingual classification, 2) Fixed length of input sentences 3) Suffers from logical inference 4) computationally expensive.	BooksCorpus datasets and the English Wikipedia.
Howard et al. 2018	ULMFIT	Fully Connected Neural Network, Unidirectional	Uses AWD-LSTMs	Pre-Training Fine Tuning	1) Transfer Learning in Language Domain 2) very well on small and medium corpora 3) Prevent over-catastrophic forgetting when fine-tuning	1) Model not trained on GLUE benchmark. 2) Unidirectional	Wikitext-103, IMDb, TREC-6, Yelp-full, Yelp-bi, DBpedia AG's news,
Radford et al. 2018	GPT	Transformer, Unidirectional	to model language, a semi-supervised learning approach employed utilizing a multi-head attention layer transformer decoders.	Pre-Training Fine Tuning	1) improved lexical robustness. 2) Outperforms various models trained on domain-specific datasets 3) no-fine tuning required for GPT-2 and GPT-3.	1) The model's resource-intensive nature makes the pre-training step costly. 2) inability to deal with dependencies that are larger than the given fixed lengths.	BooksCorpus, WebText
Yang et al. 2019	XLNet	Auto-Regressive Transformer, Bidirectional.	Use two-stream self-attention and Permutation Language Model principles are used (PLM)	Pre-Training Fine Tuning	1) The ability to extract bi-directional contextual Information 2) It removes BERT's fixed-length limitation.	1) XLNet computationally intensive.	English Wikipedia, Common crawl, Giga 5, Books Corpus, Clueweb 2012-13
Liu et al. 2019	RoBERTa	Transformer, Bidirectional	Replication of BERT with larger corpus and tuned hyper-parameters. Uses Dynamic Masking.	Pre-Training Fine Tuning	1) The use of more extensive pre-training data results in improved performance. 2) In downstream NLP tasks, outperforms XLNet and BERT.	1) resource-intensive nature 2) It is computationally intensive and takes longer to complete.	English Wikipedia, Books Corpus, CC-News, Stories, OpenWebText.
Tang et al. 2019	Distil BERT	Transformer, Bidirectional	Uses Early Form of BERT by reducing the of layers by a factor of 2, Uses dynamic masking.	Pre-Training Fine Tuning	1) Language modeling capability with the pre-training 2) The new model is faster and lighter compared with BERT.	1) Fixed length limitation	Book Corpus and English Wikipedia

Σχήμα 2.4: Συγκριτική ανάλυση προ-εκπαιδευμένων μοντέλων [52]

LLMs

Οι Liu et al.[59], σημειώνοντας πως η ανίχνευση και αναγνώριση συναισθήματος και αισθήματος (sentiment) αποτελούν μονάχα μία διάσταση ενός ευρύτερου συνόλου συναισθηματικών αξιολογήσεων που αγνοεί εργασίες παλινδρομικής φύσης (regression tasks - όπως η

εύρεση της έντασης ενός συναισθήματος) διεκπεραίωσαν μία σειρά πειραμάτων που αποσκοπούσε σε μία ολοκληρωτική συναισθηματική ανάλυση. Σε αυτή την μελέτη υιοθετούνται κατηγορηματικά και διασταστικά σύνολα δεδομένων που στηρίζονται στο SemEval-2018 Task 1: Affect in Tweets, το οποίο συνίσταται μία ποικιλία δεδομένων (π.χ. κατηγοριοποίηση δραστηκότητας valence, κατηγοριοποίηση συναισθήματος, παλινδρόμηση έντασης), πάνω στα οποία θα εκπαιδεύουν εκπαιδεύουν τρία μοντέλα διαφορετικών παραμέτρων βασισμένα στο μεγάλο γλωσσικό μοντέλο LLaMA 2[104]. Τα μοντέλα, λοιπόν, θα αξιολογηθούν όχι μόνο στην αναγνώριση του συναισθήματος αλλά και στην πρόβλεψη της έντασης και δραστηκότητας του, προσφέροντας μία πιο ολοκληρωμένη εποπτεία των ικανοτήτων τους. Αποτέλεσμα της έρευνας ήταν η συνεισφορά του EmoLLaMA το οποίο όταν συγκρίθηκε με άλλα ανταγωνιστικά γλωσσικά μοντέλα ξεπερνούσε την επίδοσή τους στις περισσότερες μετρικές αξιολόγησης.

Πορίσματα

Συνοψίζοντας την παραπάνω ανάλυση καταλήγουμε στους τρεις διαμορφωτικούς άξονες αυτής της έρευνας:

1. Η ταξινόμηση του Έκμαν που επικρατεί στην βιβλιογραφία εισάγει αυστηρούς περιορισμούς στην αποτύπωση του πλούτου των ανθρώπινων συναισθημάτων που πρέπει να ξεπεραστεί με μία νέα κατηγοριοποίηση συναισθημάτων που είναι προσαρμοσμένη σε δεδομένα κειμενικής φύσεως text modality.
2. Η πιο υποσχόμενη τεχνολογία στον τομέα του της αναγνώρισης συναισθήματος σε κείμενα είναι τα μεγάλα γλωσσικά μοντέλα: χρειάζεται συνεπώς να αξιολογηθούν τα πιο δημοφιλή εξ'αυτών.
3. Τα κειμενικά δεδομένα σε διαλόγους είναι πιο αντιπροσωπευτικά των περισσότερων εφαρμογών αυτής της τεχνολογίας, οπότε το σύνολο δεδομένων πρέπει να είναι σε μορφή συζητήσεων.

Μέθοδοι Αναπαράστασης Λέξεων και Γλωσσικά Μοντέλα

3.1 Εισαγωγή

Η Επεξεργασία φυσικής Γλώσσας -Natural language Processing (NLP) είναι τομέας της Επιστήμης των Υπολογιστών που ανήκει σε ένα διεπιστημονικό σύμπλεγμα πεδίων που περιλαμβάνει την επεξεργασία και σύνθεση ομιλίας και γλώσσας, την υπολογιστική γλωσσολογία, την γλωσσική τεχνολογία και την μηχανική μάθηση. Σκοπός του τομέα είναι η ανάπτυξη των απαραίτητων μοντέλων και τεχνολογιών ώστε οι υπολογιστές να μπορούν να επεξεργαστούν, αναλύσουν και παράγουν ανθρώπινο λόγο, επιτρέποντας την επικοινωνία Ανθρώπου-Υπολογιστή μαζί με πολλές ακόμη χρήσιμες εργασίες[46].

Η ανάπτυξη του διαδικτύου και των μέσων μαζικής δικτύωσης δεν αποτελεί κάποιο νέο, αλλά είναι αξιόλογο πως το 5.35δισ ανθρώπων που αναγνωρίζονται ως χρήστες του διαδικτύου και το 5.04δισ που αναγνωρίζονται ως χρήστες των μέσων κοινωνικής δικτύωσης [48] παράγουν ένα ασσύληπτο ποσό δεδομένων καθημερινά, πολλές φορές, στην μορφή γράπτου λόγου. Αυτό αποτελεί ένα ισχυρό κίνητρο για την δημιουργία μεθόδων αυτόματης επεξεργασίας κειμένου και εξαγωγής πληροφορίας, ελκύοντας το ερευνητικό και εμπορικό ενδιαφέρον για ανάπτυξη νέων τεχνικών και ενθαρρύνοντας συνεπώς την εξέλιξη του ήδη δημοφιλή αυτού κλάδου [49].

Καταλυτικός παράγοντας στην πρόοδο των δυνατοτήτων του NLP ήταν η ανάπτυξη προηγμένων μεθόδων αναπαράστασης λέξεων, η εξέλιξη των οποίων οδήγησε σε κάποιες εξαιρετικά ενδιαφέρουσες εφευρέσεις που βρίσκονται στο επίκεντρο του ερευνητικού ενδιαφέροντος.

Σε αυτό το κεφάλαιο θα γίνει μία επισκόπηση των βασικών μεθόδων αναπαράστασης λέξεων κατά την πορεία αυτής της καίριας για το NLP τεχνολογίας, ενώ στην συνέχεια θα ανα-

λυθούν τα γλώσσικά μοντέλα και τα βασικά στοιχεία των αρχιτεκτονικών τους.

3.2 Αναπαράσταση λέξεων

3.2.1 Παραδοσιακές μέθοδοι

Κωδικοποίηση One-Hot

Το **One-Hot Encoding** είναι μία **κατηγορηματική** μέθοδος αναπαράστασης λέξεων ως διανύσματα. Κάθε λέξη στο λεξιλόγιο αναπαρίσταται ως ένα δυαδικό διάνυσμα μήκους ίσου με το εχυαλ μέγεθος του λεξιλογίου N . Το διάνυσμα έχει μόνο μηδενικές τιμές, εκτός από ένα μοναδικό στοιχείο με τιμή 1 που υποδυκνύει την παρουσία της λέξης. Μαθηματικά, αυτή η μέθοδος αναπαράστασης λέξεων περιγράφεται ως εξής:

- **Λεξιλόγιο V :** Το σύνολο όλων των μοναδικών λέξεων στο corpus, $V = \{w_1, w_2, \dots, w_N\}$.
- **Διανυσματική Αναπαράσταση:** Κάθε λέξη w_i αναπαρίσταται από ένα διάνυσμα $\mathbf{e}_i$ μήκους N :

$$\mathbf{e}_i = [0, 0, \dots, 1, \dots, 0]$$

όπου το 1 βρίσκεται στην i -ή θέση και αντιστοιχεί στον δείκτη της λέξης στο λεξιλόγιο.[36]

Παράδειγμα

Έστω λεξιλόγιο $V = \{\text{'cat'}, \text{'dog'}, \text{'hat'}\}$.

Της one-hot εςτορς αρε:

$$\mathbf{e}_{\text{cat}} = [1, 0, 0]^\top, \quad \mathbf{e}_{\text{dog}} = [0, 1, 0]^\top, \quad \mathbf{e}_{\text{hat}} = [0, 0, 1]^\top$$

Παρόλο που ο υπολογισμός των αναπαραστάσεων one-hot encoding είναι εξαιρετικά αποδοτικός, πρόκειται για μέθοδο με σημαντικά μειονεκτήματα. Κάποια από αυτά είναι η υψηλή διαστατικότητα στα μεγάλα λεξιλόγια που επιφέρει αύξηση της υπολογιστικής πολυπλοκότητας και η αδυναμία της να συλλάβει σημασιολογική πληροφορία των χειμένων καθώς δεν υπάρχει συσχέτιση μεταξύ των προς-αναπαράσταση λέξεων.[36]

Κωδικοποίηση Ετικέτας

Μία εξίσου απλή και περιορισμένη προσέγγιση είναι η **Κωδικοποίηση Ετικέτας** (Label Encoding), στην οποία σε κάθε λέξη ανατίθεται μια αναπαρασταση στην μορφή ενός μοναδικού, δεκαδικού αριθμού.

- **Λεξιλόγιο $V = \{w_1, w_2, \dots, w_N\}$.**
- **Συνάρτηση Κωδικοποίησης:** $f : V \rightarrow \mathbb{Z}$, όπου:

$$f(w_i) = i$$

Παράδειγμα

Χρησιμοποιώντας το ίδιο λεξιλόγιο:

$$f(\text{'cat'}) = 1, \quad f(\text{'dog'}) = 2, \quad f(\text{'hat'}) = 3$$

Οι περιορισμοί αυτής της μεθόδου είναι προφανής και αντίστοιχη με αυτούς του one-hot encoding, καθώς η αυθαίρετη ανάθεση δεκαδικών αριθμών σε κάθε λέξη δεν εφοδιάζει το μοντέλο με κάποια υποδομή εξαγωγής συσχετίσεων μεταξύ των λέξεων.

Bag of Words

Το **BoW** είναι ένα απλό μοντέλο εξαγωγής γνωρισμάτων που μοντελοποιεί κειμενικά δεδομένα προς επεξεργασία από αλγορίθμους ανάκτησης πληροφορίας και μηχανικής μάθησης. Συγκεκριμένα, στα μοντέλα BoW, ένα κείμενο (όπως είναι μία πρόταση ή ένα έγγραφο) αναπαρίσταται ως μία αδόμενη συλλογή όλων των λέξεων που παρουσιάζονται σε αυτό, αδιαφορώντας για την σειρά των λέξεων, την γραμματική και το συγκεκριμένο και εστιάζοντας μόνο στην συχνότητα εμφάνισης της κάθε λέξης. Σκοπός είναι η δημιουργία ενός λεξιλογίου όλων των μοναδικών όρων στο δοθέν corpus και ύστερα το κάθε έγγραφο να αναπαρασταθεί ως ένα διάνυσμα που θα υποδυκνύει την παρουσία ή απουσία -συχνότητα- του κάθε όρου από το λεξιλόγιο [94]. Συνεπώς, έχουμε:

- **Corpus D**: Μία συλλογή M εγγράφων.

$$D = \{d_1, d_2, d_3, \dots, d_M\}$$

- **Vocabulary V**: Ένα σύνολο όλων των μοναδικών λέξεων στο corpus, μεγέθους N .

$$V = \{w_1, w_2, w_3, \dots, w_N\}$$

- **Document d_j** : Συνίσταται από μία ακολουθία λέξεων (tokens).

$$d_j = [t_{j1}, t_{j2}, t_{j3}, \dots, t_{jL_j}]$$

όπου L_j ο αριθμός των λέξεων στο έγγραφο d_j , και t_{jk} η k -ή λέξη στο d_j .

Για κάθε έγγραφο d_j και κάθε λέξη w_i στο λεξιλόγιο V , υπολογίζεται η **συχνότητα όρου** tf_{ij} :

$$\text{tf}_{ij} = \text{freq}(w_i, d_j) = \sum_{k=1}^{L_j} \delta(w_i, t_{jk})$$

όπου:

$$\delta(w_i, t_{jk}) = \begin{cases} 1, & \text{αν } w_i = t_{jk} \\ 0, & \text{αν } w_i \neq t_{jk} \end{cases}$$

Διανυσματική Αναπαράσταση

Κάθε έγγραφο d_j αναπαρίσταται σαν διάνυσμα $\mathbf{x}_j$ στο $\mathbb{R}^N$:

$$\mathbf{x}_j = [\text{tf}_{1j}, \text{tf}_{2j}, \text{tf}_{3j}, \dots, \text{tf}_{Nj}]^\top$$

όπου $^\top$ υποδυκνύει την ανάστροφο (transpose), κάνοντας το $\mathbf{x}_j$ ένα διάνυσμα στήλης.

Μητρώο εγγράφων-όρων

Στοιβάζοντας τα διανύσματα $\mathbf{x}_j$, διαμορφώνουμε **Μητρώο εγγράφων-όρων** $\mathbf{X}$ μέγεθους $N \times M$:

$$\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3, \dots, \mathbf{x}_M]$$

Κάθε στήλη $\mathbf{X}$ αναπαριστά ένα έγγραφο, και κάθε σειρά αντιστοιχεί σε μία λέξη του λεξιλογίου.

Παράδειγμα

Έστω ότι έχουμε 3 έγγραφα:

- d_1 : ‘the cat sat’
- d_2 : ‘the cat sat in the hat’
- d_3 : ‘the dog barked’

Βήμα 1: Δημιουργία Λεξιλογίου

$$V = \{\text{‘the’}, \text{‘cat’}, \text{‘sat’}, \text{‘in’}, \text{‘hat’}, \text{‘dog’}, \text{‘barked’}\}$$

Βήμα 2: Υπολογισμός Συχνότητας εμφάνισης όρων

Λέξη	tf_{i1}	tf_{i2}	tf_{i3}
the	1	2	1
cat	1	1	0
sat	1	1	0
in	0	1	0
hat	0	1	0
dog	0	0	1
barked	0	0	1

Πίνακας 3.1: Συχνότητα όρων κάθε εγγράφου

Βήμα 3: Διαμόρφωση Διανυσμάτων

$$\mathbf{x}_1 = [1, 1, 1, 0, 0, 0, 0]^\top$$

$$\mathbf{x}_2 = [2, 1, 1, 1, 1, 0, 0]^\top$$

$$\mathbf{x}_3 = [1, 0, 0, 0, 0, 1, 1]^\top$$

Βήμα 4: Δημιουργία Μητρώου εμφάνισης όρων

$$\mathbf{X} = \begin{bmatrix} 1 & 2 & 1 \\ 1 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \end{bmatrix}$$

όπου κάθε στήλη αντιστοιχεί σε $\mathbf{x}_1$, $\mathbf{x}_2$, και $\mathbf{x}_3$ αντίστοιχα.

Δώθηκε ιδιαίτερη έμφαση σε αυτή την, σχετικά απλή, μέθοδο καθώς κρίνεται πως η κατανόηση της θα βοηθήσει για την δημιουργία διαίσθησης της αναπαράστασης λέξεων, εφόδιο απαραίτητο στην προσπέλαση πιο σύνθετων μεθόδων.

Το μοντέλο BoW εφόσον ποσοτικοποιεί μονάχα την συχνότητα εμφάνισης των λέξεων σε ένα έγγραφο, συχνά χαρακτηρίζεται ως μία απλή τεχνική μοντελοποίησης. Εντούτοις, παραμένει εύχρηστο σε πολλά NLP tasks και ιδιαίτερα σε προβλήματα κατηγοριοποίησης όπως είναι η ανίσχνευση συναισθήματος[102], εξού και η συχνή παρουσία του στην σχετική βιβλιογραφία και η εγγύτητα του με στατιστικούς ταξινομητές όπως το **Naïve Bayes**[46]. Παρά την απλότητα και αποδοτικότητα του όμως, το BoW υποφέρει από τις εξής αδυναμίες:

- Αποτυχία σύλληψης **συγκειμενικής πληροφορίας**
- Αποτυχία σύλληψης της **πολυσημίας** των λέξεων, στο πλαίσιο του BoW η πρόταση “Mary is quicker than John” είναι ταυτόσημη με την πρόταση “John is quicker than Mary” [63].
- Υψηλή **υπολογιστική πολυπλοκότητα** σε μεγάλα λεξικά

TF-IDF

Η μέθοδος **Term Frequency-Inverse Document Frequency (TF-IDF)** ενιχύει την αναπαράσταση του BoW αναθέτοντας βάρη στις λέξεις ανάλογα με την σημασία τους σε σχέση με το υπόλοιπο corpus. Συνεπώς, σε σχέση με το BoW που απλώς απαριθμεί την συχνότητα εμφάνισης των λέξεων, η μέθοδος TF-IDF προσαρμόζει αυτή τη καταμέτρηση αναλογίζοντας πόσο συχνή ή σπάνια είναι μία λέξη στο δοθέν σύνολο εγγράφων. Ως αποτέλεσμα, δίνεται περισσότερη σημασία σε λέξεις που είναι μοναδικές ή σε λέξεις που εμφανίζονται σχετικά λίγες φορές σε όλη την έκταση του corpus, μειώνοντας τον αντίκτυπο κοινότυπων λέξεων όπως άρθρα και σύνδεσμοι και παράλληλα αναδυνάμεικτες λέξεις που φέρουν πολύ πληροφορία.

Με λίγα λόγια, το TF-IDF είναι το μέτρο της σημασίας ενός όρου στο έγγραφο. Συνίσταται από τον συνδυασμό δύο στατιστικών ποσοτήτων, το Term Frequency (TF) που μετρά πόσο συχνά εμφανίζεται μία λέξη στο έγγραφο [61] και το Inverse Document Frequency (IDF) που μετρά πόσο συχνή είναι μία λέξη σε μία συλλογή εγγράφων D [44].

Επενδύοντας την μαθηματική θεμελίωση του BoW, έχουμε:

Η **Συχρότητα όρου** tf_{ij} μπορεί να υπολογιστεί όπως και στο BoW:

$$\text{tf}_{ij} = \text{freq}(w_i, d_j) = \sum_{k=1}^{L_j} \delta(w_i, t_{jk})$$

Εναλλακτικά, κανονικοποιώντας την tf ώστε να συμπεριληφθεί το μέγεθος του εγγράφου:

$$\text{tf}_{ij} = \frac{\text{freq}(w_i, d_j)}{L_j}$$

Η ποσότητα **Inverse Document Frequency** idf_i μετρά την σημασία της λέξης w_i στο corpus D ως εξής:

$$\text{idf}_i = \log \left(\frac{M}{n_i} \right)$$

όπου:

- M το συνολικό πλήθος των εγγράφων του corpus.
- n_i ο αριθμός των εγγράφων στα οποία εμφανίζεται η λέξη w_i :

$$n_i = |\{d_j \in D : w_i \in d_j\}|$$

Προς αποφυγή διαίρεσης με το 0, πρέπει $n_i \geq 1$.

Το **βάρος TF-IDF** tfidf_{ij} για λέξη w_i στο έγγραφο d_j είναι:

$$\text{tfidf}_{ij} = \text{tf}_{ij} \times \text{idf}_i$$

Κάθε έγγραφο d_j αναπαρίσταται σαν ένα TF-IDF ζυγισμένο διάνυσμα διάνυσμα $\mathbf{x}_j$ στο $\mathbb{R}^N$:

$$\mathbf{x}_j = [\text{tfidf}_{1j}, \text{tfidf}_{2j}, \text{tfidf}_{3j}, \dots, \text{tfidf}_{Nj}]^T$$

Παράδειγμα

Χρησιμοποιώντας το ίδιο corpus όπως προηγουμένως:

- d_1 : ‘the cat sat’
- d_2 : ‘the cat sat in the hat’
- d_3 : ‘the dog barked’

Βήμα 1: Δημιουργία Λεξιλογίου

$$V = \{\text{'the'}, \text{'cat'}, \text{'sat'}, \text{'in'}, \text{'hat'}, \text{'dog'}, \text{'barked'}\}$$

Βήμα 2: Υπολογισμός Συχνότητας εμφάνισης όρων (TF)

Υπολογίζεται η συχνότητα όρων για κάθε λέξη κάθε εγγράφου.

Λέξη	tf _{i1}	tf _{i2}	tf _{i3}
the	1	2	1
cat	1	1	0
sat	1	1	0
in	0	1	0
hat	0	1	0
dog	0	0	1
barked	0	0	1

Πίνακας 3.2: Συχνότητα όρων κάθε Εγγράφου

Λέξη	n_i
the	3
cat	2
sat	2
in	1
hat	1
dog	1
barked	1

Πίνακας 3.3: Πλήθος εγγράφων που περιέχουν κάθε λέξη

Βήμα 3: Υπολογισμός IDF

Αρχικά υπολογίζεται ο αριθμός των εγγράφων n_i , που περιέχουν την λέξη w_i .

Υπολογισμός IDF για κάθε λέξη:

$$\text{idf}_i = \log \left(\frac{M}{n_i} \right)$$

Βήμα 4: Υπολογισμός Βαρών TF-IDF

Υπολογίζεται ως:

$$\text{tfidf}_{ij} = \text{tf}_{ij} \times \text{idf}_i.$$

Βήμα 5: Διαμόρφωση Διανυσμάτων

$$\mathbf{x}_1 = [0, 0.176, 0.176, 0, 0, 0, 0]^\top$$

$$\mathbf{x}_2 = [0, 0.176, 0.176, 1.098, 1.098, 0, 0]^\top$$

$$\mathbf{x}_3 = [0, 0, 0, 0, 0, 1.098, 1.098]^\top$$

Ιδιότητες TF-IDF

- Αναθέτει βάρη στις λέξεις, δίνοντας υψηλότερα βάρη σε λέξεις που είναι σημαντικές στο έγγραφο αλλά λιγότερο συχνές στο corpus.

Λέξη	idf_i
the	$\log\left(\frac{3}{3}\right) = 0$
cat	$\log\left(\frac{3}{2}\right) \approx 0.176$
sat	$\log\left(\frac{3}{2}\right) \approx 0.176$
in	$\log\left(\frac{3}{1}\right) \approx 1.098$
hat	$\log\left(\frac{3}{1}\right) \approx 1.098$
dog	$\log\left(\frac{3}{1}\right) \approx 1.098$
barked	$\log\left(\frac{3}{1}\right) \approx 1.098$

Πίνακας 3.4: Inverse Document Frequencies

Λέξη	tfidf_{i1}	tfidf_{i2}	tfidf_{i3}
the	$1 \times 0 = 0$	$2 \times 0 = 0$	$1 \times 0 = 0$
cat	$1 \times 0.176 = 0.176$	$1 \times 0.176 = 0.176$	$0 \times 0.176 = 0$
sat	$1 \times 0.176 = 0.176$	$1 \times 0.176 = 0.176$	$0 \times 0.176 = 0$
in	$0 \times 1.098 = 0$	$1 \times 1.098 = 1.098$	$0 \times 1.098 = 0$
hat	$0 \times 1.098 = 0$	$1 \times 1.098 = 1.098$	$0 \times 1.098 = 0$
dog	$0 \times 1.098 = 0$	$0 \times 1.098 = 0$	$1 \times 1.098 = 1.098$
barked	$0 \times 1.098 = 0$	$0 \times 1.098 = 0$	$1 \times 1.098 = 1.098$

Πίνακας 3.5: Βάρη TF-IDF για κάθε έγγραφο

- **Μειώνει την επίδραση** των πιο συχνών λέξεων, εφόσον τους ανατίθεται χαμηλότερο βάρος.
- Η δυνατότητα **κανονικοποίησης** προσφέρει ευελιξία καθώς τα διανύσματα δύνανται να κανονικοποιηθούν ώστε να γίνει προσαρμογή στο μέγεθος του εγγράφου.[54]

Όπως και το BoW ωστόσο, αυτή η μέθοδος υποφέρει από τον βασικό περιορισμό ότι δεν συλλαμβάνει την σειρά των λέξεων, το σημασιολογικό περιεχόμενο και το συγκείμενο το οποίο οδηγεί σε λιγότερο ουσιώδης αναπαραστάσεις [70].

3.2.2 Μέθοδοι κατανεμημένης αναπαράστασης

Ένα μοτίβο που έγινε εμφανές στις παραδοσιακές μεθόδους, ήταν ότι σε όλες απουσίαζε η ικανότητα μοντελοποίησης της σημασιολογικής πληροφορίας των κειμένων. Η συνειδητοποίηση της βαρύτητας υπερπήδησης αυτού του εμποδίου, μαζί με την άνοδο του κλάδου του NLP, έφερε την ανάπτυξη τεχνικών κατανεμημένης αναπαράστασης λέξεων. Αυτές οι μέθοδοι, εμπνευσμένες από το πεδίο της Κατανεμημένης Σημασιολογίας (**Distributional Semantics**)⁵, βασίζονται στην ιδέα ότι λέξεις που εμφανίζονται σε παρόμοια πλαίσια έχουν

⁵Distributional semantics develops theories and methods to represent the meaning of natural language expressions, with vectors encoding their statistical distribution in linguistic contexts. It is at once a

παρόμοια σημασία [33]. Αυτό επιτυγχάνεται με την ενσωμάτωση των λέξεων σε έναν συνεχή διανυσματικό χώρο, όπου παρόμοιες λέξεις βρίσκονται κοντά μεταξύ τους.

Στο παρόν υπο-κεφάλαιο χαρτογραφούνται οι βασικές μέθοδοι κατανεμημένης αναπαράστασης που ανέπτυξαν τον κλάδο.

Λανθάνουσα Σημασιολογική Ανάλυση

Η *Λανθάνουσα Σημασιολογική Ανάλυση* (Latent Semantic Analysis - LSA) ή Latent Semantic Indexing (LSI), είναι μία θεμελιώδης τεχνική NLP που αξιοποιεί κανόνες της γραμμικής άλγεβρας για να ανακαλύψει λανθάνουσες αλληλο-εξαρτήσεις λέξεων σε μεγάλα σύνολα κειμένων (corpora)⁶[24]. Εφαρμόζοντας *Διάσπαση Ιδιαζουσών Τιμών* (Singular Value Decomposition - SVD)[22], το LSA δύναται να συλλάβει την σημασιολογική δομή λέξεων μειώνοντας τη διάσταση του μητρώου όρων-εγγράφων.

Term-Document Matrix Construction Δεδομένου ενός σώματος κειμένων με M έγγραφα και ένα λεξιλόγιο από N μοναδικούς όρους, κατασκευάστε έναν πίνακα όρων-εγγράφων $\mathbf{X} \in \mathbb{R}^{N \times M}$, όπου κάθε στοιχείο x_{ij} αντιπροσωπεύει το βάρος του όρου i στο έγγραφο j (π.χ., βαθμολογία TF-IDF).

2. Διάσπαση Ιδιαζουσών Τιμών Ο πίνακας $\mathbf{X}$ αποδομείται σε τρεις πίνακες:

$$\mathbf{X} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top$$

όπου:

- $\mathbf{U} \in \mathbb{R}^{N \times r}$: Πίνακας αριστερών μοναδιαίων διανυσμάτων (διανύσματα όρων).
- $\mathbf{\Sigma} \in \mathbb{R}^{r \times r}$: Διαγώνιος πίνακας μοναδιαίων τιμών.
- $\mathbf{V} \in \mathbb{R}^{M \times r}$: Πίνακας δεξιών μοναδιαίων διανυσμάτων (διανύσματα εγγράφων).
- r : Βαθμός του πίνακα $\mathbf{X}$.

3. Μείωση Διάστασης Επιλέγει τις κορυφαίες k μοναδιαίες τιμές και τα αντίστοιχα διανύσματα:

$$\mathbf{X}_k = \mathbf{U}_k \mathbf{\Sigma}_k \mathbf{V}_k^\top$$

όπου $k < r$. Αυτή η περικοπή αποτυπώνει τις πιο σημαντικές λανθάνουσες σημασιολογικές διαστάσεις.

theoretical model to express meaning, a practical methodology to construct semantic representations, a computational framework for acquiring meaning from language data, and a cognitive hypothesis about the role of language usage in shaping meaning. - Από το βιβλίο "Distributional Semantics, Cambridge University Press"

⁶corpus, πληθ. corpora, βλ. Λεξικό)

Η μέθοδος LSA καταφέρνει να συλλάβει την συνωνυμία των λέξεων και τις εννοιολογικές μεταξύ τους ομοιότητες, ενώ παράλληλα διατηρεί πληροφοριακή ακεραιότητα λόγω της εξάλειψης θυρούβου που επιτυγχάνεται με την μείωση της διάστασης. Ωστόσο, η υπολογιστική πολυπλοκότητα του SVD[51] και η αδυναμία αποτελεσματικής διαχείρισης της πολυσημίας εισάγουν κάποια βασικά μειονεκτήματα. Παραμένει όμως σχετική τεχνική σε θέματα ανάκτησης πληροφορίας και ταξινόμησης εγγράφων[86].


Word2Vec

Το 2013, οι Mikolov et al. [65] παρουσίασαν ένα σύνολο μοντέλων με το όνομα **Word2Vec** τα οποία παράγουν διανυσματικές αναπαραστάσεις λέξεων (word embeddings) που δύνανται να συλλάβουν σημασιολογικές και συντακτικές ομοιότητες μεταξύ τους, κάτι που ο τομέας αναζητούσε για πολύ καιρό. Οι δύο κύριες αρχιτεκτονικές είναι:

- **Continuous Bag of Words(CBOW)**
- **Skip-Gram**

Πρόκειται για ένα shallow νευρωνικό δίκτυο 2 κρυφών επιπέδων το οποίο έχει ενδεικτικά εκπαιδευτεί στο Google News 6B corpus ώστε να παράγει αναπαραστάσεις λέξεων που ενσωματώνουν το context της κάθε λέξης. Το επακόλουθο είναι η κωδικοποίηση γλωσσικών μοτίβων στις αναπαραστάσεις και ένας διανυσματικός χώρος όπου λέξεις που ανήκουν σε παρόμοια συγκείμενα να αντιστοιχούν σε διανύσματα που έχουν μεταξύ τους εγγύτητα.


Ο στόχος του Word2Vec είναι η μεγιστοποίηση της πιθανοφάνειας πρόβλεψης μίας λέξης δοθέντος του συγκειμένου της (CBOW) ή, αντιστρόφως, της πρόβλεψης του συγκειμένου δοθέντος μίας λέξης (Skip-Gram). Σε κάθε βήμα της εκπαίδευσης όμως, και τα δύο μοντέλα χρησιμοποιούν ένα προκαθορισμένου μήκους υποσύνολο του corpus (window) ορίζοντας ένα τοπικό context.



Σχήμα 3.1: Αρχιτεκτονική των δύο μοντέλων[65]

Ως αποτέλεσμα, αυτή η μέθοδος αναπαράστασης συλλαμβάνει τις σημασιολογικές σχέσεις των λέξεων. Είναι επομένως αντιληπτό ότι πρόκειται για μια τεχνολογία ιδιαίτερα σχετική για

ένα έργο όπως η αναγνώριση συναισθήματος, όπου οι λέξεις που φέρουν υψηλή συναισθηματική πληροφορία πρέπει να αναπαρίστανται σε σχετικότητα με το συγκεκριμένο, εξού και η ανώτερη επίδοση της σε σχέση με μεθόδους όπως το one-hot encoding [47].



Σχήμα 3.2: Οπτικές αναλογίες που προκύπτουν από το W2V, Google Labs

GloVe (Global Vectors for Word Representation)

Το **GloVe**, επινόηση των Pennington et al. (2014) είναι ένας αλγόριθμος μη επιβλεπόμενης μάθησης που παράγει word embeddings μέσω της συνάντησης παγκόσμιων στατιστικών συνύπαρξης λέξεων από ένα σώμα κειμένων [79], επεκτείνοντας την διαδικασία εκπαίδευσης του Word2Vec η οποία βασίζεται στην χρήση ενός προκαθορισμένου υπο-συνόλου του corpus (window).

1. Μητρώο Co-occurrence Δημιουργείται το μητρώο συν-εμφάνισης (co-occurrence) $X \in \mathbb{R}^{W \times W}$, όπου κάθε στοιχείο X_{ij} αναπαριστά την συχνότητα με την οποία η λέξη j εμφανίζεται στο context της λέξης i .

2. Objective Function Ελαχιστοποίηση ζυγισμένης συνάρτησης ελαχίστων τετραγώνων:

$$J = \sum_{i,j=1}^W f(X_{ij}) \left(\mathbf{w}_i^\top \tilde{\mathbf{w}}_j + b_i + \tilde{b}_j - \log X_{ij} \right)^2$$

Όπου:

- $\mathbf{w}_i, \tilde{\mathbf{w}}_j$: Word vectors για την βασική λέξη και την λέξη συγκεκριμένου.
- $b_i, \tilde{b}_j$: Bias terms.
- $f(X_{ij})$: Weighting function.

3. Weighting Function

$$f(X_{ij}) = \begin{cases} \left(\frac{X_{ij}}{x_{\max}}\right)^\alpha, & \text{if } X_{ij} < x_{\max} \\ 1, & \text{else} \end{cases}$$

Σύνθηθης παράμετροι: $\alpha = 0.75$, $x_{\max} = 100$.

Στα πλεονεκτήματα αυτής της μεθόδου καταλλογίζονται η αξιοποίηση των παγκόσμιων (στο πλαίσιο του corpus) πληροφορίες συνύπαρξης για την παραγωγή πιο ολοκληρωμένων αναπαραστάσεων.

3.2.3 Contextual αναπαραστάσεις λέξεων

Οι αναφερόμενες αναπαραστάσεις λέξεων παράγουν μοναδικές, στατικές αναπαραστάσεις για κάθε λέξη ανεξάρτητα του συγκεκριμένου που τις περιτριγυρίζουν. Η απάντηση σε αυτόν τον περιορισμό είναι οι Contextualized αναπαραστάσεις, οι οποίες είναι δυναμικές σε σχέση με το συγκεκριμένο.

Κύρια Μοντέλα

- **ELMo (Embeddings from Language Models)** [80]: Χρησιμοποιεί βαθιά αμφίδρομα LSTMs για την παραγωγή διανυσματικών αναπαραστάσεων λέξεων με τρόπο που λαμβάνει υπόψη όλο το περιεχόμενο της εισόδου.[31] Αυτό επιτυγχάνεται με την αμφίδρομη προσπέλαση της εισόδου που επιτρέπει στην αρχιτεκτονική την σύλληψη της πολυσημίας των λέξεων. Κατά την εμφάνιση του προσέφερε υψηλότερη επίδοση από τα ανταγωνιστικές τεχνικές αναπαράστασης στο έργο του sentiment analysis[80].
- Τα **BERT (Bidirectional Encoder Representations from Transformers)**[27] χρησιμοποιούν την αρχιτεκτονική Transformer για την παραγωγή αναπαραστάσεων που λαμβάνουν υπόψη το εκάστοτε συμφραζόμενο της λέξης.

	Source	Nearest Neighbors
GloVe	play	playing, game, games, played, players, plays, player, Play, football, multiplayer
biLM	Chico Ruiz made a spectacular <u>play</u> on Alusik 's grounder {...}	Kieffer , the only junior in the group , was commended for his ability to hit in the clutch , as well as his all-round excellent <u>play</u> .
	Olivia De Havilland signed to do a Broadway <u>play</u> for Garson {...}	{...} they were actors who had been handed fat roles in a successful <u>play</u> , and had talent enough to fill the roles competently , with nice understatement .

Σχήμα 3.3: Επίδειξη αναπαραστάσεων του ELMo σε σύγκριση με του glove, από[80]

Με την εμφάνιση αυτών των τεχνολογιών, έχει πλέον καθιερωθεί ένα πρότυπο αναπαραστάσεων με ικανότητα σύλληψης λεπτής σημασιολογικής πληροφορίας που πυροδότησε την ραγδαία ανάπτυξη του κλάδου του NLP, παρέχοντας πυκνές διανυσματικές αναπαραστάσεις των

λέξεων που ενσωματώνουν στην αποτύπωση τους σημασιολογικές και συντακτικές σχέσεις μεταξύ αυτών. Ξεκινώντας από μοντέλα όπως το LSA και το LDA⁷, που ανακαλύπτουν λανθάνουσες δομές, έως το Word2Vec και το GloVe που προσφέρουν αποδοτικά και ισχυρά embeddings, αυτές οι μέθοδοι έχουν βελτιώσει σημαντικά την επίδοση στην πλειοψηφία των NLP benchmarks [71]. Η εισαγωγή των συμφραζόμενων αναπαραστάσεων σηματοδοτεί μια περαιτέρω πρόοδο, επιτρέποντας στα μοντέλα να λαμβάνουν υπόψη τη δυναμική φύση της γλώσσας και ανοίγοντας τον δρόμο για τα γλωσσικά μοντέλα μεγαλύτερης κλίμακας.

3.3 Γλωσσικά Μοντέλα

Γλωσσικό Μοντέλο είναι μία συνάρτηση που αντιστοιχίζει ένα μέτρο (μία τιμή) πιθανότητας στα αλφαριθμητικά που μπορούν να παραχθούν από ένα λεξιλόγιο [63]. Δηλαδή, για γλωσσικό μοντέλο M αλφαβήτου Σ :

$$\sum_{s \in \Sigma^*} P_M(s) = 1$$

όπου:

- Σ^* αναπαριστά το σύνολο όλων των πιθανών ακολουθιών (οποιοδήποτε μήκους) που δύναται να σχηματιστεί από το αλφάβητο Σ ,
- s είναι μία ακολουθία συμβόλων (μία λέξη ή πρόταση),
- $P_M(s)$ η πιθανότητα που αποδίδεται από το μοντέλο M στην ακολουθία s .

Σε αυτό το κεφάλαιο θα παρουσιαστούν τα βασικά χαρακτηριστικά των γλωσσικών μοντέλων και η εξέλιξη τους κατά τα χρόνια.

3.3.1 Παραδοσιακά Μοντέλα

N-grams

Το απλούστερο είδος γλωσσικού μοντέλου είναι τα N-grams. Το γλωσσικό μοντέλο αυτό, χρησιμοποιεί τις προηγούμενες $N - 1$ λέξεις (τυπικά μια ή δύο) σαν μια προσέγγιση της ιστορίας. Συνεπώς ένα 2-gram καλείται σαν πρώτης τάξης Markov μοντέλο (κοιτάζει μια λέξη στο παρελθόν), ενώ το 3-gram σαν δεύτερης τάξης Markov μοντέλο και σε γενικές γραμμές κάθε N-ενγραμ καλείται σαν $N - 1$ τάξης Markov μοντέλο.

Συνεπώς, για την ακολουθία λέξεων $W = (w_1, w_2, \dots, w_T)$, η πιθανότητα, χρησιμοποιώντας τον κανόνα αλυσίδας, είναι:

$$P(W) = \prod_{t=1}^T P(w_t | w_1, w_2, \dots, w_{t-1})$$

που απλοποιείται σε:

⁷LDA is a three-level hierarchical Bayesian model, in which each item of a collection is modeled as a finite mixture over an underlying set of topics - Andrew Y. Ng et al. (2003)

$$P(w_t|w_1, w_2, \dots, w_{t-1}) \approx P(w_t|w_{t-N+1}, \dots, w_{t-1})$$

Για παράδειγμα, το 2-gram ($N = 2$) είναι:

$$P(W) \approx \prod_{t=1}^T P(w_t|w_{t-1})$$

Ο βασικός περιορισμός αυτού του μοντέλου είναι η αναμενόμενη σπανιότητα των δεδομένων, καθώς σε μεγαλύτερα N-grams η πιθανοφάνεια εύρεσης της ίδιας ακολουθίας μικραίνει, οδηγώντας σε αραιά δεδομένα. Παράλληλα, παρά την ικανότητα αναγνώρισης μοτίβων, η αδυναμία σημασιολογικής σύλληψης αποτελεί επίσης σημαντικό περιορισμό [15].

3.3.2 Νευρωνικά Μοντέλα

Feedforward Νευρωνικά Γλωσσικά Μοντέλα

Οι Bengio et al. [9], παρουσίασαν το 2003 τα Feedforward Νευρωνικά γλωσσικά μοντέλα (FFNNLM) που χρησιμοποιούν νευρωνικά δίκτυα για να τον υπολογισμό εμφάνισης της επόμενης λέξης.

Κάθε λέξη w αναπαρίσταται από ένα διάνυσμα $\mathbf{e}_w$.

Η αρχιτεκτονική έχει ως εξής:


- **Input Layer:** Concatenation των embeddings των προηγούμενων $N - 1$ λέξεων.
- **Hidden Layer(s):** Μη γραμμικοί μετασχηματισμοί.
- **Output Layer:** Πρόβλεψη κατανομής πιθανότητας με χρήση softmax.

Αργότερα, τα Recurrent Neural Network Language Models (RNNLMs) προτάθηκαν από τους Mikolov et al [66] σαν εναλλακτική λόγω της ικανότητας τους να μοντελοποιήσουν ακολουθιακή πληροφορία (όπως λέξεις) αυθαίρετου μήκους χωρίς να απαιτείται ένα προκαθορισμένο window size. Ένας ακόμη λόγος που αυτή η ανάπτυξη έγινε αποδεκτή ήταν η μείωση του αριθμού των παραμέτρων που έπρεπε να ρυθμιστούν κατά την εκπαίδευση. Το μοντέλο μάλιστα επεκτάθηκε λίγο μετά την εμφάνιση του [67]. Παρά την ανωτερότητα του όμως υπέρ των feed-forward neural network language models και των n-gram μοντέλων, εξακολουθεί να υποφέρει από την αδυναμία κωδικοποίησης ακολουθιών μεγάλης έκτασης, όπως συχνά συμβαίνει με τα RNN μοντέλα.

3.3.3 Transformer-Based Μοντέλα

Η ανάγκη υπέρβασης των περιορισμών που χαρακτηρίζουν τις αναφερόμενες τεχνολογίες, συμβάδισε με την αύξηση της διαθέσιμης υπολογιστικής ισχύος στην ανάπτυξη μίας πολυσήμαντης για το NLP εφεύρεσης, την αρχιτεκτονική των Transformers [105]. Τα Transformers είναι πλέον το πρότυπο στην κατασκευή Μεγάλων Γλωσσικών Μοντέλων, επαναστατώντας πλήρως τον τομέα της επεξεργασίας ομιλίας και γλώσσας. Η αρχιτεκτονική του συνίσταται από

ένα νευρωνικό δίκτυο συγκεκριμένης δομής που περιλαμβάνει τον μηχανισμό **self-attention** ή **multi-head attention** - την contextual αναπαράσταση της σημασίας των συμβόλων που επιτυγχάνεται με την ενσωμάτωση πληροφορίας από τα περιβάλλοντα σύμβολα [46]. Αυτή η λύση βοηθάει το μοντέλο να ενημερωθεί για τις σημασιολογικές και συντακτικές συσχετίσεις των tokens σε μεγάλες εκτάσεις corpora.



Σχήμα 3.4: Αρχιτεκτονική ενός (left-to-right) Transformer που επιδουκνύει την κωδικοποίηση κάθε token εισόδου[46]

Ο μηχανισμός προσοχής, σε θεμελιακό βαθμό, μοντελοποιείται ως το ζυγισμένο άθροισμα των context vectors, με έμφαση στο πως υπολογίζονται τα βάρη και ποιά διανύσματα θα αθροιστούν. Διαισθητικά:

$$a_i = \sum_{j \leq i} \alpha_{ij} x_j$$

όπου:

- a_i : Η έξοδος προσοχής στην θέση i .
- α_{ij} : Το βάρος προσοχής μεταξύ των θέσεων i και j .
- x_j : Η είσοδος στην θέση j .

Επεκτείνοντας, όπως περιγράφεται από τους Vaswani et al.[105], ο κύριος υπολογισμός της προσοχής δίνεται από:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

- $Q \in \mathbb{R}^{n \times d_k}$: Matrix of queries.
- $K \in \mathbb{R}^{m \times d_k}$: Matrix of keys.
- $V \in \mathbb{R}^{m \times d_v}$: Matrix of values.

- d_k : Διάσταση των queries και keys.
- n, m : Μήκη ακολουθίας των queries και keys/values.

Υπολογισμός των βαρών:

1. **Υπολογισμός τιμών συμβατότητας:**

$$\text{Τιμές} = QK^\top$$

Υπολογισμός στικτού γινομένου μεταξύ queries και keys.

2. **Στάθμιση τιμών:**

$$\text{Σταθμισμένες τιμές} = \frac{\text{Τιμές}}{\sqrt{d_k}}$$

Γίνεται διαίρεση των τιμών με $\sqrt{d_k}$ για να μην επιτραπεί στην μεγάλες τιμές να δυσκολεύουν την εκπαίδευση.

3. **Εφαρμογή Softmax:**

$$\alpha = \text{Softmax}(\text{Σταθμισμένες τιμές})$$

Ύστερα, γίνεται μετατροπή των τιμών σε κατανομή πιθανότητας (βάρη προσοχής), όπου $\alpha \in \mathbb{R}^{n \times m}$.

4. **Υπολογισμός ζυγισμένου αθροίσματος τιμών**

$$\text{Attention}(Q, K, V) = \alpha V$$

Multi-Head Προσοχή

1. **Linear Projections:**


Οι ερευνητές στο [105] διαπίστωσαν πως είναι ωφέλιμο, για κάθε κεφαλή i , να εφαρμοστεί γραμμική προβολή στα Q , K , και V :

$$\begin{aligned} Q_i &= QW_i^Q \\ K_i &= KW_i^K \\ V_i &= VW_i^V \end{aligned}$$

όπου W_i^Q, W_i^K, W_i^V είναι μητρώο προβολής για την κεφαλή i .

2. **Υπολογισμός προσοχής για κάθε κεφαλή:**

$$\text{κεφαλή}_i = \text{Προσοχή}(Q_i, K_i, V_i)$$



Σχήμα 3.5: Ροή πληροφορίας στην αυτό-προσοχή[46]

3. Concatenate and Project:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O$$

όπου W^O η έξοδος του μητρώου προβολής και h ο αριθμός των κεφαλών προσοχής.

Εφαρμόζοντας τον μηχανισμό προσοχής, τα Transformers αρθρώνονται ως τον συνδυασμό 2 τμημάτων:

- **Encoder:** Επεξεργάζεται την ακολουθία εισόδου και παράγει τις αναπαραστάσεις.
- **Decoder:** Παράγει την ακολουθία εξόδου προβλέποντας ξεχωριστά κάθε token χρησιμοποιώντας την έξοδο του κωδικοποιητή και τα, έως τώρα, tokens.

Ο encoder συντίθεται από πολλά όμοια επίπεδα, το καθένα με δύο βασικά υπο-επίπεδα:

1. Μηχανισμός Multi-Head Self-Attention

Ο σκοπός του μηχανισμού, όπως αναφέρθηκε παραπάνω, είναι να συλλαμβάνει τις σχέσεις των λέξεων μεταξύ τους ανεξαρτήτως απόστασης. Παράλληλα, μέσω των πολλών κεφαλών, το μοντέλο μπορεί να προσπελάσει πολλά κομμάτια της εισόδου, εμπλουτίζοντας τις αναπαραστάσεις του.


2. Position-Wise Feed-Forward Network

Αυτό το επίπεδο εφαρμόζει ένα feed-forward network σε κάθε θέση ώστε να εισάγει μη γραμμικότητα και να επεξεργαστεί περαιτέρω την πληροφορία που εξάγει το προηγούμενο επίπεδο.

Ο decoder είναι όμοιος σε δομή με τον encoder, με την προσθήκη όμως ενός ακόμη επιπέδου:

1. Μηχανισμός Multi-Head Self-Attention

Επιτελεί παρόμοια λειτουργία με του κωδικοποιητή, αλλά προσθέτει μία λειτουργία masking ώστε να εγγυηθεί ότι οι προβλέψεις στην θέση i θα εξαρτούνται μόνο από τις γνωστές εξόδους μέχρι εκείνο το σημείο (από θέσεις μικρότερες του i)



Σχήμα 3.6: Encoder-Decoder Αρχιτεκτονική: [105]

2. Multi-Head Encoder-Decoder Attention

Αυτό το επιπρόσθετο επίπεδο επιτρέπει στον αποκωδικοποιητή να αξιοποιήσει πληροφορία της ακολουθίας εισόδου κατά την παραγωγή της εξόδου.

3. Position-Wise Feed-Forward Network

Τέλος, λόγω της απουσίας της ακολουθιακής φύσης των RNNs, η αρχιτεκτονική των Transformers περιλαμβάνει **positional encodings** ώστε να ενσωματώσει πληροφορία για την θέση του κάθε token στην ακολουθία. Αυτή, ορίζεται ως:

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d_{\text{μoδελ}}}}\right)$$

$$PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{\text{μoδελ}}}}\right)$$

όπου:

- pos : Θέση στην ακολουθία.
- i : index διάστασης.

- d_{model} : διαστατικότητα μοντέλου.

Πάνω σε αυτή τη τεχνολογία, βασίζονται μεγαλύτερα Γλωσσικά Μοντέλα όπως το BERT και η οικογένεια μοντέλων GPT. Παράλληλα, ο μηχανισμός προσοχής συμβαδίζει και με τα πιο ελπιδοφόρα αποτελέσματα στο πρόβλημα της αναγνώρισης συναισθημάτων στην βιβλιογραφία (βλ.Κεφ2), καθώς πλέον λεπτά σημεία του λόγου μπορούν να ποσοτικοποιηθούν με μαθηματικό τρόπο.

Προ-εκπαιδευμένα Γλωσσικά Μοντέλα

BERT Η αρχιτεκτονική του μοντέλου BERT (Bidirectional Encoder Representations from Transformers) είναι ένας πολυεπίπεδος αμφίδρομος Transformer, βασισμένος στην αρχική υλοποίηση που περιγράφηκε στο [105] και κυκλοφόρησε στη βιβλιοθήκη tensor2tensor. Υπάρχουν δύο τύποι μοντέλων BERT, το BERTBASE και το BERTLARGE. Το μοντέλο χρησιμοποιεί ένα συγκεκριμένο σύστημα αναπαράστασης εισόδου και εξόδου για να κωδικοποιεί προτάσεις φυσικής γλώσσας σε συνεχή διανυσματικές αναπαραστάσεις. Στην ουσία παίρνει ως είσοδο την ακολουθία word embeddings, στην οποία πρώτα εφαρμόζει tokenization σε επιμέρους κομμάτια λέξεων ή υπολέξεις μέσω της τεχνικής WordPiece tokenization. Τα κομμάτια λέξεων στη συνέχεια μετατρέπονται σε διανυσματικές αναπαραστάσεις μέσω ενός embedding matrix, το οποίο μαθαίνεται κατά τη διάρκεια της εκπαίδευσης. Επιπλέον, το BERT χρησιμοποιεί δύο ειδικά tokens για να σημάνει την αρχή και το τέλος κάθε πρότασης - το [CLS] (classification) και το [SEP] (separator). Το [CLS] token παρατίθεται στην αρχή της ακολουθίας εισόδου και χρησιμοποιείται για να αναπαραστήσει ολόκληρη την πρόταση σε επακόλουθες (downstream) εργασίες⁸, όπως η ταξινόμηση ή η παλινδρόμηση. Το [SEP] token χρησιμοποιείται για να χωρίζει τις προτάσεις σε περίπτωση πολλαπλών προτάσεων στην είσοδο. Όσον αφορά την αναπαράσταση εξόδου, το μοντέλο δημιουργεί μια contextualized αναπαράσταση για κάθε token εισόδου, η οποία παράγεται λαμβάνοντας υπόψη ολόκληρη την ακολουθία εισόδου (βλ. μηχανισμό προσοχής). Η αναπαράσταση εξόδου για κάθε token προέρχεται από την τελική κρυφή κατάσταση του μοντέλου BERT, η οποία είναι μια διανυσματική αναπαράσταση της ακολουθίας εισόδου αφού περάσει από πολλά επίπεδα self-attention και στρώσεις feed-forward νευρωνικού δικτύου. Επιπλέον, το BERT χρησιμοποιεί το ειδικό token [CLS] ως την τελική αναπαράσταση εξόδου για ολόκληρη την ακολουθία εισόδου. Αυτό χρησιμοποιείται σε επακόλουθες εργασίες που απαιτούν ταξινόμηση της ακολουθίας εισόδου, όπως η ανάλυση συναισθημάτων[28].


Το BERT δεν είναι προεκπαιδευμένο όπως τα παραδοσιακά γλωσσικά μοντέλα. Αντίθετα, το BERT προεκπαιδεύεται χρησιμοποιώντας δύο μη επιβλεπόμενες εργασίες, οι οποίες εκτελούνται ταυτόχρονα. Αυτές οι εργασίες είναι το Masked Language Model (MLM) και το Next Sentence Prediction (NSP). Αυτές οι εργασίες περιγράφονται παρακάτω. Η εκπαίδευση του BERT ολοκληρώνεται με το Fine-tuning.

⁸Στην επεξεργασία φυσικής γλώσσας, η αναγνώριση συναισθημάτων από κείμενα είναι ένα παράδειγμα downstream task ή επακόλουθης εργασίας, αφού χρησιμοποιεί ένα προ-εκπαιδευμένο μοντέλο γλώσσας σε μία εργασία που ξεπερνά την αρχική εκπαίδευση. Πιο πολλές σχετικές πληροφορίες αναλύονται στο Κεφάλαιο 4.

Εργασία 1: Masked Language Model (MLM) - Το BERT κρύβει τυχαία (εφαρμόζοντας masking) μερικά από τα tokens εισόδου και απαιτεί από το μοντέλο να προβλέψει τα κρυμμένα tokens βασισμένο στο περιβάλλον συγκείμενο. Αυτή η εργασία επιτρέπει στο BERT να καταγράψει αμφίδρομες contextual πληροφορίες για κάθε δείγμα εισόδου.

Εργασία 2: Next Sentence Prediction (NSP) - Το BERT εκπαιδεύεται για να προβλέψει εάν μια πρόταση ακολουθεί μια άλλη πρόταση στην ακολουθία εισόδου. Αυτή η εργασία βοηθά το BERT να συλλάβει σχέσεις μεταξύ προτάσεων και να κατανοήσει τη συνολική δομή της εισόδου. Συνολικά, η προσέγγιση προεκπαίδευσης του BERT χρησιμοποιώντας τις εργασίες MLM και NSP του επιτρέπει να συλλαμβάνει πλούσιες αμφίδρομες contextual πληροφορίες και σχέσεις μεταξύ των προτάσεων, οι οποίες μπορούν να προσαρμοστούν σε μια μεγάλη ποικιλία εργασιών επεξεργασίας φυσικής γλώσσας.

Το BERT είναι μια μεγάλη αρχιτεκτονική νευρωνικών δικτύων με τεράστιο αριθμό παραμέτρων, κυμαινόμενο από 100 εκατομμύρια έως πάνω από 300 εκατομμύρια. Έτσι, η εκπαίδευση ενός μοντέλου BERT εκ νέου σε ένα μικρό σύνολο δεδομένων θα είχε ως αποτέλεσμα overfitting[28]. Ως εκ τούτου, είναι προτιμότερο να χρησιμοποιηθεί ένα προ-εκπαιδευμένο μοντέλο BERT που έχει εκπαιδευτεί σε ένα τεράστιο σύνολο δεδομένων ως σημείο αφετηρίας. Μπορούμε στη συνέχεια να εκπαιδεύσουμε περαιτέρω το μοντέλο στο σχετικά μικρότερο σύνολο δεδομένων μας, και αυτή η διαδικασία είναι γνωστή ως fine-tuning [27] και θα αναλυθεί παρακάτω. Επομένως, το fine-tuning είναι μια κοινή τεχνική για μεταφορά μάρτησης.



Σχήμα 3.7: BERT input representations: Η είσοδος είναι το άθροισμα των token embeddings, segment embeddings and position embeddings[105]

GPT Models Η οικογένεια των Generative Pre-trained Transformer (GPT) μοντέλων, ανεπτυγμένη από την OpenAI, αντιπροσωπεύει μια σειρά γλωσσικών μοντέλων που εξείζαν σημαντικά τον τομέα του NLP, όχι μόνο επιστημονικά αλλά και εμπορικά. Κάθε έκδοση των GPTs βασίζεται στην προηγούμενη, με μεγαλύτερο μέγεθος μοντέλου, βελτιωμένη αρχιτεκτονική και καλύτερη σχέση επίδοσης και απόδοσης σε ποικίλες εργασίες. Παρακάτω δίνεται μια σύντομη επισκόπηση κάθε μοντέλου από το GPT-1 έως το GPT-4.

GPT-1

Το GPT-1[87] παρουσιάστηκε το 2018 και βασίστηκε στην αρχιτεκτονική των Transformers, με μονοκατευθυνόμενη δομή, που σημαίνει ότι επεξεργαζόταν το κείμενο από αριστερά προς τα δεξιά (σε αντίθεση με το αμφίδρομο BERT). Το GPT-1 περιλάμβανε 12 επίπεδα (transformer blocks), 117 εκατομμύρια παραμέτρους, και χρησιμοποίησε μη-επιβλεπόμενη προ-εκπαίδευση, ακολουθούμενη από επιβλεπόμενο fine-tuning. Εκπαιδεύτηκε σε ένα μεγάλο corpus στην εργασία πρόβλεψης της επόμενης λέξης μαθαίνοντας πληροφορίες από τα συμφραζόμενα. Παρά την πρωτοπορία του, το GPT-1 είχε περιορισμούς στην αντιμετώπιση πιο πολύπλοκων εργασιών[101].

GPT-2

Το 2019, η OpenAI το μεγαλύτερο μοντέλο GPT-2, με αύξηση έως 1.5 δισεκατομμύρια παραμέτρους. Η κύρια βελτίωση ήταν η δυνατότητά του να παράγει πιο συνεκτικό και ευανάγνωστο μακροσκελές κείμενο. Το GPT-2 μπορούσε επίσης να εκτελεί πολλές εργασίες με zero-shot learning, χωρίς ειδική προσαρμογή. Έδειξε σημαντικές βελτιώσεις στην παραγωγή κειμένου, μετάφραση, περίληψη και απάντηση σε ερωτήσεις.[88]

GPT-3

Μόλις έναν χρόνο αργότερα δημοσιεύτηκε και η εξέλιξη, το GPT-3, το οποίο είναι ένα από τα πιο αξιοσημείωτα μοντέλα της οικογένειας GPT λόγω του μεγέθους του, φτάνοντας τις 175 δισεκατομμύρια παραμέτρους. Το GPT-3 αξιοποίησε few-shot και zero-shot learning, που σημαίνει ότι μπορούσε να εκτελεί εργασίες κατανοώντας μοτίβα από λίγα ή και καθόλου παραδείγματα. Αντιμετώπιζε ένα ευρύ φάσμα εφαρμογών, όπως η δημιουργία κώδικα, η δημιουργική γραφή και εργασίες συνομιλίας.

GPT-4

Το GPT-4, κυκλοφόρησε το 2023 και αποτελεί το πιο προχωρημένο μοντέλο της οικογένειας GPT. Το GPT-4 εισήγαγε multimodal δυνατότητες, που σημαίνει ότι μπορούσε να επεξεργαστεί τόσο κείμενο όσο και εικόνες(μέσω του Dall-E), επεκτείνοντας τις δυνατότητές του σημαντικά. Είναι πιο αξιόπιστο, δημιουργικό, και ικανό να χειρίζεται πιο περίπλοκες ερωτήσεις σε σχέση με τους προκατόχους του. Το GPT-4 συνεχίζει να βασίζεται στην αρχιτεκτονική των Transformers αλλά με βελτιωμένο prompt engineering και καλύτερη ικανότητα γενίκευσης σε διάφορους τομείς. Οι τεχνικές λεπτομέρειες, όπως ο ακριβής αριθμός παραμέτρων, παραμένουν ιδιοκτησία της OpenAI[72].

Claude Models

Claude 1

Η οικογένεια Claude, αναπτυγμένη από την Anthropic, αντιπροσωπεύει μια σειρά από εξελιγμένα μεγάλα γλωσσικά μοντέλα σχεδιασμένα με έμφαση στην ασφάλεια, την ηθική ευθυγράμμιση και την robust επίδοση σε μια ευρεία γκάμα εργασιών NLP. Το Claude 1 κυκλοφόρησε στις αρχές του 2023 ως το πρώτο μεγάλο γλωσσικό μοντέλο της Anthropic. Επικεντρώθηκε στη βελτίωση της ηθικής ευθυγράμμισης των γλωσσικών μοντέλων, σχεδιασμένο για να ελαχιστοποιεί επιβλαβή ή τοξικά αποτελέσματα μέσω του Constitutional AI, μιας προσέγγισης που χρησιμοποιεί ένα προκαθορισμένο σύνολο κανόνων για να καθοδηγήσει τη συμπεριφορά του μοντέλου. Το Claude 1 είχε μικρότερα μοντέλα μεγέθους μοντέλων σε σύγκριση με άλλα, ανταγωνιστικά αλλά ξεχώριζε στην ηθικά ακέραιη παραγωγή περιεχομένου.[85]

Claude 2

Αργότερα την ίδια χρονιά κυκλοφόρησε το Claude 2 το οποίο περιλάμβανε βελτιωμένες δυνατότητες few-shot learning και μεγαλύτερα μοντέλα, φτάνοντας έως και 40B παραμέτρους. Το Claude 2 έδειξε σημαντικές βελτιώσεις στη διαχείριση ανοιχτών συνομιλιακών εργασιών και στην zero-shot γενίκευση. Το μοντέλο ήταν επίσης πιο αποδοτικό όσον αφορά την κατανάλωση ενέργειας και το υπολογιστικό κόστος, καθιστώντας το πιο προσιτό για μια ευρύτερη γκάμα εφαρμογών.

Claude 3-3.5

Το Claude 3 επικεντρώθηκε στη βελτίωση της ικανότητας του μοντέλου να διαχειρίζεται εργασίες μακρού context. Ήταν βελτιστοποιημένο για καλύτερη επίδοση στη διατήρηση της συνοχής σε εκτεταμένες συνομιλίες και σύνθετες αφηγήσεις, με μεγέθη μοντέλων που έφταναν τα 50B παραμέτρους. Το Claude 3 ήταν ιδιαίτερα αποτελεσματικό σε εργασίες που απαιτούν βαθιά κατανόηση των συμφραζομένων, όπως η ερευνητική βοήθεια και η τεχνική συγγραφή. Στις 5 Ιουνίου του 2024, η Anthropic κυκλοφόρησε και το Claude Sonnet 3.5, την τελευταία έκδοση στη σειρά των μεγάλων γλωσσικών μοντέλων Claude. Αυτή η έκδοση αναπτύχθηκε για να βελτιώσει το Claude 3 Sonnet με βελτιώσεις στη συλλογιστική, τη δημιουργικότητα, ενσωματώνοντας παράλληλα τις multimodal δυνατότητες. Το Claude Sonnet 3.5 εισήγαγε ένα μοντέλο με 100B παραμέτρους, εκπαιδευμένο σε ένα σύνολο δεδομένων που αποτελείται από περισσότερα από 20 τρισεκατομμύρια tokens που συλλέχθηκαν από δημόσια διαθέσιμες και αδειοδοτημένες πηγές.[1]

LLaMA Models

LLaMA-1

Η οικογένεια LLaMA (Large Language Model Meta AI), αναπτυγμένη από τη Meta, αντιπροσωπεύει μια σειρά μεγάλων γλωσσικών μοντέλων σχεδιασμένων για να δημοκρατικοποιήσουν την πρόσβαση σε προηγμένες δυνατότητες NLP καθώς αποτελούν συνεισφορά ανοιχτού

κώδικα. Η Meta κυκλοφόρησε την οικογένεια LLaMA με στόχο να μειώσει το μέγεθος των μοντέλων, διατηρώντας παράλληλα υψηλή επίδοση, προσφέροντας μια διαθέσιμη εναλλακτική λύση στους ερευνητές σε σύγκριση με τα κλειστά εμπορικά μοντέλα. Στις αρχές του 2023, η ομάδα της Meta AI παρουσίασε το πρώτο μοντέλο της LLaMA-1, περιλαμβάνοντας ποικιλία τάξεων μεγεθών, με 7B, 13B, 30B, και 65B παραμέτρους. Ο στόχος του LLaMA-1 ήταν να δείξει ότι μικρότερα μοντέλα, όταν εκπαιδεύονται σε ένα επαρκώς μεγάλο και ποικιλόμορφο σύνολο δεδομένων, μπορούν να φτάσουν ή να ξεπεράσουν την επίδοση πολύ μεγαλύτερων μοντέλων, όπως το αναφερόμενο GPT-3. Τα μοντέλα LLaMA-1 εκπαιδεύτηκαν σε δημόσια διαθέσιμα δεδομένα, όπως τα Common Crawl, C4, GitHub και άλλα, χρησιμοποιώντας περίπου 1 τρισεκατομμύριο τοκενς. Αυτό το μοντέλο εισήγαγε καινοτομίες στην αποδοτικότητα εκπαίδευσης, μειώνοντας το περιβαλλοντικό αποτύπωμα και τις υπολογιστικές απαιτήσεις, ενώ επιτύγγανε αποτελέσματα τελευταίας τεχνολογίας σε διάφορα benchmarks, όπως η κατανόηση φυσικής γλώσσας (NLU) και οι εργασίες παραγωγής (generation tasks)[103].

LLaMA-2

Αργότερα την ίδια χρονιά, κυκλοφόρησε το LLaMA-2 που βελτίωσε περαιτέρω τη σχεδίαση και επίδοση του LLaMA-1. Τα μοντέλα LLaMA-2 βελτιώθηκαν για συγκεκριμένες εργασίες, όπως η παραγωγή κειμένου, η περίληψη κειμένων και το question answering. Τα μοντέλα LLaMA-2 περιλάμβαναν τα LLaMA-2-7B, LLaMA-2-13B, και LLaMA-2-70B παραμέτρων [104]. Παράλληλα, απαντώντας στους ενδιαασμούς που εκφράζονται για την ασφάλεια των μεγάλων γλωσσικών μοντέλων[113], η Meta εισήγαγε βελτιώσεις στην ασφάλεια μέσω της ενσωμάτωσης πιο προηγμένων τεχνικών alignment για την ελαχιστοποίηση των κινδύνων κακής χρήσης των μοντέλων. Επιπλέον, το LLaMA-2 συνέχισε να εστιάζει στην υπολογιστική αποδοτικότητα, βελτιώνοντας παράλληλα την κατανόηση συμφραζομένων και τη γενίκευση των εργασιών.[104]

LLaMA-3

Η νεότερη έκδοση αυτής της οικογένειας μοντέλων είναι το LLaMA-3 το οποίο κυκλοφόρησε με δύο μεγέθη μοντέλων: 8B και 70B παραμέτρους. Τα μοντέλα έχουν προεκπαιδευτεί σε περίπου 15 τρισεκατομμύρια tokens κειμένου που συλλέχθηκαν από δημόσια διαθέσιμες πηγές. Σύμφωνα με τις εσωτερικές δοκιμές της Meta AI τον Απρίλιο του 2024, το LLaMA-3 70B ξεπερνούσε τα Gemini Pro 1.5 και Claude 3 Sonnet στις περισσότερες μετρήσεις. [29]

Τα μεγάλα γλωσσικά μοντέλα έχουν σηματοδοτήσει την έναρξη ενός καινούριου κεφαλαίου στον κλάδο του NLP. Η γλωσσική και σημασιολογική κατανόηση που κατέχουν κάνουν τις επιδόσεις τους στις περισσότερες εργασίες επεξεργασίας φυσικής γλώσσας εντυπωσιακές. Ωστόσο, για να μεγιστοποιηθεί η αξιοποίηση των ικανοτήτων τους, καμιά φορά είναι χρήσιμο να προσαρμοστούν στις λεπτομέρειες πιο συγκεκριμένων εργασιών. Τεχνικές όπως η Μάθηση Μεταφοράς (Transfer Learning), στην οποία ένα μοντέλο που έχει προ-εκπαιδευτεί για μία συγκεκριμένη εργασία προσαρμόζεται ώστε να μπορεί να χρησιμοποιηθεί σε μία καινούρια εργασία[75], δίνουν ώθηση προς αυτή την κατεύθυνση

	Finetuned	Multilingual	Long context	Tool use	Release
Llama 3 8B	✗	✗ ¹	✗	✗	April 2024
Llama 3 8B Instruct	✓	✗	✗	✗	April 2024
Llama 3 70B	✗	✗ ¹	✗	✗	April 2024
Llama 3 70B Instruct	✓	✗	✗	✗	April 2024
Llama 3.1 8B	✗	✓	✓	✗	July 2024
Llama 3.1 8B Instruct	✓	✓	✓	✓	July 2024
Llama 3.1 70B	✗	✓	✓	✗	July 2024
Llama 3.1 70B Instruct	✓	✓	✓	✓	July 2024
Llama 3.1 405B	✗	✓	✓	✗	July 2024
Llama 3.1 405B Instruct	✓	✓	✓	✓	July 2024

Σχήμα 3.8: Επισκόπηση των μοντέλων LLaMA 3[29], των δυνατοτήτων και ημερομηνιών έκδοσης τους

Category	Benchmark	Llama 3 8B	Gemma 2 9B	Mistral 7B	Llama 3 70B	Mixtral 8x22B	GPT 3.5 Turbo	Llama 3 405B	Nemotron 4 340B	GPT-4o (o128)	GPT-4o	Claude 3.5 Sonnet
General	MMLU (5-shot)	69.4	72.3	61.1	83.6	76.9	70.7	87.3	82.6	85.1	89.1	89.9
	MMLU (0-shot, CoT)	73.0	72.3 ^Δ	60.5	86.0	79.9	69.8	88.6	78.7 ^Δ	85.4	88.7	88.3
	MMLU-Pro (5-shot, CoT)	48.3	—	36.9	66.4	56.3	49.2	73.3	62.7	64.8	74.0	77.0
	IFEval	80.4	73.6	57.6	87.5	72.7	69.9	88.6	85.1	84.3	85.6	88.0
Code	HumanEval (0-shot)	72.6	54.3	40.2	80.5	75.6	68.0	89.0	73.2	86.6	90.2	92.0
	MBPP EvalPlus (0-shot)	72.8	71.7	49.5	86.0	78.6	82.0	88.6	72.8	83.6	87.8	90.5
Math	GSM8K (8-shot, CoT)	84.5	76.7	53.2	95.1	88.2	81.6	96.8	92.3 [◇]	94.2	96.1	96.4 [◇]
	MATH (0-shot, CoT)	51.9	44.3	13.0	68.0	54.1	43.1	73.8	41.1	64.5	76.6	71.1
Reasoning	ARC Challenge (0-shot)	83.4	87.6	74.2	94.8	88.7	83.7	96.9	94.6	96.4	96.7	96.7
	GPQA (0-shot, CoT)	32.8	—	28.8	46.7	33.3	30.8	51.1	—	41.4	53.6	59.4
Tool use	BFCL	76.1	—	60.4	84.8	—	85.9	88.5	86.5	88.3	80.5	90.2
	Nexus	38.5	30.0	24.7	56.7	48.5	37.2	58.7	—	50.3	56.1	45.7
Long context	ZeroSCROLLS/QuALITY	81.0	—	—	90.5	—	—	95.2	—	95.2	90.5	90.5
	InfiniteBench/En.MC	65.1	—	—	78.2	—	—	83.4	—	72.1	82.5	—
	NIH/Multi-needle	98.8	—	—	97.5	—	—	98.1	—	100.0	100.0	90.8
Multilingual	MGSM (0-shot, CoT)	68.9	53.2	29.9	86.9	71.1	51.4	91.6	—	85.9	90.5	91.6

Σχήμα 3.9: Συγκριτική επίδοση fine tuned LLaMA 3 με άλλα ισχυρά γλωσσικά μοντέλα σε evaluation benchmarks όπως μαθηματική ικανότητα, reasoning, παραγωγή κώδικα κ.ο.κ.[29]

Στην ιδέα της μάθησης μεταφοράς στηρίζονται και άλλες μέθοδοι που, στοχεύοντας στην εύχρηστη αξιοποίηση των πολύπλευρων δυνατοτήτων των LLMs, κάνουν εφικτή την προσαρμογή τους. Οι δύο βασικές, είναι το **fine-tuning** και το **prompt tuning**.

Προσαρμογή προ-εκπαιδευμένων Γλωσσικών Μοντέλων

Έως τώρα έχει γίνει αντιληπτό πως τα προ-εκπαιδευμένα γλωσσικά μοντέλα εκπαιδεύονται σε εκτενή σύνολα δεδομένων, με επιβλεπόμενους ή μη τρόπους, απαιτώντας όμως εξαιρετικά υψηλούς υπολογιστικούς πόρους (ενδεικτικά, το νέο μοντέλο της OpenAI, εκπαιδεύτηκε χρησιμοποιώντας περίπου 25,000 Nvidia A100 GPUs σε διάρκεια 90-100 ημερών⁹). Αυτή η υπολογιστική ‘ακαμψία’ των μεγάλων γλωσσικών μοντέλων, σε συνδυασμό με την ανεπάρκεια ποιοτικών συνόλων δεδομένων για τις ποικίλες επακόλουθες εργασίες στο NLP, κάνει την εκ-νέου εκπαίδευση τους δυσπρόσιτη.

Εντούτοις, έχουν επινοηθεί τεχνικές που επιτρέπουν την πιο ‘ελαφρύα’ εκπαίδευση, οι οποίες αξιοποιούν τις ικανότητες κατανόησης γλώσσας που έχουν αναπτύξει τα μοντέλα και την προσαρμόζουν σε πιο συγκεκριμένες εργασίες.

Η **προσαρμογή** των LLMs για εξειδικευμένα καθήκοντα, όπως η αναγνώριση συναισθημάτων σε κείμενα, μπορεί να πραγματοποιηθεί με δύο κύριες προσεγγίσεις: μέσω τεχνικών fine-tuning και μέσω τεχνικών βασισμένων σε προτροπές (prompts) που χωρίζονται περαιτέρω σε prompt engineering και prompt-tuning.

Αρχικά το πρότυπο για την προσαρμογή μοντέλων σε συγκεκριμένες εργασίες ήταν το fine-tuning με την χρήση συνόλων δεδομένων σχετικών με την εν λόγω εργασία, αλλά η ανταγωνιστική της μέθοδος προσέφερε μια πιο ελαφρύα και εύχρηστη εναλλακτική. Η επιλογή της κατάλληλης μεθόδου εξαρτάται από τους διαθέσιμους υπολογιστικούς πόρους, το μέγεθος των δεδομένων και την επιθυμητή εξειδίκευση του μοντέλου.

⁹<https://klu.ai/blog/gpt-4-llm>

4.1 Fine-Tuning

Το **fine-tuning** είναι μια τεχνική στην οποία το μοντέλο, το οποίο έχει ήδη μάθει κατά την προ-εκπαίδευση του να αναγνωρίζει γλωσσικά μοτίβα, επανεκπαιδεύεται για κάποιες εποχές (epochs) σε ένα συγκεκριμένο σύνολο δεδομένων που ανταποκρίνεται στην επιθυμητή εφαρμογή. Κατά αυτή την διαδικασία, οι παράμετροι του μοντέλου μεταβάλλονται ώστε αυτό να μπορεί να συλλάβει τα χαρακτηριστικά που είναι αποκλειστικά στην εργασία, διατηρώντας παράλληλα την γενική γλωσσική και σημασιολογική κατανόηση του[40].

Πρόκειται για μία απλή διαδικασία της οποίας τα υποσχόμενα αποτελέσματα έχουν μελετηθεί εκτενώς στην βιβλιογραφία. Έρευνες όπως των Sun et al.(2019) δείχνουν ότι το fine-tuning είναι κρίσιμο για την επίτευξη υψηλής ακρίβειας σε εξειδικευμένες εφαρμογές αναγνώρισης συναισθημάτων, καθώς το μοντέλο μαθαίνει τα χαρακτηριστικά των συναισθηματικών εκφράσεων μέσω της επανεκπαίδευσης [100].

Ωστόσο δεν πρόκειται για τεχνική χωρίς μειονεκτήματα καθώς χαρακτηρίζεται από τάση για υπερεκπαίδευση (overfitting) και από υψηλές απαιτήσεις σε υπολογιστικούς πόρους. Ο τελευταίος προβληματισμός βέβαια απαντάται από μεθόδους που επιτυγχάνουν μείωση του υπολογιστικού αποτυπώματος του ολοκληρωτικού fine-tuning μέσω της αποδοτικής εκπαίδευσης των μοντέλων[114]. Η αφαίρεση παραμέτρων[89], εκπαίδευση μόνο συγκεκριμένων εισαγόμενων τμημάτων νευρωνικών δικτύων[39] και ενημέρωση βαρών με χρήση προσέγγισης χαμηλού βαθμού[42], αποτελούν επιτυχημένες προσπάθειες υπέρβασης αυτών των περιορισμών.

Τα τελευταία χρόνια όμως έχει προταθεί μία εναλλακτική προσέγγιση η οποία δεν επιβάλλει τροποποιήσεις στην εσωτερική λειτουργία των μοντέλων, αλλά αφορά τον τρόπο που αυτό λαμβάνει την είσοδο του. Αυτή η μέθοδος διατηρεί το προ-εκπαιδευμένο γλωσσικό μοντέλο ακέραιο, εισάγωντας μονάχα ένα μικρό σύνολο παραμέτρων -την **προτροπή (prompt)**- σε επίπεδο εισόδου.

Με το μέγεθος των μεγάλων γλωσσικών μοντέλων να αυξάνει εκθετικά, μέθοδοι που δεν επιβάλλουν την χρονοβόρα και υπολογιστικά δαπανηρή τροποποίηση ενός μεγάλου πλήθους παραμέτρων αλλά παράγουν αποτελέσματα με αποδοτικό τρόπο, έχουν μία δικαιολογημένη προτίμηση.

4.2 Μάθηση βασισμένη σε προτροπές

Παραδοσιακά, σε εργασίες ταξινόμησης, το προεκπαιδευμένο μοντέλο υπολογίζει την πιθανότητα:

$$P_{\theta}(Y | X)$$

όπου Y είναι μια ακολουθία από tokens που αντιπροσωπεύουν την ετικέτα κλάσης, X είναι η είσοδος κειμένου και θ αντιπροσωπεύει τις παραμέτρους (βάρη) του μοντέλου, που ρυθμίζονται μέσω fine-tuning.

Χρησιμοποιώντας προτροπές (prompts), ένα σύνολο παραμέτρων θ_p προστίθεται, ενώ οι αρχικές παράμετροι του μοντέλου θ συνήθως παραμένουν σταθερές, και το μοντέλο πρέπει

τώρα να υπολογίσει την πιθανότητα:

$$P_{\theta; \theta_p}(Y \mid X; P)$$

όπου P είναι τα prompt tokens, παραμετροποιημένα από θ_p , που περνάνε στο μοντέλο ως επιπλέον είσοδος [55].

4.2.1 Prompt engineering

Καθορισμός προτροπών

Όπως αναφέρθηκε, οι προτροπές (prompts) αποτελούνται από ένα σύνολο prompt tokens, παραμετροποιημένα από θ_p . Αυτά τα tokens μπορούν να καθοριστούν είτε χειροκίνητα [81] [11], χρησιμοποιώντας προκαθορισμένες προτροπές, συνήθως διαισθητικές ως προς τον τρόπο που οι άνθρωποι κατανοούν την εργασία, είτε να μάθουν αυτόματα χρησιμοποιώντας διάφορες μεθόδους [57].

Παραδείγματα τέτοιων μεθόδων είναι:

- **Μέθοδοι βασισμένες στην παραφράση:** Αυτές οι μέθοδοι παίρνουν μια προκαθορισμένη προτροπή και την παραφράζουν σε πολλαπλές, σημασιολογικά παρόμοιες προτροπές, από τις οποίες επιλέγεται αυτή που επιτυγχάνει την καλύτερη απόδοση.
- **Μέθοδοι βασισμένες στην εξόρυξη:** Τέτοιες μέθοδοι αναζητούν σε ένα μεγάλο σώμα κειμένου (π.χ. Wikipedia) για ακολουθίες που περιέχουν τις εισόδους εκπαίδευσης x και τις εξόδους εκπαίδευσης y , και βρίσκουν είτε τις ενδιάμεσες λέξεις είτε τα μονοπάτια εξάρτησης μεταξύ των εισόδων και εξόδων [57].

4.2.2 Τύποι προτροπών

Διακριτές (hard) προτροπές

Οι προτροπές που προτάθηκαν αρχικά στη βιβλιογραφία και χρησιμοποιούνται πολύ συχνά είναι οι διακριτές προτροπές (επίσης καλούμενες hard prompts), δηλαδή προτροπές που αποτελούνται από tokens που αντιστοιχούν άμεσα σε μια υπάρχουσα λέξη στο λεξιλόγιο του μοντέλου [11], [43]. Οι παράμετροι προτροπής θ_p σε αυτή την περίπτωση είναι ένα υποσύνολο των παραμέτρων του προεκπαιδευμένου γλωσσικού μοντέλου θ , και συγκεκριμένα των παραμέτρων ενσωμάτωσης λέξεων θ_{emb} (δηλαδή $\theta_p \subseteq \theta_{\text{emb}} \subseteq \theta$).

Με τις διακριτές προτροπές, η μορφή της εισόδου συνήθως είναι:

$$P_1 P_2 \dots P_i [X] P_{i+1} \dots P_j [Z] P_{j+1} \dots P_n$$

όπου P_i , $i = 1, 2, \dots, n$ είναι τα prompt tokens, καθένα από τα οποία αντιστοιχεί σε μια λέξη στο λεξιλόγιο του μοντέλου, $[X]$ είναι τα tokens (προερχόμενα από το εισαγόμενο κείμενο) και $[Z]$ είναι ένα ή περισσότερα ελλείποντα tokens που το μοντέλο πρέπει να συμπληρώσει (mask tokens), με την εργασία να διατυπώνεται ως εργασία μοντελοποίησης γλώσσας.

Για παράδειγμα, για μια εργασία αναγνώρισης συναισθημάτων, το πρότυπο θα μπορούσε να είναι: «Στην πρόταση $[X]$, ο ομιλητής αισθάνεται $[Z]$ », όπου το $[X]$ θα ήταν οι λέξεις του

ομιλητή του οποίου το συναίσθημα πρέπει να αναγνωριστεί και το $[Z]$ θα συμπληρωνόταν με την πρόβλεψη του μοντέλου.

Soft prompts

Οι διακριτές προτροπές προσφέρουν ερμηνευσιμότητα, καθώς οι άνθρωποι μπορούν εύκολα να κατανοήσουν το νόημά τους. Ωστόσο, η διαδικασία επιλογής του βέλτιστου προτύπου για κάθε εργασία μπορεί να είναι δύσκολη και όχι βέλτιστη. Κινητοποιημένοι από τις προκλήσεις που θέτουν οι hard prompts, καθώς και από το γεγονός ότι, σε αντίθεση με τους ανθρώπους, τα προεκπαιδευμένα μοντέλα μπορούν να κατανοήσουν συνεχή παραμέτρους που δεν αντιστοιχούν άμεσα σε φυσική γλώσσα, οι ερευνητές ανέπτυξαν έναν δεύτερο τύπο προτροπών, που ονομάζονται soft prompts [55][58].

Αυτές αποτελούνται από συνεχείς παραμέτρους, οι οποίες μπορούν να βελτιστοποιηθούν μέσω back-propagation απευθείας στον χώρο ενσωμάτωσης (embedding space), καθιστώντας τις εύκολα εκπαιδεύσιμες και πλήρως προσαρμόσιμες σε κάθε εργασία και γλωσσικό μοντέλο. Μπορούν να θεωρηθούν ως «μαλακές» λέξεις, με τις ενσωματώσεις προτροπών να βρίσκονται μεταξύ των πραγματικών ενσωματώσεων λέξεων του λεξιλογίου (δηλαδή $\theta_p \supseteq \theta$).

Η αρχικοποίηση των soft prompts μπορεί να πραγματοποιηθεί με διάφορους τρόπους. Ο πιο απλός είναι η τυχαία αρχικοποίηση των παραμέτρων τους. Ωστόσο, με τα χρόνια, έχουν προταθεί και άλλες μέθοδοι, όπως η αρχικοποίηση με ενσωματώσεις τυχαίων λέξεων από το λεξιλόγιο του γλωσσικού μοντέλου ή με τις ενσωματώσεις των ετικετών που αντιστοιχούν σε διαφορετικές κλάσεις, σε εργασίες ταξινόμησης [58].

Συνδυασμός hard και soft prompts

Αντί να επιλέξουν μεταξύ διακριτών και soft prompts, ορισμένοι ερευνητές[37] έχουν προτείνει τη συγχώνευση των δύο προαναφερθέντων τύπων, προκειμένου να βελτιώσουν την απόδοση, χρησιμοποιώντας μερικές ρυθμιζόμενες soft prompts, των οποίων οι παράμετροι μπορούν να βελτιστοποιηθούν για τη μεγιστοποίηση της απόδοσης, αλλά προσθέτοντας επίσης μερικά hard prompt tokens, που αντιστοιχούν άμεσα σε λέξεις του λεξιλογίου του μοντέλου και καθορίζονται ειδικά για κάθε εργασία.

4.2.3 Εξελιξίσεις

Τα τελευταία χρόνια, η έρευνα στο prompt engineering και στο prompt tuning έχει σημειώσει σημαντική πρόοδο, με την ανάπτυξη νέων τεχνικών και την εφαρμογή τους σε μεγάλα γλωσσικά μοντέλα. Μερικές από τις πιο σημαντικές εξελίξεις περιλαμβάνουν:

Instruction Tuning

Το Instruction Tuning είναι μια μέθοδος όπου τα μοντέλα εκπαιδεύονται σε ένα μεγάλο σύνολο από οδηγίες και τις αντίστοιχες απαντήσεις τους, βελτιώνοντας την ικανότητά τους

να ακολουθούν ανθρώπινες οδηγίες σε διάφορες εργασίες [108], [95]. Αυτό επιτρέπει στα μοντέλα να γενικεύουν καλύτερα σε νέες εργασίες και να παρέχουν πιο συνεπείς και χρήσιμες απαντήσεις.

Reinforcement Learning from Human Feedback (RLHF)

Η μάθηση ενίσχυσης από ανθρώπινη ανάδραση (Reinforcement Learning from Human Feedback) χρησιμοποιείται για τη βελτιστοποίηση των προτροπών και των αποκρίσεων των μοντέλων, λαμβάνοντας υπόψη την ανθρώπινη προτίμηση και ποιότητα απάντησης [73]. Αυτό επιτρέπει στα μοντέλα να προσαρμόζονται καλύτερα στις ανάγκες των χρηστών και να παράγουν πιο χρήσιμες και ευθυγραμμισμένες με τις ανθρώπινες αξίες απαντήσεις.

Chain-of-Thought Prompting

Η τεχνική Chain-of-Thought Prompting ενθαρρύνει τα μοντέλα να παράγουν ενδιάμεσα βήματα συλλογισμού πριν από την τελική απάντηση, βελτιώνοντας την απόδοση σε εργασίες που απαιτούν λογική και επίλυση προβλημάτων [109]. Με την παροχή παραδειγμάτων που περιλαμβάνουν αυτά τα ενδιάμεσα βήματα, τα μοντέλα μπορούν να αναπτύξουν μια «αλυσίδα σκέψης» που οδηγεί σε πιο ακριβείς και αιτιολογημένες απαντήσεις.

Η prompt based μάθηση, στην μορφή είτε του prompt engineering είτε του prompt tuning, έχει εφαρμοστεί επιτυχώς σε μεγάλα γλωσσικά μοντέλα, όπως το GPT-3, αποδεικνύοντας ότι μπορεί να επιτύχει απόδοση συγκρίσιμη με την πλήρη προσαρμογή (fine-tuning), ενημερώνοντας μόνο ένα μικρό σύνολο παραμέτρων [55]. Αυτό το καθιστά μια αποδοτική μέθοδο για την προσαρμογή μεγάλων μοντέλων σε συγκεκριμένες εργασίες χωρίς το κόστος της πλήρους εκπαίδευσης. Συνολικά, η διαδικασία του fine-tuning είναι πιο χρονοβόρα και απαιτεί περισσότερους υπολογιστικούς πόρους σε σύγκριση με το prompt-tuning, αλλά συνήθως επιτυγχάνει καλύτερη ακρίβεια, ειδικά όταν υπάρχει διαθέσιμο ένα μεγάλο σύνολο δεδομένων. Στην περίπτωση της αναγνώρισης συναισθημάτων, η προσαρμογή μέσω fine-tuning μπορεί να αντιμετωπίσει περίπλοκες και λεπτές συναισθηματικές πληροφορίες που ενδέχεται να μην αναγνωρίζονται εύκολα από ένα μοντέλο που βασίζεται μόνο στην προ-εκπαίδευση του.

Πειραματική αξιολόγηση και αποτελέσματα


5.1 Διαμόρφωση Πειράματος

Ακολουθώντας την έως τώρα ανάλυση μας, αναγνωρίζουμε την δυνητική ισχύ του `prompt tuning` και `fine tuning` στην επίλυση επακόλουθων εργασιών επεξεργασίας φυσικής γλώσσας, όπως είναι το η αναγνώριση συναισθήματος σε κειμενικούς διαλόγους. Η προσέγγιση μας συνιστά μία αξιολόγηση αυτών των μεθόδων ως μέσο σύγκρισης της ικανότητας συναισθηματικής αντίληψης διαφόρων LLMs. Παράλληλα, αναγνωρίζοντας τις διαπιστώσεις (1), (2), (3) που έγιναν στα πορίσματα του Κεφαλαίου 2, η πειραματική διαδικασία διαμορφώνεται ως εξής.

- Αναγνωρίζοντας την προηγμένη ικανότητα των LLMs να προσπελάσουν τον ανθρώπινο λόγο και να συλλάβουν σύνθετα εννοιολογικά νοήματα σε κείμενο, ενώ παράλληλα παρατηρώντας πως η τωρινή βιβλιογραφία δεν έχει ακόμη προβεί σε μία μαζική, οργανωμένη αξιολόγηση της επίδοσης τους στην αναγνώριση συναισθήματος, προχωράμε στην σύγκριση 3 state-of-the-art Γλωσσικών Μοντέλων σε αυτήν την εργασία - ***GPT-4o-2024-08-06 VS Claude-3-5-Sonnet-20240620 VS LLAMA3*** -. Προσπαθούμε να εγείρουμε τα καλύτερα δυνατά αποτελέσματα εφαρμόζοντας επίσης `prompt-tuning` και `fine-tuning`.
- Η αναγνώριση συναισθήματος σε διαλόγους είναι ένα σύνθετο πρόβλημα που απαιτεί λεπτή σημασιολογική κατανόηση της γλώσσας και ενσωμάτωση συγκεκριμένης πληροφορίας. Προτείνουμε λοιπόν μία μεθοδολογία που δεν θα απομονώνει το κάθε κομμάτι του διαλόγου αλλά θα το ενσωματώνει σε **json** αρχεία τα οποία θα περιλαμβάνουν όλη την απαραίτητη **συγκειμενική πληροφορία**. Δηλαδή για την αναγνώριση των συναισθημάτων στην *N*-οστή εκφώνηση, η είσοδος θα περιλαμβάνει όλες τις εκφωνήσεις από

$1 \dots N - 1$ μαζί με τις αντίστοιχες πληροφορίες των ομιλητών και των αναγνωρισμένων συναισθημάτων, εξηγήσεων και score βεβαιότητας.

- Αναγνωρίζοντας τους περιορισμούς στα τωρινά σχολιασμένα σύνολα δεδομένων και συμβαδίζοντας με τις έρευνες που υποδυκνύουν ότι η αφοσίωση στην ταξινόμια Ekman δεν επαρκεί για την ολοκληρωμένη περιγραφή των συναισθημάτων, πραγματοποιούμε το **annotation** ενός δείγματος του διαλογικού συνόλου δεδομένων **DailyDialog**, στο οποίο συμμετείχαν **20** χρήστες προσφέροντας **142** σχολιασμούς **40** συνολικών διαλόγων. Η διαδικασία έγινε με αυστηρές προδιαγραφές σε μία ανανεωμένη ταξινόμια που προέκυψε από την συνάντηση του σχετικού έργου του ερευνητή Alan S. Cowen.



Σχήμα 5.1: Κατανομή συναισθημάτων που χρησιμοποιούνται στις ταξινομίες της βιβλιογραφίας. Εμφανής είναι η τάση για υιοθέτηση της ταξινόμιας Έκμαν συγκριτικά με ταξινομίες που περιλαμβάνουν άλλα συναισθήματα[25]

5.2 Μεθοδολογία

5.2.1 Ενημέρωση Ταξινόμιας

Η ταξινόμια των συναισθημάτων είναι ένας ορθάνοιχτος ερευνητικός τομέας, με τους επιστήμονες να μην συμφωνούν όχι μόνο στην φύση των καθαυτό συναισθημάτων, αλλά ούτε και στα κριτήρια ταξινόμησης τους. Αυτή η τομή μεταξύ νευροεπιστημών, εξελικτικής βιολογίας και γνωστικής ψυχολογίας δεν έχει, ακόμα, εναρμονιστεί[14]¹⁰.

¹⁰Κάτα τους αιώνες, από τον Ντεκάρτ μέχρι σήμερα, φιλόσοφοι και ψυχολόγοι έχουν προτείνει οπουδήποτε από 3 έως 11 βασικά συναισθήματα. Όλες οι λίστες περιλαμβάνουν τον φόβο, τον θυμό, την στεναχώρια, κάποιες περιέχουν χαρά, αγάπη και έκπληξη. Δεν υπάρχει αδιαμφισβήτητος τρόπος να καταλείξεις σε έναν ακριβή αριθμό, παρόλο που η ανάλυση παραγόντων, έρευνες κλίμακας ομοιότητας, αναπτυξιακές και πολυ-πολιτισμικές μελέτες είναι χρήσιμες. Αλλά σε τελική ανάλυση, αυτή είναι μία θεωρητική απόφαση του αξιολογείται στο πλαίσιο των επαγωγών και της διορατικότητας που επιφέρει, την μελέτη που υπονοεί και

Το μόνο σίγουρο ωστόσο, όπως έχουν σημειώσει πολλοί ερευνητές, είναι πως η κυριαρχούσα στην βιβλιογραφία ταξινόμια του Έκμαν είναι ιδιαίτερα αφαιρετική και αφήνει ένα μεγάλο κομμάτι της ανθρώπινης εμπειρίας αχαρτογράφητο [21].

Βασιζόμενοι λοιπόν το έργο του ερευνητή Alan S. Cowen[21], η δουλειά του οποίου εισήγαγε στατιστικές μεθόδους μεγάλης κλίμακας στο πεδίο της ταξινόμιας των συναισθημάτων, παρουσιάζουμε μία ανανεωμένη λίστα συναισθημάτων. Αυτή προκύπτει από την συνάντηση των συναισθημάτων που παρουσιάζονται στις σχετικές μελέτες που αναφέρουν 27 διαφορετικές κατηγορίες συναισθηματικής εμπειρίας που εγείρουν σύντομα βίντεο[19], 13 κατηγορίες από μουσικά ερεθίσματα[18], 28 από τις εκφράσεις του προσώπου[20], 12 από την προσωδία του λόγου και 24 από σύντομες λεκτικές εκφορές, αποκλείοντας όμως προσθήκες που δεν υποστηρίζονται από κάποια επιστημονική πλασίωση αλλά έχουν επιλεχθεί λόγω της συχνής παρουσίας τους σε διαδικασίες σχολιασμού δεδομένων (π.χ. 'approval' [26], οδηγώντας σε **39** συνολικά συναισθήματα:

admiration	adoration	aesthetic appreciation
amusement	anger	awe
awkwardness	boredom	calmness
confusion	contempt	craving
desire	disappointment	disgust
empathic pain	embarrassment-shame	envy
excitement	fear	gratitude
grief	guilt	horror
interest-curiosity	joy	nervousness-anxiety
nostalgia	pride	relief
neutral	realization	sadness
satisfaction	surprise	sympathy-caring
triumph	annoyance	remorse

Πίνακας 5.1: Λίστα Συναισθημάτων που προέκυψαν από την συνάντηση των ταξινόμιών της βιβλιογραφίας

5.2.2 Δημιουργία Συνόλου Δεδομένων

Αναλογιζόμενοι των περιορισμών που έχουν τα υπάρχοντα σύνολα δεδομένων που έχουν εφαρμοστεί στο πρόβλημα της αναγνώρισης συναισθήματος σε κείμενα, αποφασίσαμε, στα πλαίσια της παρούσας έρευνας, να κατασκευάσουμε ένα αναβαθμισμένο σύνολο δεδομένων.

Το θεμέλιο αυτής της προσπάθειας ήταν το σύνολο δεδομένων Daily Dialog[60], μία εκτενής συλλογή από διαλόγους που αντικατοπτρίζουν την καθημερινή επικοινωνία των ανθρώπων.

τον βαθμό στον οποίο τα εμπειρικά δεδομένα συμβαδίζουν μαζί της.” Robert Plutchik 2001: The Nature of Emotions[83]

Dataset	Μέγεθος		Ταξινόμια	Διαλογικό	Λόγοι μη Συμ- βατότητας
ISEAR	7,666	προ- τάσεις	7 συναισθήματα	Όχι	Όχι διαλογικό· Περιορισμένη τα- ξινόμια
EmoBank	10,000	προ- τάσεις	Διαστατικό (Valence, Arousal, Domi- nance)	Όχι	Όχι κατηγορικό· Όχι διαλογικό
SemEval 2018	10,000 tweets		11 συναισθήματα	Όχι	Όχι διαλογικά δε- δομένα
DailyDialog	13,118 διάλογοι		7 συναισθήματα	Ναι	Περιορισμένη ταξι- νομία
EmotionLines	2,000 διάλογοι		7 συναισθήματα	Ναι	Περιορισμένη ταξι- νομία
MELD	1,433 διάλογοι		7 συναισθήματα	Ναι	Περιορισμένη ταξι- νομία
SEMAINE	100 διάλογοι		(Valence, Arousal, Dominance)	Ναι	Όχι κατηγορικό· μικρό δείγμα
GoEmotions	58,000 σχόλια		27 συναισθήματα	Όχι	Όχι διαλογικά δε- δομένα

Πίνακας 5.2: Σύνοψη συνόλων δεδομένων για Αναγνώριση Συναισθήματος και λόγοι μη συμβατότητας με το πλαίσιο/σκοπό της εργασίας

Για την συγκέντρωση υποψήφιων annotators, δημοσιεύτηκε μία ανοιχτή πρόσκληση συμμετοχής σε διάφορα μέσα κοινωνικής δικτύωσης και forums που σχετίζονται με την επιστήμη των υπολογιστών και την ψυχολογία. Συνολικά, πήραν μέρος 21 εθελοντές σχολιαστές (annotators).

Οι συμμετέχοντες στην διαδικασία των αναθέσεων, αφού συμπλήρωναν μία φόρμα δήλωσης ενδιαφέροντος, ανακατευθυνόντουσαν στην ιστοσελίδα που δημιουργήθηκε στα πλαίσια της εργασίας. Σε αυτή, εισερχόμενοι με τα προσωποποιημένα στοιχεία τους, τους παρουσιάζονταν 10 συνολικοί διάλογοι, για κάθε κομμάτι των οποίων έπρεπε να επιλέξουν:

- Το **συναίσθημα** (ή τα συναισθήματα) που έκριναν ότι ταίριαζε στο ύπο μελέτη κομμάτι του διαλόγου από την ανανεωμένη ταξινόμια.
- Το **confidence score**, δηλαδή το ποσό βεβαιότητας για την επιλογή τους.
- Το **weight** που αντιστοιχούσε σε ένα μέτρο βάρους του-ων- συναισθήματος-ων-, δηλαδή ένα μέτρο έντασης του συναισθήματος, σύμφωνα με την κρίση του σχολιαστή.

Οι σχολιαστές δεν είχαν χρονικό περιορισμό και οι δυνατότητες της πλατφόρμας μας τους επέτρεπε να επισκεφθούν της πρόοδο τους οποτεδήποτε επιθυμούσαν χωρίς δέσμευση ολο-

User	Age Group	Study Field	Student/Worker
User 1	18-30	Computer Science	Student
User 2	18-30	Computer Science	Student
User 3	18-30	Computer Science	Student
User 4	18-30	Computer Science	Student
User 5	18-30	Computer Science	Student
User 6	18-30	Natural Sciences	Student
User 7	18-30	Engineering	Student
User 8	18-30	Social Science	Worker
User 9	under 18	2ndDegree Education	Student
User 10	18-30	Social Science	Worker
User 11	18-30	Economics	Worker
User 12	18-30	Law	Worker
User 13	18-30	Arts and Culture	Worker
User 14	18-30	Computer Science	Student
User 15	18-30	Natural Science	Student
User 16	18-30	Social Science	Student
User 17	18-30	None of the above	Worker
User 18	18-30	Social Science	Student
User 19	18-30	Economics	Worker
User 20	18-30	Computer Science	Student
User 21	18-30	Engineering	Worker

Πίνακας 5.3: Στοιχεία των Συμμετεχόντων της διαδικασίας ανάθεσης συναισθημάτων

κλήρωσης σε περιορισμένο διάστημα. Σημειώνεται πως προς εξασφάλιση της ποιότητας των αποτελεσμάτων και για την εξάλειψη οποιασδήποτε προκατάληψης στην διαδικασία, οι annotators ήταν εθελοντές που ολοκλήρωσαν τους σχολιασμούς των συζητήσεων στον δικό τους χώρο και χωρίς χρηματική αμοιβή.

Αφού συλλέχθηκε ένα ικανοποιητικό δείγμα από σχολιασμούς, ακολούθησε μία διαδικασία εκλογής και κανονικοποίησης του τελικού συναισθήματος του κάθε υπο-μέρους των διαλόγων.

Για την μετατροπή των confidence scores των χρηστών σε αριθμητικές τιμές, χρησιμοποιήθηκε η ακόλουθη αντιστοίχιση:

$$c = \begin{cases} 0.3 & \text{if confidence_score} = \text{"Low"} \\ 0.6 & \text{if confidence_score} = \text{"Mid"} \\ 1.0 & \text{if confidence_score} = \text{"High"} \\ 0 & \text{αλλιώς} \end{cases}$$

Έτσι δίνεται μια αριθμητική τιμή c στην ποιοτική ποσότητα "Low", "Mid", "High"

Το k -score για κάθε συναισθήμα υπολογίζεται πολλαπλασιάζοντας το ανατιθέμενο βάρος με την αριθμητική τιμή του confidence score:

$$k = \text{weight} \times c$$

Το *weight* αναπαριστά την ένταση του συναισθήματος όπως κρίνεται από των σχολιαστή. Πολλαπλασιάζοντας το με το confidence score c έχουμε ένα **ζυγισμένο μέτρο έντασης** του συναισθήματος στο annotation.

Για να συμπεριληφθεί η συχνότητα εμφάνισης ενός συναισθήματος κατά τα annotations, υπολογίζουμε την κανονικοποιημένη **συχνότητα**:

$$n_e^{\text{norm}} = \frac{n_e}{N}$$

Όπου:

- n_e Ο αριθμός των εμφανίσεων του συναισθήματος e κατά τα annotations του συγκεκριμένου part.
- N ο συνολικός αριθμός των συναισθημάτων παρόν στις αναθέσεις του συγκεκριμένου part.

Επεξήγηση: Η κανονικοποίηση τοποθετεί την συχνότητα εμφάνισης σε μία κλίμακα από το 0 έως το 1, αντικατοπτρίζοντας το ποσό των χρηστών που επέλεξαν το συναισθήμα e .

Υπολογίζουμε ένα score για κάθε συναισθήμα παίρνοντας το ζυγισμένο άθροισμα του k -score και την κανονικοποιημένη συχνότητα εμφάνισης (δηλαδή το πόσοι annotators επέλεξαν ένα συγκεκριμένο συναισθήμα για το προς αξιολόγηση κομμάτι του διαλόγου) :

$$s_e = \alpha \times k_e + \beta \times n_e^{\text{norm}}$$

Όπου:

- s_e το score κάθε συναισθήματος e .
- α και β τα weighting factors (π.χ., $\alpha = 0.4$, $\beta = 0.6$) που καθορίζουν την βαρύτητα του k -score και της συχνότητας εμφάνισης.
- k_e το αθροιστικό k -score για το συναίσθημα e .
- n_e^{norm} η κανονικοποιημένη συχνότητα εμφάνισης του συναισθήματος e .

Επεξήγηση: Η εξίσωση συσχετίζει την ένταση του συναισθήματος (μέσω του k_e) με το πόσο ομόφωνα επιλέχθηκε από τους σχολιαστές (μέσω του n_e^{norm}), παρέχοντας ένα συμπεριληπτικό score για κάθε συναίσθημα.

Ακολουθεί μια διαδικασία κανονικοποίησης ώστε τα scores να υπάρχουν στην κλίμακα 0-1. Αυτό επιτυγχάνεται διαιρώντας με το μέγιστο score:

$$s_e^{\text{norm}} = \frac{s_e}{s_{\max}}$$

Όπου:

- s_e^{norm} είναι το κανονικοποιημένο, συνολικό score για το συναίσθημα e .
- $s_{\max}$ το μέγιστο score για το δοθέν part.

Κανονικοποιώντας τα scores εξασφαλίζουμε ότι το μεγαλύτερο score είναι ≤ 1 διευκολύνοντας τις μετέπειτα συγκρίσεις και προσφέροντας proportionality στις τιμές.

Τελικά, ο κάθε διάλογος, μαζί με τα τελικά annotations του, αντιστοιχούσε σε ένα αρχείο json με την ακόλουθη, ενδεικτική πληροφορία (περιλαμβάνοντας όμως και confidence scores, weights):

Dialog

Speaker	Text
Speaker A	What do you do when you are angry?
Speaker B	I usually calm down first and think about the reason that caused my anger.
Speaker A	That's smart. What do you usually do to relieve your anger?
Speaker B	Something like listening to music is a good idea.
Speaker A	Oh, what kind of music do you listen to?
Speaker B	Classic. Something that could calm your mind.

Speaker A	I think that might work for me as well.
Speaker B	Working out is another good way to relieve anger.
Speaker A	Like what?
Speaker B	Jogging, yoga, or even just taking a walk.

Πίνακας 5.4: Παράδειγμα ενός διαλόγου από το σύνολο δεδομένων. Περιλαμβάνει τα κομμάτια του διαλόγου καθώς και τους ομιλητές που τα εκφέρουν.

Manual Emotions for user y

Part	Emotion	Comments
Part 0	Interest - Curiosity	-
Part 1	Calmness	-
Part 2	Interest - Curiosity, Realization	-
Part 3	Calmness	-
Part 4	Interest - Curiosity	-
Part 5	Calmness	-
Part 6	Realization	-
Part 7	Neutral	-
Part 8	Interest - Curiosity	-
Part 9	Neutral	-

Πίνακας 5.5: Παράδειγμα ανάθεσης συναισθημάτων από την ταξινόμηση στα επιμέρους κομμάτια του διαλόγου από τυχαίο χρήστη y.

Manual Emotions for user x

Part	Emotion	Comments
Part 0	Anger, Interest - Curiosity	Searching for a way to deal with anger.
Part 1	Neutral, Calmness	Simply answering the question.
Part 2	Interest - Curiosity	Wants to know more about the previous answer.
Part 3	Calmness, Neutral	Simply answering the question.
Part 4	Interest - Curiosity	Had not thought of using music to relieve anger before.
Part 5	Neutral, Calmness	Repeats the usage of calm in their answers.
Part 6	Relief	Found a possible solution to anger.
Part 7	Neutral, Calmness	Continues giving advice.
Part 8	Interest - Curiosity	Wants to learn more.

Part 9	Neutral, Calmness	-
--------	-------------------	---

Πίνακας 5.6: Παράδειγμα ανάθεσης συναισθημάτων από την ταξινομία στα επιμέρους κομμάτια του διαλόγου από 2ο τυχαίο χρήστη x.

Manual Emotions for user z

Part	Emotion	Comments
Part 0	Interest - Curiosity	-
Part 1	Calmness	Due to sobriety and calmness required for answering.
Part 2	Admiration, Interest - Curiosity	Follow-up question.
Part 3	Neutral	-
Part 4	Interest - Curiosity	-
Part 5	Neutral	-
Part 6	Realization	-
Part 7	Neutral	-
Part 8	Interest - Curiosity	-
Part 9	Neutral	-

Πίνακας 5.7: Παράδειγμα ανάθεσης συναισθημάτων από την ταξινομία στα επιμέρους κομμάτια του διαλόγου από 3ο τυχαίο χρήστη z.

Final Emotions


Part	Final Emotion	All Emotions (Scores)
Part 0	Interest - Curiosity	Interest - Curiosity (1.0), Anger (0.416)
Part 1	Calmness	Calmness (1.0), Neutral (0.297)
Part 2	Interest - Curiosity	Interest - Curiosity (1.0), Realization (0.356), Admiration (0.287)
Part 3	Calmness	Calmness (1.0), Neutral (0.847)
Part 4	Interest - Curiosity	Interest - Curiosity (1.0)
Part 5	Calmness	Calmness (1.0), Neutral (0.684)
Part 6	Realization	Realization (1.0), Relief (0.525)
Part 7	Neutral	Neutral (1.0), Calmness (0.576)
Part 8	Interest - Curiosity	Interest - Curiosity (1.0)
Part 9	Neutral	Neutral (1.0), Calmness (0.397)

Πίνακας 5.8: Αποτελέσματα εκλογής τελικού συναισθήματος ύστερα από την διαδικασία κανονικοποίησης.

Όπου:

- **manual emotions** τα επιλεγμένα annotations των χρηστών
- **final emotions** τα εκλεγμένα τελικά συναισθήματα από την διαδικασία εκλογής και κανονικοποίησης
- **all emotions** τα συνολικά συναισθήματα που εκλέχθηκαν από τους χρήστες, μαζί με τα κανονικοποιημένα scores

Καταλήγουμε λοιπόν, με ένα dataset που ακολουθεί την παρακάτω κατανομή συναισθημάτων:




Σχήμα 5.2: Κατανομή Συναισθημάτων στο νέο σύνολο δεδομένων

Παρατηρούμε ότι όπως και στην περίπτωση του GoEmotions, προκύπτει μία κατανομή που είναι προκατειλημμένη προς συγκεκριμένα συναισθήματα, στην δικιά μας περίπτωση, αυτά που σε όρους ανάλυσης sentiment, θα κατηγοριοποιώντουσαν ως αμφίσημα.

Συναίσθημα	Πλήθος
Interest - Curiosity	72
Neutral	47
Realization	21
Disappointment	20
Excitement	18
Sympathy	16
Sadness	13
Nervousness - Anxiety	10
Relief	9
Annoyance	7
Joy	7
Calmness	7
Guilt	6
Pride	6
Confusion	5
Anger	5
Empathic pain	5
Satisfaction	4
Contempt	4
Surprise	4
Gratitude	4
None of the above	3
Fear	3
Admiration	3
Awkwardness	3
Remorse	2
Boredom	2
Disgust	2
Nostalgia	2
Aesthetic appreciation	1
Embarrassment-Shame	1
Triumph	1
Amusement	1
Adoration	1

Πίνακας 5.9: Κατανομή πλήθους συναισθημάτων στο σύνολο δεδομένων




Σχήμα 5.3: Κατανομή Sentiment στο dataset, χωρισμένα σε αμφίσημα, θετικά και αρνητικά.

5.3 Πειραματική Αξιολόγηση

Έχοντας πλέον το σύνολο δεδομένων μας και έχοντας διασφαλίσει για την ακεραιότητα των τιμών του, προχωράμε στην αξιολόγηση των LLMs. Καλώντας τα APIs που έχει ορίσει η διεύθυνση του εκάστοτε LLM για το κάθε προτροπή-prompt, σε κάθε επανάληψη της κλήσης η είσοδος είναι:

- Η προτροπή
- Ο διάλογος που περιλαμβάνει:
 - Το προς αξιολόγηση κομμάτι διαλόγου
 - Το συγκείμενο, μαζί με τις αντίστοιχες προβλέψεις του μοντέλου για το συναίσθημα που αναγνωρίστηκε σε κάθε προηγούμενο υπο-μέρος του.

Για την αξιολόγηση του ποσοστού βελτίωσης που επιφέρουν prompts που ακολουθούν τα πρωτόκολλα του εκάστοτε LLM, χρησιμοποιήθηκαν οι 3 ακόλουθες εκδοχές, σε αύξουσα σειρά πληρότητας:



Σχήμα 5.4: Heatmap συναισθημάτων ταξινομημένων βάσει Sentiment και την συχνότητα εμφάνισής τους. Όσο πιο κόκκινο το δείγμα, τόσο συχνότερα εμφανίζεται το αντίστοιχο συναίσθημα.

Prompt Version 1

Given a JSON structure of a conversation between two individuals (present in the input file under the tag "dialog"), identified as Speaker A and Speaker B, you are to complete the task of Emotion Detection on each utterance of each dialog.

You will iteratively complete emotion detection for each part of the dialogue.

You must follow the pattern: first detect the emotion in "*part₀*" then, given the emotions present in the last part, detect the emotion in "*part₁*" (next part) then, given the emotions present in the last two parts, detect the emotion in "*part₂*" (next part) etc.

The referenced list of emotions is: admiration, adoration, aesthetic appreciation, amusement, anger, awe, awkwardness, boredom, calmness, confusion, contempt, desire, craving, disappointment, disgust, empathic pain, embarrassment-shame, envy, excitement, fear, gratitude, grief, guilt, horror, interest-curiosity, joy, nervousness-anxiety, nostalgia, pride, relief, neutral, realization, sadness, satisfaction, surprise, sympathy-caring, triumph, annoyance, remorse.

Only choose emotions from this list; no other emotions are acceptable. Always keep in mind the context of the conversation. Also output an explanation for your choice of emotion, as well as a confidence score from 0-1 indicating how certain you are of your choice.

Rudimentary version, no special instructions.

Prompt Version 2

You are a master psychologist with excellent understanding of human emotions, as well as a keen understanding of written language.

Given a JSON structure representing a conversation between two individuals, identified as Speaker A and Speaker B, each message should include the following fields: "speaker" (indicating whether the speaker is A or B), "message" (the content of the conversation), and "emotion" along with its corresponding intensity "confidence_score" (indicating the emotional state tagged with its intensity from a prior analysis, if available).

Additionally, the JSON encompasses a "next_sentence" from one of the speakers, also tagged with their respective identifier (A or B).

Your task is to analyze the emotional content of this "next_sentence" by referring to a provided list of emotions: [emotion1, emotion2, ...]. Select and justify the most suitable emotions from this list that resonate with the sentiment expressed in the "next_sentence," considering the emotional trajectory from the preceding messages in the conversation.

Example Input: "conversation": ["speaker": "A", "message": "Whens your birthday?", "emotion": "curiosity", "confidence_score": 0.8], "next_sentence": "speaker": "B", "message": "Its just around the corner. "

Example Output:

"emotion": "emotion", "confidence_score": "intensity from 0-1", "explanation": "reasoning..."

The allowed list of emotions is: [admiration, adoration, aesthetic appreciation, amusement, anger, awe, awkwardness, boredom, calmness, confusion, contempt, desire, craving, disappointment, disgust, empathic pain, embarrassment-shame, envy, excitement, fear, gratitude, grief, guilt, horror, interest-curiosity, joy, nervousness-anxiety, nostalgia, pride, relief, neutral, realization, sadness, satisfaction, surprise, sympathy-caring, triumph, annoyance, remorse].

Only emotions from this list are acceptable; no other emotions will be considered. Do NOT choose emotions outside of the list like "Concern", "Agreement", "Frustration", etc.

Instructions that follow *OpenAI*, *Claude*, *Llama* protocols: Adopt a persona, provide detailed output format and example.

Prompt Version 3

You are an expert in human psychology and linguistics with a deep understanding of emotional nuances in conversations and written word.

You will receive a JSON input representing a conversation between Speaker A and Speaker B. Each message in the conversation includes the following fields:

"speaker": Indicates whether the speaker is A or B. "message": The content of the conversation. The JSON also contains a "next_sentence" that you must analyze the emotional content of. Your task is to:

- 1) Analyze the "next_sentence" and identify the most appropriate emotion(s) from the provided list, considering the context of the entire conversation up to that point.
- 2) Assign a "confidence_score" to each selected emotion (ranging from 0 to 1), indicating the intensity of that emotion.
- 3) Provide a brief explanation for each emotion chosen, taking into account the emotional trajectory from the preceding messages.

Allowed List of Emotions: [admiration, adoration, aesthetic appreciation, amusement, anger, awe, awkwardness, boredom, calmness, confusion, contempt, desire, craving, disappointment, disgust, empathic pain, embarrassment-shame, envy, excitement, fear, gratitude, grief, guilt,

horror, interest-curiosity, joy, nervousness-anxiety, nostalgia, pride, relief, neutral, realization, sadness, satisfaction, surprise, sympathy-caring, triumph, annoyance, remorse]

Important: Only choose emotions from the above list. Do NOT select any emotions outside of this list.

Task Requirements:

- Contextual Understanding: You must consider all previous dialog parts and their corresponding emotions to understand the context before analyzing the "next_sentence".
- Emotion Selection: Select all emotions from the list that accurately represent the emotional content of the "next_sentence". If the emotions present in the text don't match those in the list, pick the closest one.
- Confidence Scoring: For each emotion selected, assign a confidence score between 0 and 1 that reflects how certain you are of your choice. If the emotional content is ambiguous, assign a lower confidence score.
- Explanation: Provide a clear and concise explanation for each emotion chosen, referencing relevant parts of the "next_sentence" and the conversation context.

Output Format: Your response must be a JSON object with a key "emotions" containing a list of emotion objects. Each emotion object should have the following fields:

- "emotion": The name of the emotion.
- "confidence_score": The intensity score (0-1).
- "explanation": The reasoning behind selecting this emotion.

Example Input: "conversation": ["speaker": "A", "message": "When's your birthday?", "emotion": "interest-curiosity", "confidence_score": 0.8, "explanation": "Speaker A expresses curiosity in finding out the other person's birthday", "speaker": "B", "message": "It's just around the corner!", "emotion": "excitement", "confidence_score": 0.7, "explanation": "Speaker B responds to Speaker A's question with a sense of enthusiasm, evident by the exclamation mark. Additionally, birthdays are associated with excitement so the emotions are of that nature."], "next_sentence": "speaker": "A", "message": "Can't wait to celebrate with you!" Example Output: "emotions": ["emotion": "joy", "confidence_score": 0.9, "explanation": "The phrase 'Can't wait to celebrate with you!' indicates a high level of happiness and excitement about the upcoming celebration, aligning with the emotion of joy." , "emotion": "excitement", "confidence_score": 0.85, "explanation": "The anticipation expressed by 'Can't wait' reflects a strong sense of excitement regarding the event. This also follows the excitement expressed by Speaker A in the previous message, reflecting the infectious nature of such emotions"]

Instructions:

- Maintain Consistent Formatting: Adhere to the JSON format with correct field names and structure to facilitate seamless integration with downstream processes.
- Restrict Emotion Selection: Only use emotions from the provided list. Avoid introducing or inferring emotions not listed. Some parts of dialog, like normal-everyday conversations, might not have explicit emotional content. Use neutral in those cases.
- Leverage Contextual Information: Utilize the entire conversation history, including previous emotions and their confidence scores, to inform your emotion detection in the "next_sentence". Always have thought-out reasoning for your assumptions.

- **Comprehensive Explanations:** Your explanations should be insightful, explaining not only why an emotion was chosen but how it fits into the broader emotional flow of the conversation.

Some parts of dialog, like normal-everyday conversations, might not have explicit emotional content. Use neutral in those cases.

Further instructions improvements: Fine grained instruction guidelines multiple input-output examples

Στην τελική εκδοχή του prompt πληρούνται όλες οι προδιαγραφές που συνίστανται από τα πρωτόκολλα των επιστημονικών συντονιστών των μοντέλων, δηλαδή:

- Επίτευξη chain of thought με την απαίτηση του reasoning
- Ξεκάθαρες και αναλυτικές οδηγίες
- Παραδείγματα εισόδου-εξόδου
- Παροχή reference text
- Υιοθέτηση μίας προσωπικότητας¹¹

Fine-Tuning

Στα πλαίσια του πειράματος, παρουσιάζουμε μία fine-tuned εκδοχή του gpt 4o, εκπαιδευμένη σε ένα κομμάτι του συνόλου δεδομένων μας. Συγκεκριμένα, για την εκπαίδευση του μοντέλου έγινε ένα 70% training - 10% validation - 20% testing split με στρωματοποιημένη δειγματοληψία ώστε να εγγυηθεί η ομοιόμορφη κατανομή των συναισθημάτων σε κάθε σύνολο(set).

Σύνολο	Μέρη
Training set	218
Validation set	32
Test set	63

Πίνακας 5.10: Δείγματα ανά σύνολο

Όσο αναφορά τις παραμέτρους εκπαίδευσης, έχοντας επίγνωση της μικρής έκτασης του συνόλου δεδομένων, ύστερα από πειραματισμό για την εύρεση του ιδανικού συνδυασμού batch size, epochs και LR multiplier, καταλήξαμε:

- **Epochs: 8**

Η επιλογή αυτού του μεγάλου αριθμού εποχών, σε συνεργασία με τις υπόλοιπες παραμέτρους οι οποίες κατεύναζαν τον κίνδυνο για **overfitting**, προσέφερε επαρκή χρόνο

¹¹<https://platform.openai.com/docs/guides/prompt-engineering/six-strategies-for-getting-better-results>

εκπαίδευσης στο μοντέλο να μάθει χρήσιμα μοτίβα. Σε άλλες προσπάθειες εκπαίδευσης με χαμηλότερο αριθμό εποχών η επίδοση του μοντέλου μειωνόταν, πιθανότατα λόγω underfitting.

- **Batch size: 16**

Με αυτό το μέγεθος παρτίδας το μοντέλο ενημερώνει τα βάρη του με ισορροπημένο ρυθμό. Καθώς τα μικρά μεγέθη παρτίδας σε datasets περιορισμένου μεγέθους μπορεί να οδηγήσουν σε αστάθεια, ένας μεγαλύτερος αριθμός, στην έκταση των 8 εποχών, εισάγει σταθερότητα.

- **Learning rate multiplier: 0.25**

Ο χαμηλός δείκτης ρυθμού μάθησης ήταν κομβικός για την εκπαίδευση καθώς το μοντέλο έκανε μικρές και ελεγχόμενες τροποποιήσεις στα βάρη του κατά την διάρκεια του μεγάλου αριθμού εποχών.

Στο testing phase απέδειχθηκε πως αυτή η παραμετροποίηση επέφερε ελαχιστοποίηση του overfitting και σε καλύτερη γενίκευση σε καινούρια δεδομένα. Καθώς έπρεπε να χειριστούμε μόλις 218 δείγματα εκπαίδευσης, με μοντέλο χρειάστηκε να εκτεθεί στα δεδομένα επανειλημμένα, κάτι που εγγυήθηκε η αντίστοιχη ρύθμιση των εποχών. Συνολικά, είχαμε 76.326 trained tokens, Training loss: 0.2285 και Full validation loss: 0.4607 (Σχήμα 5.5).

5.4 Αποτελέσματα πειραμάτων

5.4.1 Prompt-based Προσαρμογή

Model	V1 Correct	V2 Correct	V3 Correct	Total	V1 %	V2 %	V3 %
gpt-4o-2024-08-06	137	141	151	313	43.77	45.05	48.24
claude-3-5-sonnet-20240620	129	133	144	313	41.21	42.49	46.01
llama 3	100	106	116	313	31.95	33.87	37.06


Πίνακας 5.11: Ποσοστά ακρίβειας κάθε μοντέλου

Model	V1 to V2 Improvement%	V2 to V3 Improvement%
gpt-4o-2024-08-06	2.92	7.08
claude-3-5-sonnet-20240620	3.11	8.28
llama 3	6.01	9.42

Πίνακας 5.12: Ποσοστό βελτίωσης ανά prompt (improvement margin)

Διαπιστώνουμε λοιπόν πως, συνολικά, όλα τα μοντέλα έχουν χαμηλή επίδοση, με κανένα από αυτά να ξεπερνά το 50% .

Είναι αξιόλογο ωστόσο πως η αύξηση της επίδοσης βελτίωση του prompt σε όλα τα μοντέλα. Παρατηρείται συγκεκριμένη ευαισθησία των LLMs στις αυστηρές προδιαγραφές του



Σχήμα 5.5: Loss plots στην εκπαίδευση, με πράσινο συμβολίζεται το Training Loss ενώ με μωβ το Validation Loss


3ου prompt, επιβεβαιώνοντας πως η τήρηση αυτών των κανόνων είναι οδηγός για την αποτελεσματικότερη επικοινωνία με αυτά τα γλωσσικά μοντέλα.

Συνολικά, την συγκριτικά καλύτερη επίδοση έχει το gpt-4o-2024-08-06 με την χρήση του 3ου prompt, δίνοντας 48.24% ακρίβεια.

5.4.2 Σύγκριση prompt engineering - fine tuning

Το πείραμα συνοψίστηκε με την αξιολόγηση της fine-tuned εκδοχής του gpt 4o. Με εκπαίδευση που αποσκοπεί στην ελαχιστοποίηση του overfitting, το εν λόγω μοντέλο παρουσίασε την καλύτερη έως τώρα επίδοση με 0.5479% ακρίβεια.

Η ανάλυση των αποτελεσμάτων για τα τρία LLMs (GPT-4o-2024-08-06, Claude-3.5-Sonnet-20240620, LLaMA 3) καταδεικνύει ότι οι τεχνικές fine-tuning και prompt-tuning βελτιώνουν αισθητά την απόδοση των μοντέλων στην αναγνώριση συναισθημάτων σε διαλόγους. Συγκεκριμένα, το GPT-4o πέτυχε το υψηλότερο ποσοστό σωστής αναγνώρισης με 48.24% σε σχέση με τα υπόλοιπα μοντέλα, ενώ το Claude Sonnet 3.5 ακολούθησε με ποσοστό 46.01%. Το LLaMA 3, παρόλο που είχε χαμηλότερη απόδοση (37.06%), έδειξε βελτιώσεις



Σχήμα 5.6: Σύγκριση απόδοσης fine tuned GPT με Prompt tuning, ο κάθετος άξονας αντιπροσωπεύει το ποσοστό επιτυχίας και ο οριζόντιος τα υπο-αξιολόγηση μοντέλα

κατά τη διάρκεια της διαδικασίας προσαρμογής από prompt σε prompt, αποδεικνύοντας πως η τήρηση των αναφερόμενων προδιαγραφών επιφέρει βελτίωση της επίδοσης.

Αξιοσημείωτο είναι ότι το fine-tuned μοντέλο παρουσίασε τη βέλτιστη απόδοση με σκορ 0.5479%, υπογραμμίζοντας την αποτελεσματικότητα της διαδικασίας fine-tuning για τη βελτίωση της ακρίβειας. Αν και τα αποτελέσματα του prompt-tuning παρουσίασαν βελτιώσεις, η απόδοση των μοντέλων παρέμεινε μέτρια και δεν ξεπέρασε το 50%, με εξαίρεση το fine-tuned μοντέλο. Αυτό υποδηλώνει ότι για να επιτευχθεί μεγαλύτερη ακρίβεια στην αναγνώριση συναισθημάτων, η διαδικασία προσαρμογής μέσω fine-tuning προσφέρει σημαντικά οφέλη έναντι του prompt-tuning, παρόλο που η εκπαίδευση του έγινε σε ένα σχετικά μικρό δείγμα.

Συνολικά, η έρευνα επιβεβαιώνει τη σημασία της προσαρμογής των μεγάλων γλωσσικών μοντέλων στην αναγνώριση συναισθημάτων, ενώ υποδεικνύει ότι υπάρχει περιθώριο περαιτέρω βελτιστοποίησης, ειδικά στον τομέα της βελτίωσης των τεχνικών fine-tuning για την καλύτερη ανίχνευση συναισθημάτων σε διαλόγους χειμένου.

Συμπεράσματα και Μελλοντικές επεκτάσεις

6.1 Συμπεράσματα

Η ανθρωπότητα διανύει μία εξαιρετικά ευερέθιστη περίοδο, με τις επίκαιρες τεχνολογίες, όπως είναι LLMs, να αποκτούν συνεχώς όλο και πιο εντυπωσιακές δυνατότητες. Παρ'όλα αυτά, μπορούμε να διαπιστώσουμε από τα αποτελέσματα του πειράματος πως αυτά τα μοντέλα ακόμη υστερούν σε κάποιες βασικές λειτουργίες. Συμπερασματικά:

- Η γλωσσική και σημασιολογική κατανόηση που έχουν αυτά τα μοντέλα είναι μία σπουδαία επιστημονική επίτευξη, αλλά, όσο αφορά την αναγνώριση συναισθηματικών καταστάσεων, δεν έχει φτάσει ακόμη σε αξιόπιστο επίπεδο. Με επίγνωση της δυσκολίας αυτού του έργου που -καθό βασισμένο στην υποκειμενικότητα- είναι εξαιρετικά δύσκολο να ποσοτικοποιηθεί με μαθηματικό τρόπο, η συντονισμένη προσπάθεια βελτίωσης αυτής της διάστασης των ικανοτήτων των LLMs εξακολουθεί να αποτελεί ένα σημαντικό εγχείρημα.
- Παρά τους αναφερόμενους περιορισμούς, διαπιστώνεται πως οι τεχνικές προσαρμογής προσφέρουν μία αδιαπραγμάτευτη βελτίωση στις ικανότητες των γλωσσικών μοντέλων που εξετάστηκαν. Η τήρηση των προδιαγραφών για την αποδοτική αλληλεπίδραση με τα γλωσσικά μοντέλα είναι κλειδί για την πλήρη αξιοποίηση τους.
- Τα LLMs δείχνουν μία συχνή τάση για hallucinations όταν τους ζητείται να λύσουν προβλήματα κατηγοριοποίησης. Κατά την διάρκεια του πειράματος, το φαινόμενο απόκλισης και μη-πιστότητας στις προδιαγραφές των prompts παρατηρούνταν διαρκώς, κάτι που έχει διαπιστωθεί και από άλλους ερευνητές [3]. Σημειώνεται συγκεκριμένα πως το γλωσσικό μοντέλο LLaMA που είχε την χαμηλότερη επίδοση, στην πλειοψηφία των

απαντήσεων του στο prompt 2 επέστραψε συναίσθημα που δεν άνηκε στην προτεινόμενη λίστα, αλλά εισήγαγει άλλα συναισθήματα. Οι τεκμηριώσεις του ωστόσο παρέμεναν ακέραιες και λογικές, υστερούσε μονάχα στην τήρηση της λίστας των συναισθημάτων. Αυτά δεν γινόντουσαν αποδεχτά καθώς δεν τηρούσαν τις παραδοχές συναισθηματικής ταξινόμιας που θέσαμε στα πλαίσια αυτής της μελέτης.

- Το fine tuning, παρά σε ένα, ομολογουμένως, μικρό σε έκταση corpus προσέφερε τα πιο αξιόλογα αποτελέσματα και αποτελεί την πιο υποσχόμενη μέθοδο προσαρμογής.
- Η ενσωμάτωση του συγκεκριμένου στην είδοσο της κλήσης των γλωσσικών μοντέλων τους προσέφερε ένα πολύ ισχυρό πάτημα για να κάνουν τις προβλέψεις τους πιο έγκυρες. Αξιολόγηση είναι η ικανότητα των υπο-εξέταση μοντέλων να παραπέμψουν σε κάποια αρχική εκφώνηση των ομιλητών για να δικαιολογήσουν την συναισθηματική τους κατάσταση στην τωρινή, υποδυκνεύοντας μία επίγνωση την συναισθηματικής ακολουθίας που λάμβανε χώρα στα πλαίσια ενός διαλόγου.

6.2 Μελλοντικές Επεκτάσεις

Η έρευνα αυτή ανοίγει πολλαπλές προοπτικές για τη βελτίωση της αναγνώρισης συναισθημάτων σε κειμενικούς διαλόγους, με αρκετές κατευθύνσεις για μελλοντική εργασία. Συγκεκριμένα, κρίνεται πως:

- Είναι σημαντική η επένδυση του συνόλου δεδομένων με περισσότερα annotations. Δίνοντας έκταση στο dataset μας, η ποιότητα των τελικών συναισθημάτων θα είχε τον νόμο των μεγάλων αριθμών με το μέρος της το οποίο θα προσέφερε περισσότερη βεβαιότητα στο ground truth του πειράματος. Φιλοδοξούμε λοιπόν για την επέκταση του annotation scheme μας, προσκαλώντας περισσότερους συμμετέχοντες. Η χρήση ενός πιο εκτεταμένου και ποικιλόμορφου συνόλου δεδομένων είναι κρίσιμη για την περαιτέρω βελτίωση της ακρίβειας των μοντέλων. Αποβλέπουμε στην μαζική αύξηση των δειγμάτων σχολιασμού, μέσω χειροκίνητων ή ημι-αυτόματων τεχνικών που θα μπορούσαν να βελτιώσουν τη γενίκευση των μοντέλων και να τα καταστήσουν πιο ικανά στην αναγνώριση των συναισθημάτων. Επιπλέον, η ενσωμάτωση πολυγλωσσικών συνόλων δεδομένων θα μπορούσε να οδηγήσει σε καλύτερη κατανόηση των συναισθημάτων σε ποικίλα γλωσσικά συμφραζόμενα.
- Το fine tuning των λοιπών LLMs κρίνεται επίσης υποσχόμενο εγχείρημα. Υπάρχει περιθώριο για περαιτέρω βελτιστοποίηση μέσω προσαρμογής και ο πειραματισμός με τις δυνατότητες των άλλων μοντέλων είναι ενθουσιαστική προοπτική. Μάλιστα, η ανάπτυξη προηγμένων στρατηγικών fine-tuning, όπως η σταδιακή προσαρμογή σε συγκεκριμένες κατηγορίες συναισθημάτων ή σε πιο εξειδικευμένες συνομιλίες, θα μπορούσε να βελτιώσει την απόδοση των LLMs σε δύσκολες περιπτώσεις συναισθηματικής έκφρασης.
- Η συναισθηματική ταξινόμια της εργασίας προτάθηκε ύστερα από λεπτομερή μελέτη της σχετικής βιβλιογραφίας σε μία προσπάθεια συμβάδισης με την επικαιρότητα στους

εφαπτόμενους τομείς. Αναγνωρίζεται ωστόσο ότι αυτό το εγχείρημα θα γινόταν με μεγαλύτερη διεπιστημονική ακεραιότητα αν ήταν σε πλαίσιο συνεργασίας με μελετητές της Ψυχολογίας και άλλων επιστημονικών πεδίων, ώστε, παρομοίως με τις σχετικές, αναφερόμενες εργασίες, η τελική ταξινομία θα είχε πιστότητα και αποκλειστικότητα στο μέσο του γραπτού λόγου. Προς επίτευξη αυτού του στόχου, αναγνωρίζεται πως ο διεπιστημονικός ερευνητικός συντονισμός που απαιτείται για την πρόταση μίας απόλυτης ταξινομίας βασικών συναισθημάτων που σχετίζονται με τα κείμενα είναι καίριας σημασίας.

- Η αξιολόγηση άλλων υποσχόμενων LLMs όπως αυτά της Mistral AI θα προσέφερε μία πιο ολοκληρωμένη εικόνα της ικανότητας των μεγάλων γλωσσικών μοντέλων στο εν λόγω έργο.
- Τέλος, μια ερευνητικά έγγυρη επέκταση θα ήταν η εξερεύνηση πολυτροπικών δεδομένων. Η συνδυαστική ανάλυση κειμένου με άλλες μορφές δεδομένων, όπως η ομιλία[111] ή οι εκφράσεις του προσώπου, μπορεί να ενισχύσει την ακρίβεια της αναγνώρισης συναισθημάτων. Η μελλοντική έρευνα θα μπορούσε να επικεντρωθεί σε multimodal προσεγγίσεις, όπου οι συναισθηματικές ενδείξεις από πολλαπλά κανάλια μπορούν να αξιοποιηθούν από τα μοντέλα.

Α΄ Παράρτημα

Α΄.1 Πρώτη ενότητα

Ο κώδικας που χρησιμοποιήθηκε για την εργασία παρατίθεται εδώ https://github.com/mamoueli/emo_llm

Βιβλιογραφία

- [1] The claude 3 model family: Opus, sonnet, haiku. χ.χ.
- [2] Francisca Acheampong, Henry Nunoo-Mensah και Wenyu Chen. Comparative analyses of bert, roberta, distilbert, and xlnet for text-based emotion recognition, 2020.
- [3] Vaibhav Adlakha, Parishad BehnamGhader, Xing Han Lu, Nicholas Meade και Siva Reddy. Evaluating correctness and faithfulness of instruction-following models for question answering, 2024.
- [4] Cecilia Ovesdotter Alm, Dan Roth και Richard Sproat. Emotions from text: Machine learning for text-based emotion prediction. Στο *Proceedings of Human Language Technology Conference and Conference on Empirical Methods in Natural Language Processing* Raymond Mooney, Chris Brew, Lee Feng Chien και Katrin Kirchhoff, επιμελητές, σελίδες 579–586, Vancouver, British Columbia, Canada, 2005. Association for Computational Linguistics.
- [5] Nurudin Alvarez-Gonzalez, Andreas Kaltenbrunner και Vicenç Gómez. Uncovering the limits of text-based emotion detection. Στο *Findings of the Association for Computational Linguistics: EMNLP 2021*. Association for Computational Linguistics, 2021.
- [6] Aristotle. Nichomachean ethics. Στο *Nichomachean Ethics, Poetics and Rhetoric, in The Complete Works of Aristotle, vol. 2, 1109bJ*. Barnes, επιμελητής. Princeton: Princeton University Press, 1984b, Summer 2021η έκδοση, 1984.
- [7] Christos Baziotis, Nikos Pelekis και Christos Doukeridis. DataStories at SemEval-2017 task 4: Deep LSTM with attention for message-level and topic-based sentiment analysis. Στο *Proceedings of the 11th International Workshop on Semantic Evaluation (SemEval-2017)* Steven Bethard, Marine Carpuat, Marianna Apidianaki, Saif M. Mohammad, Daniel Cer και David Jurgens, επιμελητές, σελίδες 747–754, Vancouver, Canada, 2017. Association for Computational Linguistics.
- [8] Muhammet Başarslan και Fatih Kayaalp. Mbi-grumconv: A novel multi bi-gru and multi cnn-based deep learning model for social media sentiment analysis. *Journal of Cloud Computing*, 12, 2023.

- [9] Yoshua Bengio, Réjean Ducharme, Pascal Vincent και Christian Janvin. A neural probabilistic language model. *J. Mach. Learn. Res.*, 3(νύλλ):1137–1155, 2003.
- [10] Santosh Kumar Bharti, S Varadhaganapathy, Rajeev Kumar Gupta, Prashant Kumar Shukla, Mohamed Bouye, Simon Karanja Hingaa και Amena Mahmoud. Text-based emotion recognition using deep learning approach. *Computational Intelligence and Neuroscience*, 2022(1):2645381, 2022.
- [11] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever και Dario Amodei. Language models are few-shot learners, 2020.
- [12] Oana Bălan, Gabriela Moise, Livia Petrescu, Alin Moldoveanu, Marius Leordeanu και Florica Moldoveanu. Emotion classification based on biophysical signals and machine learning techniques. *Symmetry*, 12(1), 2020.
- [13] Lea Canales και Patricio Martínez-Barco. Emotion detection from text: A survey. Στο *Proceedings of the workshop on natural language processing in the 5th information systems research working days (JISIC)*, σελίδες 37–43, 2014.
- [14] Izard CE. Emotion theory and research: highlights, unanswered questions, and emerging issues. Στο *Annu Rev Psychol.*, 2009.
- [15] Alexander Clark, Gianluca Giorgolo και Shalom Lappin. Statistical representation of grammaticality judgements: the limits of n-gram models. Στο *Proceedings of the Fourth Annual Workshop on Cognitive Modeling and Computational Linguistics (CMCL)* Vera Demberg και Roger Levy, επιμελητές, σελίδες 28–36, Sofia, Bulgaria, 2013. Association for Computational Linguistics.
- [16] Alan Cowen, Hillary Elfenbein, Petri Laukka και Dacher Keltner. Mapping 24 emotions conveyed by brief human vocalization. *American Psychologist*, 2018.
- [17] Alan Cowen, Petri Laukka, Hillary Elfenbein, Runjing Liu και Dacher Keltner. The primacy of categories in the recognition of 12 emotions in speech prosody across two cultures. *Nature Human Behaviour*, 3:1, 2019.
- [18] Alan S. Cowen, Xia Fang, Disa Sauter και Dacher Keltner. What music makes us feel: At least 13 dimensions organize subjective experiences associated with music across different cultures. *Proceedings of the National Academy of Sciences*, 117(4):1924–1934, 2020.

- [19] Alan S. Cowen και Dacher Keltner. Self-report captures 27 distinct categories of emotion bridged by continuous gradients. *Proceedings of the National Academy of Sciences*, 114(38):E7900–E7909, 2017.
- [20] Alan S. Cowen και Dacher Keltner. What the face displays: Mapping 28 emotions conveyed by naturalistic expression. *The American psychologist*, 2020.
- [21] Sauter D. Tracy J. L. Keltner D Cowen, A. Mapping the passions: Toward a high-dimensional taxonomy of emotional experience and expression. Στο *Psychological science in the public interest : a journal of the American Psychological Society*, 2019.
- [22] Jane Cullum και Ralph Willoughby. Lanczos algorithms for large symmetric eigenvalue computations. vol. i: Theory. *Classics in Applied Mathematics*, I, 2002.
- [23] C Darwin. *The Expression of the Emotions in Man and Animals*. Oxford University Press., 1872.
- [24] Scott Deerwester, Susan T. Dumais, George W. Furnas, Thomas K. Landauer και Richard Harshman. Indexing by latent semantic analysis. *Journal of the American Society for Information Science*, 41(6):391–407, 1990.
- [25] Flor Miriam Plazadel Arco, Alba Curry, Amanda Cercas Curry και Dirk Hovy. Emotion analysis in nlp: Trends, gaps and roadmap for future directions, 2024.
- [26] Dorottya Demszky, Dana Movshovitz-Attias, Jeongwoo Ko, Alan Cowen, Gaurav Nemade και Sujith Ravi. GoEmotions: A dataset of fine-grained emotions. Στο *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics* Dan Jurafsky, Joyce Chai, Natalie Schluter και Joel Tetreault, επιμελητές, σελίδες 4040–4054, Online, 2020. Association for Computational Linguistics.
- [27] Jacob Devlin, Ming Wei Chang, Kenton Lee και Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding, 2019.
- [28] Elisavet Douka, Isidoros Perikos και Ioannis Hatzilygeroudis. Sentiment analysis with the use of transformers and bert. Στο *2023 14th International Conference on Information, Intelligence, Systems Applications (IISA)*, σελίδες 1–8, 2023.
- [29] Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad Al-Dahle, Aiesha Letman, Akhil Mathur, Alan Schelten, Amy Yang, Angela Fan, Anirudh Goyal, Anthony Hartshorn, Aobo Yang, Archi Mitra, Archie Sravankumar, Artem Korenev, Arthur Hinsvark, Arun Rao, Aston Zhang, Aurelien Rodriguez, Austen Gregerson, Ava Spataru, Baptiste Roziere, Bethany Biron, Binh Tang, Bobbie Chern, Charlotte Caucheteux, Chaya Nayak, Chloe Bi, Chris Marra, Chris McConnell, Christian Keller, Christophe Touret, Chunyang Wu, Corinne Wong, Cristian Canton Ferrer, Cyrus Nikolaidis, Damien Allonsius, Daniel Song, Danielle Pintz, Danny Livshits, David Esiobu, Dhruv Choudhary, Dhruv Mahajan, Diego

Garcia-Olano, Diego Perino, Dieuwke Hupkes, Egor Lakomkin, Ehab AlBadawy, Elna Lobanova, Emily Dinan, Eric Michael Smith, Filip Radenovic, Frank Zhang, Gabriel Synnaeve, Gabrielle Lee, Georgia Lewis Anderson, Graeme Nail, Gregoire Mialon, Guan Pang, Guillem Cucurell, Hailey Nguyen, Hannah Korevaar, Hu Xu, Hugo Touvron, Iliyan Zarov, Imanol Arrieta Ibarra, Isabel Kloumann, Ishan Misra, Ivan Evtimov, Jade Copet, Jaewon Lee, Jan Geffert, Jana Vranes, Jason Park, Jay Mahadeokar, Jeet Shah, Jelmervan der Linde, Jennifer Billock, Jenny Hong, Jenya Lee, Jeremy Fu, Jianfeng Chi, Jianyu Huang, Jiawen Liu, Jie Wang, Jiecao Yu, Joanna Bitton, Joe Spisak, Jongsoo Park, Joseph Rocca, Joshua Johnstun, Joshua Saxe, Junteng Jia, Kalyan Vasuden Alwala, Kartikeya Upasani, Kate Plawiak, Ke Li, Kenneth Heafield, Kevin Stone, Khalid El-Arini, Krithika Iyer, Kshitiz Malik, Kuenley Chiu, Kunal Bhalla, Lauren Rantala-Yeary, Laurens van der Maaten, Lawrence Chen, Liang Tan, Liz Jenkins, Louis Martin, Lovish Madaan, Lubo Malo, Lukas Blecher, Lukas Landzaat, Lukede Oliveira, Madeline Muzzi, Mahesh Pasupuleti, Mannat Singh, Manohar Paluri, Marcin Kardas, Mathew Oldham, Mathieu Rita, Maya Pavlova, Melanie Kambadur, Mike Lewis, Min Si, Mitesh Kumar Singh, Mona Hassan, Naman Goyal, Narjes Torabi, Nikolay Bashlykov, Nikolay Bogoychev, Niladri Chatterji, Olivier Duchenne, Onur Çelebi, Patrick Alrassy, Pengchuan Zhang, Pengwei Li, Petar Vasic, Peter Weng, Prajjwal Bhargava, Pratik Dubal, Praveen Krishnan, Punit Singh Koura, Puxin Xu, Qing He, Qingxiao Dong, Ragavan Srinivasan, Raj Ganapathy, Ramon Calderer, Ricardo Silveira Cabral, Robert Stojnic, Roberta Raileanu, Rohit Girdhar, Rohit Patel, Romain Sauvestre, Ronnie Polidoro, Roshan Sumbaly, Ross Taylor, Ruan Silva, Rui Hou, Rui Wang, Saghar Hosseini, Sahana Chennabasappa, Sanjay Singh, Sean Bell, Seohyun Sonia Kim, Sergey Edunov, Shaoliang Nie, Sharan Narang, Sharath Raparthi, Sheng Shen, Shengye Wan, Shrutit Bhosale, Shun Zhang, Simon Vandenhenne, Soumya Batra, Spencer Whitman, Sten Sootla, Stephane Collot, Suchin Gururangan, Sydney Borodinsky, Tamar Herman, Tara Fowler, Tarek Sheasha, Thomas Georgiou, Thomas Scialom, Tobias Speckbacher, Todor Mihaylov, Tong Xiao, Ujjwal Karn, Vedanuj Goswami, Vibhor Gupta, Vignesh Ramanathan, Viktor Kerkez, Vincent Gonguet, Virginie Do, Vish Vogeti, Vladan Petrovic, Weiwei Chu, Wenhan Xiong, Wenyan Fu, Whitney Meers, Xavier Martinet, Xiaodong Wang, Xiaoqing Ellen Tan, Xinfeng Xie, Xuchao Jia, Xuewei Wang, Yaelle Goldschlag, Yashesh Gaur, Yasmine Babaei, Yi Wen, Yiwen Song, Yuchen Zhang, Yue Li, Yuning Mao, Zacharie Delpierre Coudert, Zheng Yan, Zhengxing Chen, Zoe Papakipos, Aaditya Singh, Aaron Grattafiori, Abha Jain, Adam Kelsey, Adam Shajnfeld, Adithya Gangidi, Adolfo Victoria, Ahuva Goldstand, Ajay Menon, Ajay Sharma, Alex Boesenberg, Alex Vaughan, Alexei Baevski, Allie Feinstein, Amanda Kallet, Amit Sangani, Anam Yunus, Andrei Lupu, Andres Alvarado, Andrew Caples, Andrew Gu, Andrew Ho, Andrew Poulton, Andrew Ryan, Ankit Ramchandani, Annie Franco, Aparajita Saraf, Arkabandhu Chowdhury, Ashley Gabriel, Ashwin Bharambe, Assaf Eisenman, Azadeh Yazdan, Beau James, Ben

Maurer, Benjamin Leonhardi, Bernie Huang, Beth Loyd, Beto De Paola, Bhargavi Paranjape, Bing Liu, Bo Wu, Boyu Ni, Braden Hancock, Bram Wasti, Brandon Spence, Brani Stojkovic, Brian Gamido, Britt Montalvo, Carl Parker, Carly Burton, Catalina Mejia, Changhan Wang, Changkyu Kim, Chao Zhou, Chester Hu, Ching Hsiang Chu, Chris Cai, Chris Tindal, Christoph Feichtenhofer, Damon Civin, Dana Beaty, Daniel Kreymer, Daniel Li, Danny Wyatt, David Adkins, David Xu, Davide Testuggine, Delia David, Devi Parikh, Diana Liskovich, Didem Foss, Dingkang Wang, Duc Le, Dustin Holland, Edward Dowling, Eissa Jamil, Elaine Montgomery, Eleonora Presani, Emily Hahn, Emily Wood, Erik Brinkman, Esteban Arcaute, Evan Dunbar, Evan Smothers, Fei Sun, Felix Kreuk, Feng Tian, Firat Ozgenel, Francesco Caggioni, Francisco Guzmán, Frank Kanayet, Frank Seide, Gabriela Medina Florez, Gabriella Schwarz, Gada Badeer, Georgia Swee, Gil Halpern, Govind Thattai, Grant Herman, Grigory Sizov, Guangyi, Zhang, Guna Lakshminarayanan, Hamid Shojanazeri, Han Zou, Hannah Wang, Hanwen Zha, Haroun Habeeb, Harrison Rudolph, Helen Suk, Henry Aspegren, Hunter Goldman, Ibrahim Damla, Igor Molybog, Igor Tufanov, Irina Elena Veliche, Itai Gat, Jake Weissman, James Geboski, James Kohli, Japhet Asher, Jean Baptiste Gaya, Jeff Marcus, Jeff Tang, Jennifer Chan, Jenny Zhen, Jeremy Reizenstein, Jeremy Teboul, Jessica Zhong, Jian Jin, Jingyi Yang, Joe Cummings, Jon Carvill, Jon Shepard, Jonathan McPhie, Jonathan Torres, Josh Ginsburg, Junjie Wang, Kai Wu, Kam Hou U, Karan Saxena, Karthik Prasad, Kartikay Khandelwal, Katayoun Zand, Kathy Matosich, Kaushik Veeraghavan, Kelly Michelena, Keqian Li, Kun Huang, Kunal Chawla, Kushal Lakhota, Kyle Huang, Lailin Chen, Lakshya Garg, Lavender A, Leandro Silva, Lee Bell, Lei Zhang, Liangpeng Guo, Licheng Yu, Liron Moshkovich, Luca Wehrstedt, Madian Khabisa, Manav Avalani, Manish Bhatt, Maria Tsimpoukelli, Martynas Mankus, Matan Hasson, Matthew Lennie, Matthias Reso, Maxim Groshev, Maxim Naumov, Maya Lathi, Meghan Keneally, Michael L. Seltzer, Michal Valko, Michelle Restrepo, Mihir Patel, Mik Vyatskov, Mikayel Samvelyan, Mike Clark, Mike Macey, Mike Wang, Miquel Jubert Hermoso, Mo Metanat, Mohammad Rastegari, Munish Bansal, Nandhini Santhanam, Natascha Parks, Natasha White, Navyata Bawa, Nayan Singhal, Nick Egebo, Nicolas Usunier, Nikolay Pavlovich Laptev, Ning Dong, Ning Zhang, Norman Cheng, Oleg Chernoguz, Olivia Hart, Omkar Salpekar, Ozlem Kalinli, Parkin Kent, Parth Parekh, Paul Saab, Pavan Balaji, Pedro Rittner, Philip Bontrager, Pierre Roux, Piotr Dollar, Polina Zvyagina, Prashant Ratanchandani, Pritish Yuvraj, Qian Liang, Rachad Alao, Rachel Rodriguez, Rafi Ayub, Raghotham Murthy, Raghu Nayani, Rahul Mitra, Raymond Li, Rebekkah Hogan, Robin Battey, Rocky Wang, Rohan Maheswari, Russ Howes, Ruty Rinott, Sai Jayesh Bondu, Samyak Datta, Sara Chugh, Sara Hunt, Sargun Dhillon, Sasha Sidorov, Satadru Pan, Saurabh Verma, Seiji Yamamoto, Sharadh Ramaswamy, Shaun Lindsay, Shaun Lindsay, Sheng Feng, Shenghao Lin, Shengxin Cindy Zha, Shiva Shankar, Shuqiang Zhang, Shuqiang Zhang, Sinong Wang, Sneha Agarwal, Soji Sajuyigbe, Soumith

- Chintala, Stephanie Max, Stephen Chen, Steve Kehoe, Steve Satterfield, Sudarshan Govindaprasad, Sumit Gupta, Sungmin Cho, Sunny Virk, Suraj Subramanian, Sy Choudhury, Sydney Goldman, Tal Remez, Tamar Glaser, Tamara Best, Thilo Kohler, Thomas Robinson, Tianhe Li, Tianjun Zhang, Tim Matthews, Timothy Chou, Tzook Shaked, Varun Vontimitta, Victoria Ajayi, Victoria Montanez, Vijai Mohan, Vinay Satish Kumar, Vishal Mangla, Vitor Albiero, Vlad Ionescu, Vlad Poenaru, Vlad Tiberiu Mihailescu, Vladimir Ivanov, Wei Li, Wenchen Wang, Wenwen Jiang, Wes Bouaziz, Will Constable, Xiaocheng Tang, Xiaofang Wang, Xiaojian Wu, Xiaolan Wang, Xide Xia, Xilun Wu, Xinbo Gao, Yanjun Chen, Ye Hu, Ye Jia, Ye Qi, Yenda Li, Yilin Zhang, Ying Zhang, Yossi Adi, Youngjin Nam, Yu, Wang, Yuchen Hao, Yundi Qian, Yuzi He, Zach Rait, Zachary DeVito, Zef Rosnbrick, Zhaoduo Wen, Zhenyu Yang και Zhiwei Zhao. The llama 3 herd of models, 2024.
- [30] Paul Ekman. An argument for basic emotions. *Cognition & Emotion*, 6:169–200, 1992.
- [31] Kawin Ethayarajh. How contextual are contextualized word representations? Comparing the geometry of BERT, ELMo, and GPT-2 embeddings. Στο *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)* Kentaro Inui, Jing Jiang, Vincent Ng και Xiaojun Wan, επιμελητές, σελίδες 55–65, Hong Kong, China, 2019. Association for Computational Linguistics.
- [32] Antonio Fernández-Caballero, Arturo Martínez-Rodrigo, José Manuel Pastor, José Carlos Castillo, Elena Lozano-Monazor, María T. López, Roberto Zangróniz, José Miguel Latorre και Alicia Fernández-Sotos. Smart environment architecture for emotion detection and regulation. *Journal of Biomedical Informatics*, 64:55–73, 2016.
- [33] Lorenzo Ferrone και Fabio Massimo Zanzotto. Symbolic, distributed, and distributional representations for natural language processing in the era of deep learning: A survey. *Frontiers in Robotics and AI*, 6, 2020.
- [34] Deepanway Ghosal, Navonil Majumder, Soujanya Poria, Niyati Chhaya και Alexander Gelbukh. DialogueGCN: A graph convolutional neural network for emotion recognition in conversation. Στο *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)* Kentaro Inui, Jing Jiang, Vincent Ng και Xiaojun Wan, επιμελητές, σελίδες 154–164, Hong Kong, China, 2019. Association for Computational Linguistics.
- [35] Zhinan Gou και Yan Li. Integrating bert embeddings and bilstm for emotion analysis of dialogue. *Computational Intelligence and Neuroscience*, 2023, 2023.
- [36] Khoshgoftaar T.M. Hancock, J.T. Survey on categorical data for neural networks. Στο *J Big Data* 7, 28, 2020.

- [37] Xu Han, Weilin Zhao, Ning Ding, Zhiyuan Liu και Maosong Sun. Ptr: Prompt tuning with rules for text classification, 2021.
- [38] Thibaut F. Hoehe MR. Going digital: how technology use may influence human brains and behavior, 2020.
- [39] Neil Houlsby, Andrei Giurgiu, Stanislaw Jastrzebski, Bruna Morrone, Quentinde Laroussilhe, Andrea Gesmundo, Mona Attariyan και Sylvain Gelly. Parameter-efficient transfer learning for nlp, 2019.
- [40] Jeremy Howard και Sebastian Ruder. Universal language model fine-tuning for text classification, 2018.
- [41] Yen Hao Huang, Ssu Rui Lee, Mau Yun Ma, Yi Hsin Chen, Ya Wen Yu και Yi Shin Chen. Emotionx-idea: Emotion bert – an affectional model for conversation, 2019.
- [42] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, Lu Wang και Weizhu Chen. Lora: Low-rank adaptation of large language models, 2021.
- [43] Zhengbao Jiang, Frank F. Xu, Jun Araki και Graham Neubig. How can we know what language models know? *Transactions of the Association for Computational Linguistics*, 8:423–438, 2020.
- [44] K. Jones. A statistical interpretation of term specificity in retrieval. *Journal of Documentation*, 60:493–502, 2004.
- [45] Manju Lata Joshi και Nehal Kanoongo. Depression detection using emotional artificial intelligence and machine learning: A closer review. *Materials Today: Proceedings*, 58:217–226, 2022.
- [46] Daniel Jurafsky και James H. Martin. *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models*. Prentice Hall PTR, 2024.
- [47] Spyridon Kardakis, Isidoros Perikos, Foteini Grivokostopoulou και Michael Paraskevas. Emotion recognition using deep learning techniques and word embeddings. Στο *2021 IEEE/ACIS 6th International Conference on Big Data, Cloud Computing, and Data Science (BCD)*, σελίδες 31–36, 2021.
- [48] Simon Kemp. Digital 2024 april global statshot report, χ.χ.
- [49] Koli A. Khatte K. et al Khurana, D. Natural language processing: state of the art, current trends and challenges. Στο *Multimed Tools Appl* 82, 3713–3744, 2023.
- [50] Taewoon Kim και Piek Vossen. Emoberta: Speaker-aware emotion recognition in conversation with roberta. *CoRR*, αβς/2108.12009, 2021.

- [51] L. Knockaert, B. De Backer και D. De Zutter. Svd compression, unitary transforms, and computational complexity. *IEEE Transactions on Signal Processing*, 47(10):2724–2729, 1999.
- [52] Sheetal Kusal, Shruti Patil, Jyoti Choudrie, Ketan Kotecha, Deepali Vora και Ilias Pappas. A review on text-based emotion detection – techniques, applications, datasets, and future directions, 2022.
- [53] Sheetal Kusal, Shruti Patil, Ketan Kotecha, Rajanikanth Aluvalu και Vijayakumar Varadarajan. Ai based emotion detection for textual big data: Techniques and contribution. *Big Data and Cognitive Computing*, 5(3), 2021.
- [54] Matthew J. Lavin. Analyzing documents with tf-idf, 2019.
- [55] Brian Lester, Rami Al-Rfou και Noah Constant. The power of scale for parameter-efficient prompt tuning, 2021.
- [56] Jingye Li, Donghong Ji, Fei Li, Meishan Zhang και Yijiang Liu. HiTrans: A transformer-based context- and speaker-sensitive model for emotion detection in conversations. Στο *Proceedings of the 28th International Conference on Computational Linguistics* Donia Scott, Nuria Bel και Chengqing Zong, επιμελητές, σελίδες 4190–4200, Barcelona, Spain (Online), 2020. International Committee on Computational Linguistics.
- [57] Pengfei Liu, Weizhe Yuan, Jinlan Fu, Zhengbao Jiang, Hiroaki Hayashi και Graham Neubig. Pre-train, prompt, and predict: A systematic survey of prompting methods in natural language processing, 2021.
- [58] Xiao Liu, Yanan Zheng, Zhengxiao Du, Ming Ding, Yujie Qian, Zhilin Yang και Jie Tang. Gpt understands, too, 2023.
- [59] Zhiwei Liu, Kailai Yang, Qianqian Xie, Tianlin Zhang και Sophia Ananiadou. Emollms: A series of emotional large language models and annotation tools for comprehensive affective analysis. Στο *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, KDD '24, σελίδα 5487–5496, New York, NY, USA, 2024. Association for Computing Machinery.
- [60] Yanran Li, Hui Su, Xiaoyu Shen, Wenjie Li, Ziqiang Cao και Shuzi Niu. Dailydialog: A manually labelled multi-turn dialogue dataset, 2017.
- [61] H. P. Luhn. A statistical approach to mechanized encoding and searching of literary information. *IBM Journal of Research and Development*, 1(4):309–317, 1957.
- [62] Navonil Majumder, Soujanya Poria, Devamanyu Hazarika, Rada Mihalcea, Alexander Gelbukh και Erik Cambria. Dialoguernn: An attentive rnn for emotion detection in conversations, 2019.

- [63] Christopher D. Manning, Prabhakar Raghavan και Hinrich Schütze. *Introduction to Information Retrieval*. Cambridge University Press, 2008.
- [64] Hardik Meisheri και Lipika Dey. TCS research at SemEval-2018 task 1: Learning robust representations using multi-attention architecture. Στο *Proceedings of the 12th International Workshop on Semantic Evaluation* Marianna Apidianaki, Saif M. Mohammad, Jonathan May, Ekaterina Shutova, Steven Bethard και Marine Carpuat, επιμελητές, σελίδες 291–299, New Orleans, Louisiana, 2018. Association for Computational Linguistics.
- [65] Tomas Mikolov, Kai Chen, Greg Corrado και Jeffrey Dean. Efficient estimation of word representations in vector space, 2013.
- [66] Tomáš Mikolov, Martin Karafiát, Lukáš Burget, Jan Černocký και Sanjeev Khudanpur. Recurrent neural network based language model. Στο *Interspeech 2010*, σελίδες 1045–1048, 2010.
- [67] Tomáš Mikolov, Stefan Kombrink, Lukáš Burget, Jan Černocký και Sanjeev Khudanpur. Extensions of recurrent neural network language model. Στο *2011 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, σελίδες 5528–5531, 2011.
- [68] Shervin Minaee, Nal Kalchbrenner, Erik Cambria, Narjes Nikzad, Meysam Chenaughlu και Jianfeng Gao. Deep learning based text classification: A comprehensive review, 2021.
- [69] Muhammad Raza Naqvi. Emotion detection of contextual text using deep learning. 2020.
- [70] Usman Naseem, Imran Razzak, Shah Khalid Khan και Mukesh Prasad. A comprehensive survey on word representation models: From classical to state-of-the-art word representation language models, 2020.
- [71] Usman Naseem, Imran Razzak, Shah Khalid Khan και Mukesh Prasad. A comprehensive survey on word representation models: From classical to state-of-the-art word representation language models, 2020.
- [72] OpenAI, Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altschmidt, Sam Altman, Shyamal Anadkat, Red Avila, Igor Babuschkin, Suchir Balaji, Valerie Balcom, Paul Baltescu, Haiming Bao, Mohammad Bavarian, Jeff Belgum, Irwan Bello, Jake Berdine, Gabriel Bernadett-Shapiro, Christopher Berner, Lenny Bogdonoff, Oleg Boiko, Madelaine Boyd, Anna Luisa Brakman, Greg Brockman, Tim Brooks, Miles Brundage, Kevin Button, Trevor Cai, Rosie Campbell, Andrew Cann, Brittany Carey, Chelsea Carlson, Rory Carmichael, Brooke Chan, Che Chang, Fotis Chantzis, Derek

Chen, Sully Chen, Ruby Chen, Jason Chen, Mark Chen, Ben Chess, Chester Cho, Casey Chu, Hyung Won Chung, Dave Cummings, Jeremiah Currier, Yunxing Dai, Cory Decareaux, Thomas Degry, Noah Deutsch, Damien Deville, Arka Dhar, David Dohan, Steve Dowling, Sheila Dunning, Adrien Ecoffet, Atty Eleti, Tyna Eloundou, David Farhi, Liam Fedus, Niko Felix, Simón Posada Fishman, Juston Forte, Isabella Fulford, Leo Gao, Elie Georges, Christian Gibson, Vik Goel, Tarun Gogineni, Gabriel Goh, Rapha Gontijo-Lopes, Jonathan Gordon, Morgan Grafstein, Scott Gray, Ryan Greene, Joshua Gross, Shixiang Shane Gu, Yufei Guo, Chris Hallacy, Jesse Han, Jeff Harris, Yuchen He, Mike Heaton, Johannes Heidecke, Chris Hesse, Alan Hickey, Wade Hickey, Peter Hoeschele, Brandon Houghton, Kenny Hsu, Shengli Hu, Xin Hu, Joost Huizinga, Shantanu Jain, Shawn Jain, Joanne Jang, Angela Jiang, Roger Jiang, Haozhun Jin, Denny Jin, Shino Jomoto, Billie Jonn, Heewoo Jun, Tomer Kaftan, Łukasz Kaiser, Ali Kamali, Ingmar Kanitscheider, Nitish Shirish Keskar, Tabarak Khan, Logan Kilpatrick, Jong Wook Kim, Christina Kim, Yongjik Kim, Jan Hendrik Kirchner, Jamie Kiros, Matt Knight, Daniel Kokotajlo, Łukasz Kondraciuk, Andrew Kondrich, Aris Konstantinidis, Kyle Kosic, Gretchen Krueger, Vishal Kuo, Michael Lampe, Ikai Lan, Teddy Lee, Jan Leike, Jade Leung, Daniel Levy, Chak Ming Li, Rachel Lim, Molly Lin, Stephanie Lin, Mateusz Litwin, Theresa Lopez, Ryan Lowe, Patricia Lue, Anna Makanju, Kim Malfacini, Sam Manning, Todor Markov, Yaniv Markovski, Bianca Martin, Katie Mayer, Andrew Mayne, Bob McGrew, Scott Mayer McKinney, Christine McLeavey, Paul McMillan, Jake McNeil, David Medina, Aalok Mehta, Jacob Menick, Luke Metz, Andrey Mishchenko, Pamela Mishkin, Vinnie Monaco, Evan Morikawa, Daniel Mossing, Tong Mu, Mira Murati, Oleg Murk, David Mély, Ashvin Nair, Reiichiro Nakano, Rajeev Nayak, Arvind Neelakantan, Richard Ngo, Hyeonwoo Noh, Long Ouyang, Cullen O’Keefe, Jakub Pachocki, Alex Paino, Joe Palermo, Ashley Pantuliano, Giambattista Parascandolo, Joel Parish, Emy Parparita, Alex Passos, Mikhail Pavlov, Andrew Peng, Adam Perelman, Filipede Avila Belbute Peres, Michael Petrov, Henrique Ponde de Oliveira Pinto, Michael, Pokorný, Michelle Pokrass, Vitchyr H. Pong, Tolly Powell, Alethea Power, Boris Power, Elizabeth Proehl, Raul Puri, Alec Radford, Jack Rae, Aditya Ramesh, Cameron Raymond, Francis Real, Kendra Rimbach, Carl Ross, Bob Rotsted, Henri Roussez, Nick Ryder, Mario Saltarelli, Ted Sanders, Shibani Santurkar, Girish Sastry, Heather Schmidt, David Schnurr, John Schulman, Daniel Selsam, Kyla Sheppard, Toki Sherbakov, Jessica Shieh, Sarah Shoker, Pranav Shyam, Szymon Sidor, Eric Sigler, Maddie Simens, Jordan Sitkin, Katarina Slama, Ian Sohl, Benjamin Sokolowsky, Yang Song, Natalie Staudacher, Felipe Petroski Such, Natalie Summers, Ilya Sutskever, Jie Tang, Nikolas Tezak, Madeleine B. Thompson, Phil Tillet, Amin Tootoonchian, Elizabeth Tseng, Preston Tuggle, Nick Turley, Jerry Tworek, Juan Felipe Cerón Uribe, Andrea Vallone, Arun Vijayvergiya, Chelsea Voss, Carroll Wainwright, Justin Jay Wang, Alvin Wang, Ben Wang, Jonathan Ward, Jason Wei, CJ Weinmann, Akila Welihinda, Peter Welinder, Jiayi Weng, Li-

- lian Weng, Matt Wiethoff, Dave Willner, Clemens Winter, Samuel Wolrich, Hannah Wong, Lauren Workman, Sherwin Wu, Jeff Wu, Michael Wu, Kai Xiao, Tao Xu, Sarah Yoo, Kevin Yu, Qiming Yuan, Wojciech Zaremba, Rowan Zellers, Chong Zhang, Marvin Zhang, Shengjia Zhao, Tianhao Zheng, Juntang Zhuang, William Zhuk και Barret Zoph. Gpt-4 technical report, 2024.
- [73] Long Ouyang, Jeff Wu, Xu Jiang, Diogo Almeida, Carroll L. Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, John Schulman, Jacob Hilton, Fraser Kelton, Luke Miller, Maddie Simens, Amanda Askell, Peter Welinder, Paul Christiano, Jan Leike και Ryan Lowe. Training language models to follow instructions with human feedback, 2022.
- [74] Jaak Panksepp. *Affective Neuroscience: The Foundations of Human and Animal Emotions*. Oxford University Press, 1998.
- [75] Sinno Jialin Pan και Qiang Yang. A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering*, 22(10):1345–1359, 2010.
- [76] Sungjoon Park, Jiseon Kim, Seonghyeon Ye, Jaeyeol Jeon, Hee Young Park και Alice Oh. Dimensional emotion detection from categorical emotion, 2021.
- [77] Guanxiong Pei, Haiying Li, Yandi Lu, Yanlei Wang, Shizhen Hua και Taihao Li. Affective computing: Recent advances, challenges, and future trends. *Intelligent Computing*, 3:0076, 2024.
- [78] Sancheng Peng, Rong Zeng, Hongzhan Liu, Guanghao Chen, Ruihuan Wu, Aimin Yang και Shui Yu. *Emotion Classification of Text Based on BERT and Broad Learning System*, σελίδες 382–396. 2021.
- [79] Jeffrey Pennington, Richard Socher και Christopher Manning. GloVe: Global vectors for word representation. Στο *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)* Alessandro Moschitti, Bo Pang και Walter Daelemans, επιμελητές, σελίδες 1532–1543, Doha, Qatar, 2014. Association for Computational Linguistics.
- [80] Matthew E. Peters, Mark Neumann, Mohit Iyyer, Matt Gardner, Christopher Clark, Kenton Lee και Luke Zettlemoyer. Deep contextualized word representations, 2018.
- [81] Fabio Petroni, Tim Rocktäschel, Sebastian Riedel, Patrick Lewis, Anton Bakhtin, Yuxiang Wu και Alexander Miller. Language models as knowledge bases? Στο *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)* Kentaro Inui, Jing Jiang, Vincent Ng και Xiaojun Wan, επιμελητές, σελίδες 2463–2473, Hong Kong, China, 2019. Association for Computational Linguistics.

- [82] Rosalind W. Picard. Affective computing. Στο *Affective Computing*, 1997.
- [83] Robert Plutchik. The nature of emotions: Human emotions have deep evolutionary roots, a fact that may explain their complexity and provide tools for clinical practice. *American Scientist*, 89(4):344–350, 2001.
- [84] Soujanya Poria, Erik Cambria, Devamanyu Hazarika, Navonil Majumder, Amir Zadeh και Louis Philippe Morency. Context-dependent sentiment analysis in user-generated videos. Στο *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)* Regina Barzilay και Min Yen Kan, επιμελητές, σελίδες 873–883, Vancouver, Canada, 2017. Association for Computational Linguistics.
- [85] Aman Priyanshu, Yash Maurya και Zuofei Hong. Ai governance and accountability: An analysis of anthropic’s claude, 2024.
- [86] Qianqian Qi, David J. Hessen και Peter G. M. van der Heijden. Improving information retrieval through correspondence analysis instead of latent semantic analysis. *Journal of Intelligent Information Systems*, 62(1), 2023.
- [87] Alec Radford και Karthik Narasimhan. Improving language understanding by generative pre-training. 2018.
- [88] Alec Radford, Jeff Wu, Rewon Child, David Luan, Dario Amodei και Ilya Sutskever. Language models are unsupervised multitask learners. 2019.
- [89] Evani Radiya-Dixit και Xin Wang. How fine can fine-tuning be? learning efficient language models, 2020.
- [90] Md Mahbubur Rahman και Shaila Shova. Emotion detection from social media posts, 2023.
- [91] Robert Rieber και David Robinson. *Wilhelm Wundt in History: The Making of a Scientific Psychology*. 2001.
- [92] James A Russell και Albert Mehrabian. Evidence for a three-factor theory of emotions. *Journal of Research in Personality*, 11(3):273–294, 1977.
- [93] Ofoghi B. Saffar AH, Mann TK. Textual emotion detection in health: Advances and applications. *PubMed, J Biomed Inform*, 2022.
- [94] G. Salton, A. Wong και C. S. Yang. A vector space model for automatic indexing. *Commun. ACM*, 18(11):613–620, 1975.
- [95] Victor Sanh, Albert Webson, Colin Raffel, Stephen H. Bach, Lintang Sutawika, Zaid Alyafeai, Antoine Chaffin, Arnaud Stiegler, Teven Le Scao, Arun Raja, Manan Dey,

- M Saiful Bari, Canwen Xu, Urmish Thakker, Shanya Sharma Sharma, Eliza Szczechla, Taewoon Kim, Gunjan Chhablani, Nihal Nayak, Debajyoti Datta, Jonathan Chang, Mike Tian Jian Jiang, Han Wang, Matteo Manica, Sheng Shen, Zheng Xin Yong, Harshit Pandey, Rachel Bawden, Thomas Wang, Trishala Neeraj, Jos Rozen, Abheesht Sharma, Andrea Santilli, Thibault Fevry, Jason Alan Fries, Ryan Teehan, Tali Bers, Stella Biderman, Leo Gao, Thomas Wolf και Alexander M. Rush. Multitask prompted training enables zero-shot task generalization, 2022.
- [96] Amy M. Schmitter. 17th and 18th Century Theories of Emotions. Στο *The Stanford Encyclopedia of Philosophy* Edward N. Zalta, επιμελήτης. Metaphysics Research Lab, Stanford University, Summer 2021η έκδοση, 2021.
- [97] Sofia Schöbel, Anuschka Schmitt, Dennis Benner, Mohammed Saqr, Andreas Janson και Jan Marco Leimeister. Charting the evolution and future of conversational agents: A research agenda along five waves and new frontiers. *Information Systems Frontiers*, 26(2):729–754, 2023.
- [98] Richard Socher, Alex Perelygin, Jean Wu, Jason Chuang, Christopher D. Manning, Andrew Ng και Christopher Potts. Recursive deep models for semantic compositionality over a sentiment treebank. Στο *Proceedings of the 2013 Conference on Empirical Methods in Natural Language Processing* David Yarowsky, Timothy Baldwin, Anna Korhonen, Karen Livescu και Steven Bethard, επιμελητές, σελίδες 1631–1642, Seattle, Washington, USA, 2013. Association for Computational Linguistics.
- [99] Carlo Strapparava και Alessandro Valitutti. WordNet affect: an affective extension of WordNet. Στο *Proceedings of the Fourth International Conference on Language Resources and Evaluation (LREC'04)* Maria Teresa Lino, Maria Francisca Xavier, Fátima Ferreira, Rute Costa και Raquel Silva, επιμελητές, Lisbon, Portugal, 2004. European Language Resources Association (ELRA).
- [100] Chi Sun, Xipeng Qiu, Yige Xu και Xuanjing Huang. How to fine-tune bert for text classification? Στο *CCL* Maosong Sun, Xuanjing Huang, Heng Ji, Zhiyuan Liu και Yang Liu, επιμελητές, τόμος 11856 στο *Lecture Notes in Computer Science*, σελίδες 194–206. Springer, 2019.
- [101] Krishna Thakkar και Nimit Jagdishbhai. Exploring the capabilities and limitations of gpt and chat gpt in natural language processing. *Journal of Management Research and Analysis*, 10:18–20, 2023.
- [102] Tan Thongtan και Tanasanee Phienthrakul. Sentiment classification using document embeddings trained with cosine similarity. Στο *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics: Student Research Workshop* Fernando Alva-Manchego, Eunsol Choi και Daniel Khashabi, επιμελητές, σελίδες 407–414, Florence, Italy, 2019. Association for Computational Linguistics.

- [103] Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, Aurelien Rodriguez, Armand Joulin, Edouard Grave και Guillaume Lample. Llama: Open and efficient foundation language models, 2023.
- [104] Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, Yasmine Babaei, Nikolay Bashlykov, Soumya Batra, Prajjwal Bhargava, Shruti Bhosale, Dan Bikel, Lukas Blecher, Cristian Canton Ferrer, Moya Chen, Guillem Cucurull, David Esiobu, Jude Fernandes, Jeremy Fu, Wenyin Fu, Brian Fuller, Cynthia Gao, Vedanuj Goswami, Naman Goyal, Anthony Hartshorn, Saghar Hosseini, Rui Hou, Hakan Inan, Marcin Kardas, Viktor Kerkez, Madian Khabsa, Isabel Kloumann, Artem Korenev, Punit Singh Koura, Marie Anne Lachaux, Thibaut Lavril, Jenya Lee, Diana Liskovich, Yinghai Lu, Yuning Mao, Xavier Martinet, Todor Mihaylov, Pushkar Mishra, Igor Molybog, Yixin Nie, Andrew Poulton, Jeremy Reizenstein, Rashi Rungta, Kalyan Saladi, Alan Schelten, Ruan Silva, Eric Michael Smith, Ranjan Subramanian, Xiaoqing Ellen Tan, Binh Tang, Ross Taylor, Adina Williams, Jian Xiang Kuan, Puxin Xu, Zheng Yan, Iliyan Zarov, Yuchen Zhang, Angela Fan, Melanie Kambadur, Sharan Narang, Aurelien Rodriguez, Robert Stojnic, Sergey Edunov και Thomas Scialom. Llama 2: Open foundation and fine-tuned chat models, 2023.
- [105] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser και Illia Polosukhin. Attention is all you need, 2023.
- [106] J.L. Vives και C.G. Noreña. *The Passions of the Soul: The Third Book of De Anima Et Vita*. Αριθμός β. 3 στο Studies in Renaissance literature. E. Mellen Press, 1990.
- [107] Anshul Wadhawan και Akshita Aggarwal. Towards emotion recognition in hindi-english code-mixed data: A transformer based approach, 2021.
- [108] Jason Wei, Maarten Bosma, Vincent Y. Zhao, Kelvin Guu, Adams Wei Yu, Brian Lester, Nan Du, Andrew M. Dai και Quoc V. Le. Finetuned language models are zero-shot learners, 2022.
- [109] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc Le και Denny Zhou. Chain-of-thought prompting elicits reasoning in large language models, 2023.
- [110] Tim Wildschut, Constantine Sedikides, Jamie Arndt και Clay Routledge. Nostalgia: content, triggers, functions. *Journal of personality and social psychology*, 91(5):975, 2006.
- [111] Zehui Wu, Ziwei Gong, Lin Ai, Pengyuan Shi, Kaan Donbekci και Julia Hirschberg. Beyond silent letters: Amplifying llms in emotion recognition with vocal nuances, 2024.

-
- [112] Haiqin Yang και Jianping Shen. Emotion dynamics modeling via bert, 2021.
- [113] Yifan Yao, Jinhao Duan, Kaidi Xu, Yuanfang Cai, Zhibo Sun και Yue Zhang. A survey on large language model (llm) security and privacy: The good, the bad, and the ugly. *High-Confidence Computing*, 4(2):100211, 2024.
- [114] Mengjie Zhao, Tao Lin, Fei Mi, Martin Jaggi και Hinrich Schütze. Masking as an efficient alternative to finetuning for pretrained language models. Στο *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)* Bonnie Webber, Trevor Cohn, Yulan He και Yang Liu, επιμελητές, σελίδες 2226–2241, Online, 2020. Association for Computational Linguistics.

Συντομογραφίες - Αρκτικόλεξα - - Ακρωνύμια

βλπ	βλέπε
κ.λπ.	και λοιπά
κ.ο.κ	και ούτω καθεξής
TEI	Τεχνολογικό Εκπαιδευτικό Ίδρυμα
AI	Artificial Intelligence
BoW	Bag of Words
BERT	Bidirectional Encoder Representations from Transformers
CNN	Convolutional Neural Network
DTM	Document Term Matrix
DE	Emotion Detection
ER	Emotion Recognition
GPT	Generative Pre-trained Transformer
ML	Machine Learning
NSP	Next Sentence Prediction
NLP	Natural Language Processing
TF-IDF	Term Frequency-Inverse Document Frequency
RNN	Recurrent neural networks

Απόδοση ξενόγλωσσων όρων

Απόδοση

ανάκτηση πληροφορίας
ένωση
εποχές
σώμα γλωσσικού υλικού
σύνολο
επακόλουθη εργασία
υπο-σύνολο
εξαγωγή γνωρισμάτων
παραίσθηση
υπερ-μοντελοποίηση
λεκτική αναπαράσταση
μητρώο εγγραφών όρων
μέγεθος παρτίδας
σύνολο δεδομένων

Ξενόγλωσσος όρος

information retrieval
union
epochs
corpus
set
downstream task
subset
word representation
hallucination
overfitting
word representation
Document Term Matrix
batch size
dataset

